MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

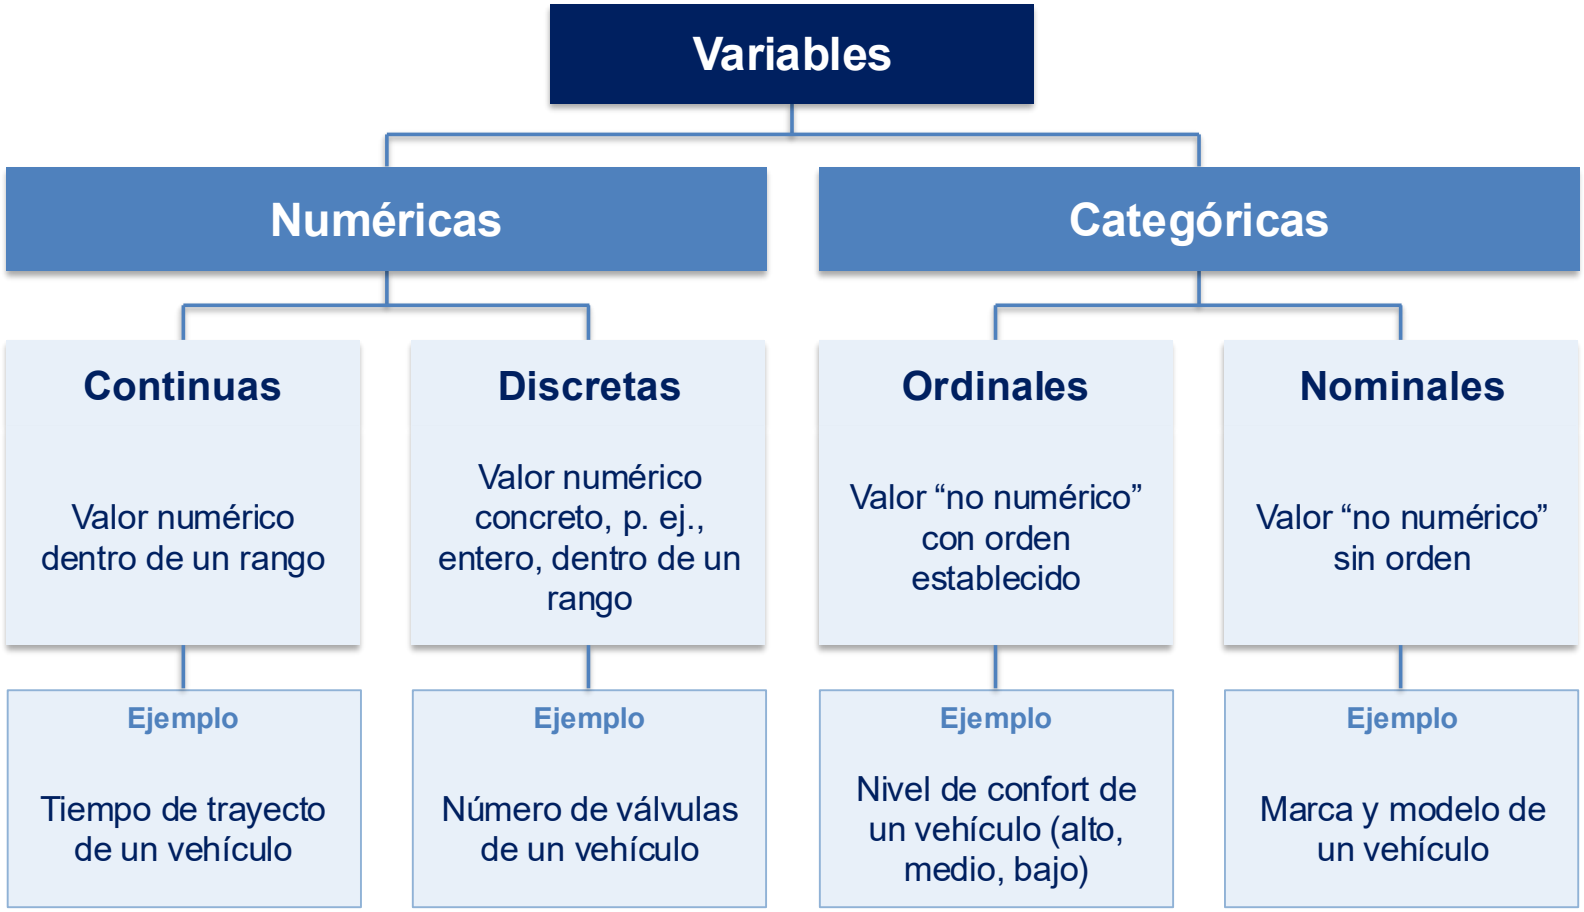
laSalle ENG
Universitat Ramon Llull

Estadística Descriptiva

Noción

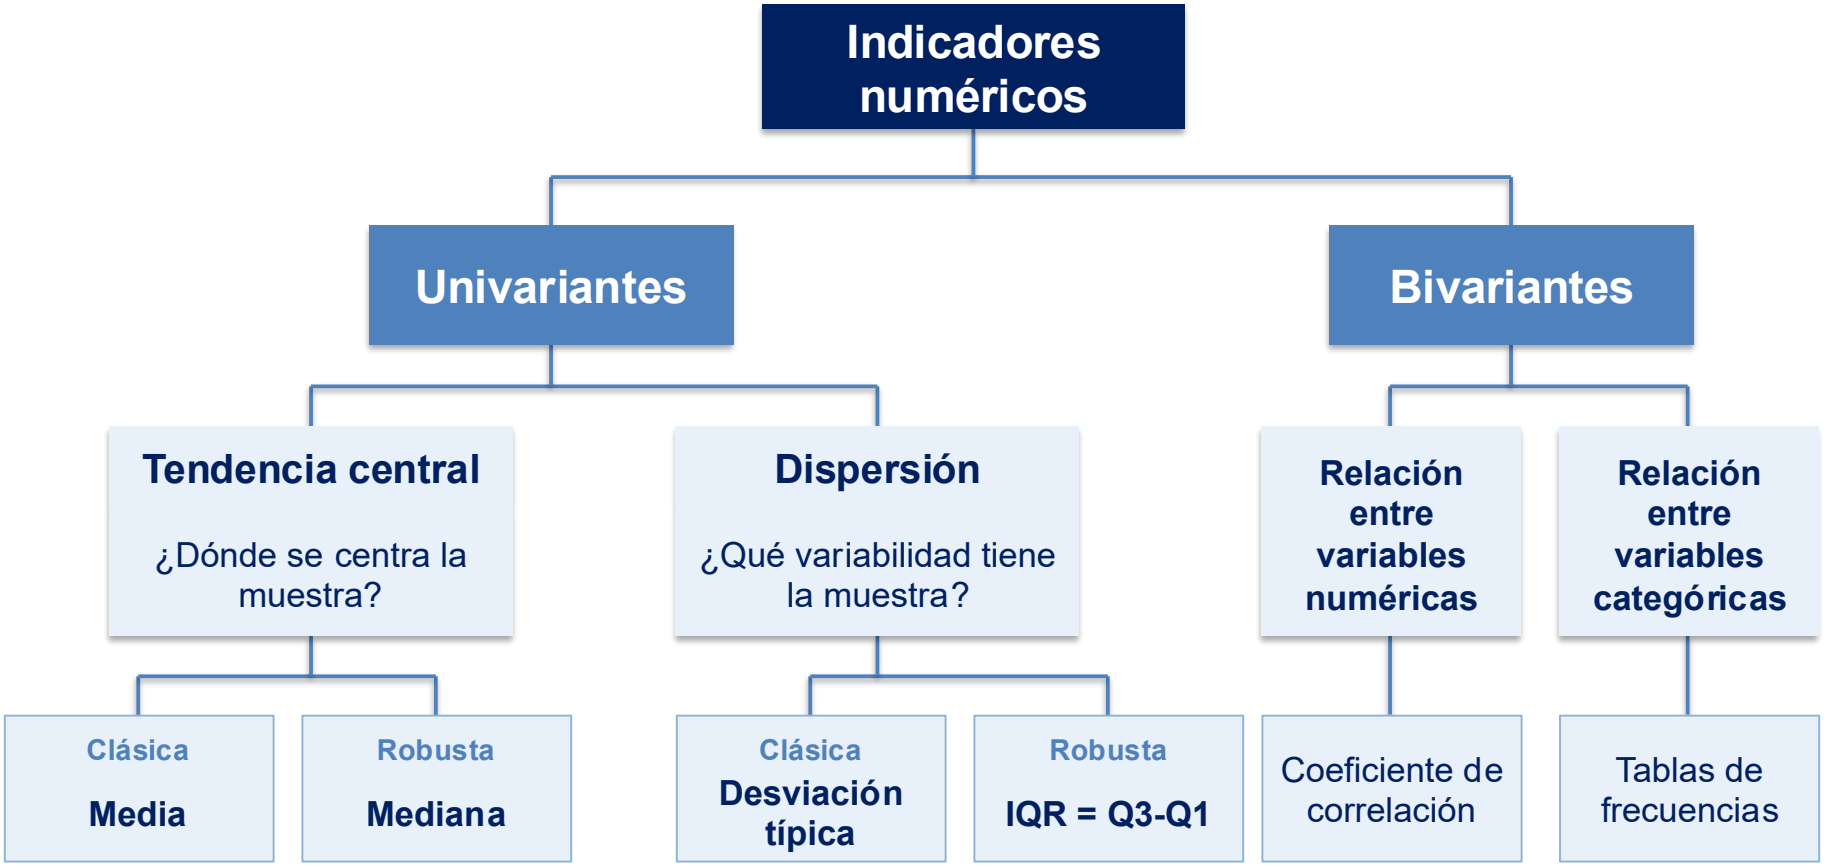
- Objetivo:
  - Univariante: Describir (estadísticamente) las variables de una muestra una a una.
  - Bivariante: Describir (estadísticamente) las relaciones existentes entre dos variables en una muestra
- Herramientas:
  - Indicadores numéricos: media, mediana, desviación típica…
  - Gráficos: histograma, boxplot, diagrama de barras…
- Independientemente del análisis a realizar, siempre se debe realizar una descriptiva de los mismos para conocerlos.

Tipos de variables



Indicadores numéricos

Los indicadores univariantes, sobre todo, aplican a variables numéricas continuas.



Gráficos descriptivos

- **Gráficos**
  - **Descriptiva univariante**
    - **Numérica continua**
      - **Boxplot**
      - **Histograma**
    - **Categórica o numérica discreta**
      - **Barplot**
  - **Descriptiva bivariante**
    - **2 numéricas continuas**
      - **Scatterplot**
    - **Una numérica y una categórica**
      - **Boxplot múltiple**
    - **2 categóricas o numéricas discretas**
      - **Barplot bivariante**
      - **Mosaic plot**

Numérica - indicadores clásicos

Media, varianza y desviación típica

Media

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 22.22$$

n: longitud de la muestra
x_i: observación i-ésima

Varianza

$$S_x^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = 40.53$$

Desviación típica o estándar

$$S_x = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} = 6.37$$

```
> ## Calcular media de la edad
> datos["Age"].mean()
[1] 22.21788

> ## Calcular varianza de la edad
> datos["Age"].var()
[1] 40.53091

> ## Calcular desviación típica de la edad
> datos["Age"].std(skipna=True, ddof=1)
[1] 6.366389
```

La varianza (V) y la desviación típica (DT) son medidas de la variabilidad de la muestra.: La DT indica cuánto se alejan en promedio mis observaciones de la media. La V es el cuadrado de la DT.

Numérica - indicadores robustos

Mediana, Cuartiles y IQR

Q1: Cuartil 1

Posición Q1 = (n+1)/4 = (179+1)/4 = 45

Q1 = $X_{(45)}$ = 18

Q2: Mediana o Cuartil 2

Posición Q2 = (n+1)/2 = (179+1)/2 = 90

Q2 = $X_{(90)}$ = 20

Q3: Cuartil 3

Posición Q3 = 3·(n+1)/4 = 135

Q3 = $X_{(135)}$ = 24

Rango Intercuartílico

IQR = Q3 - Q1 = 24 – 18 = 6



Mediana (Q2) : valor que deja el 50% de las observaciones por debajo (50% por encima)

Cuartil 1 (Q1): valor que deja el 25% de las observaciones por debajo (75% por encima)

Cuartil 3 (Q3): valor que deja el 75% de les observaciones por debajo (25% por encima)



Si la posición es un entero, el cuartil correspondiente es el valor que ocupe esa posición en la lista de valores ordenados crecientemente. Si no es un entero, se ponderan los valores anterior y posterior según la parte decimal de la posición.

```
> ## Calcular Q3
> datos["Age"].quantile(0.75)

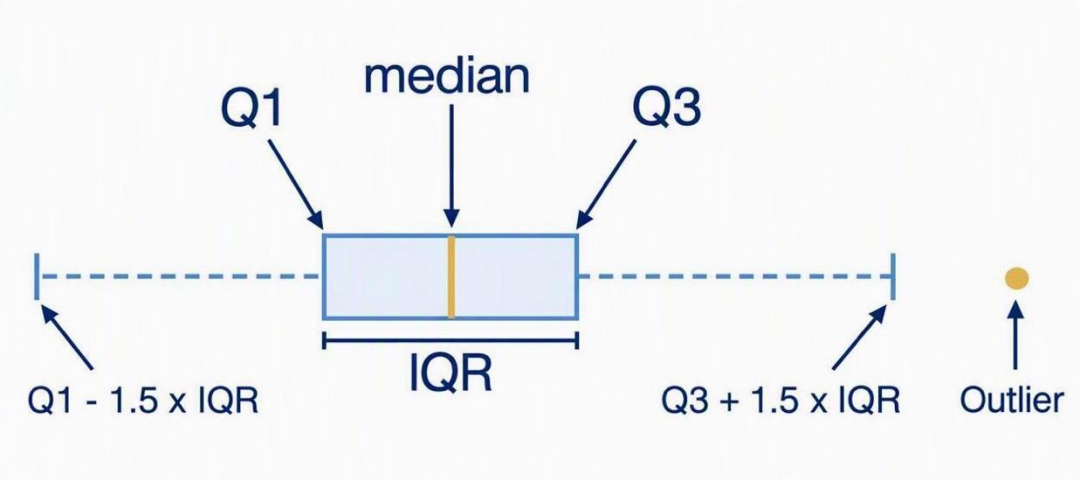
[1] 24
> ## Calcular IQR > IQR(Mobiles$Age)
> datos["Age"].quantile(0.75)-
datos["Age"].quantile(0.25)
[1] 6
```

Numérica - Gráficos

Diagrama de caja (*Boxplot*)

Representa los indicadores robustos y los outliers (datos extremos). Partes:

Caja	Bigotes	Outliers
Delimitada por el Q1 y por el Q3. La línea interior representa la mediana.	Desde la caja con una longitud máxima de 1.5 veces el IQR (=longitud de la caja). Si el mínimo o máximo de la muestra no llegan a esta distancia, el bigote llega hasta estos valores.	Puntos más allá de los bigotes. Se consideran valores anómalos.



Numérica - Gráficos

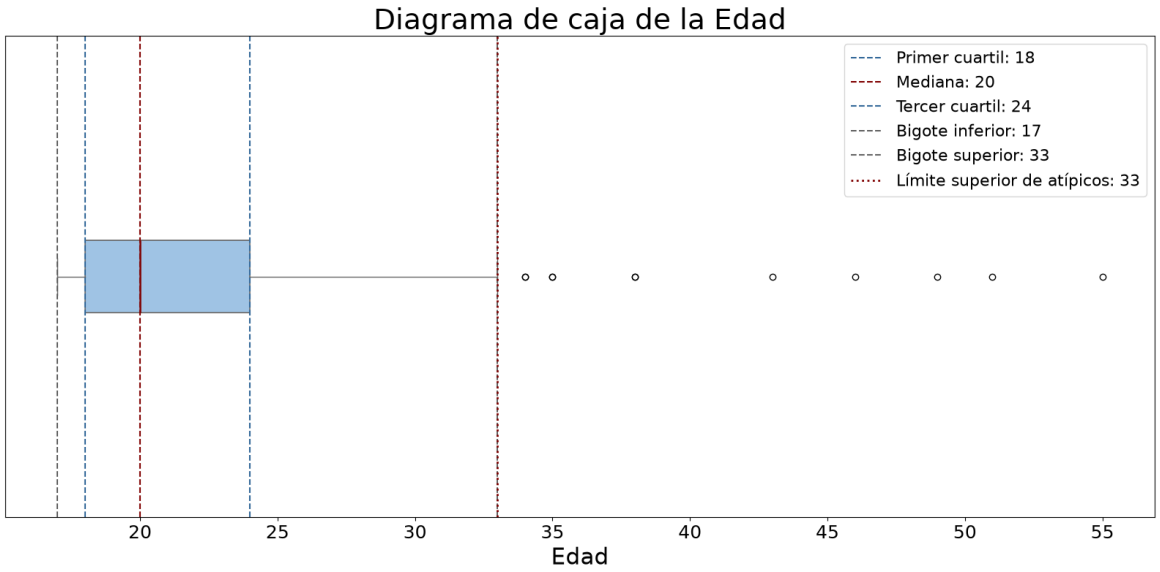
Diagrama de caja (*Boxplot*)

```
> ## Boxplot simple
> _ = datos['Age'].dropna().plot.box()

> plt.show()
```

Los valores de la figura cuadran con la descriptiva numérica. P.ej, la mediana está en el 20.

Los puntos son outliers



Numérica - Gráficos

Outliers



Los outliers son valores anómalos dentro de nuestra muestra

Comprobación de los datos

El primer paso es verificar si se tratan de errores de recogida de los datos

Justificación de la exclusión

En caso de no tratarse de errores, no es aconsejable eliminarlos para hacer el análisis más confortable. *Los valores atípicos no deben eliminarse simplemente por ser extremos. Si no se deben a errores, su exclusión debe estar debidamente justificada.*

Tratamiento de los valores

En algunos casos, existen técnicas para modificar su valor de forma que no distorsionen los análisis

Numérica - Gráficos

Histograma

Representa la distribución de la variable

Lectura del histograma

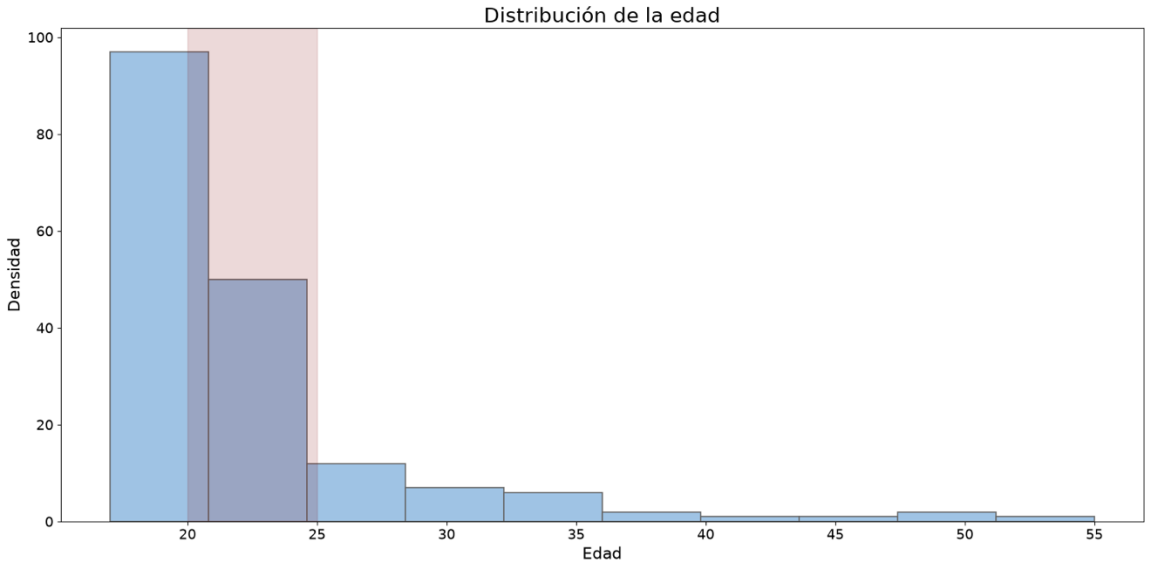
El eje horizontal contiene los valores de la variable y el eje vertical, las frecuencias (o la densidad)

```
> ## Histograma simple
> _ = datos['Age'].dropna().plot.hist(bins=10, density=True)
> _ = plt.ylabel('Densidad')

> plt.show()
```

Hay casi 100 usuarios con menos de 20 años

Densidad = Freq. Rel / Anchura Intervalo



Categórica - indicadores numéricos y gráficos

Tablas y diagramas de barras (*barplots*)

Representa el número de efectivos (frecuencias) para cada categoría

Lectura del diagrama de barras

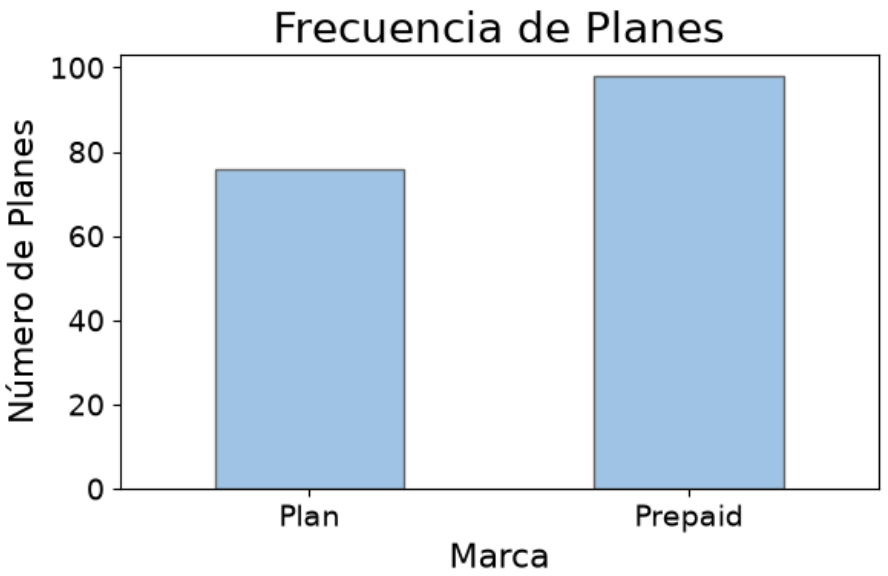
El eje horizontal contiene las categorías de la variable y el eje vertical, las frecuencias (o proporciones)

```
> ## Barplot simple
> _ = datos['Age'].value_counts().plot.bar()
> plt.show()
```

```
> ## Calculo de Frecuencias
> datos["PlanType"].value_counts()

PlanType
Prepaid 98
Plan 76
>
datos["PlanType"].value_counts(normalize=True)

PlanType
Prepaid 0.5632
Plan 0.4367
```



Núm vs Núm - Gráficos

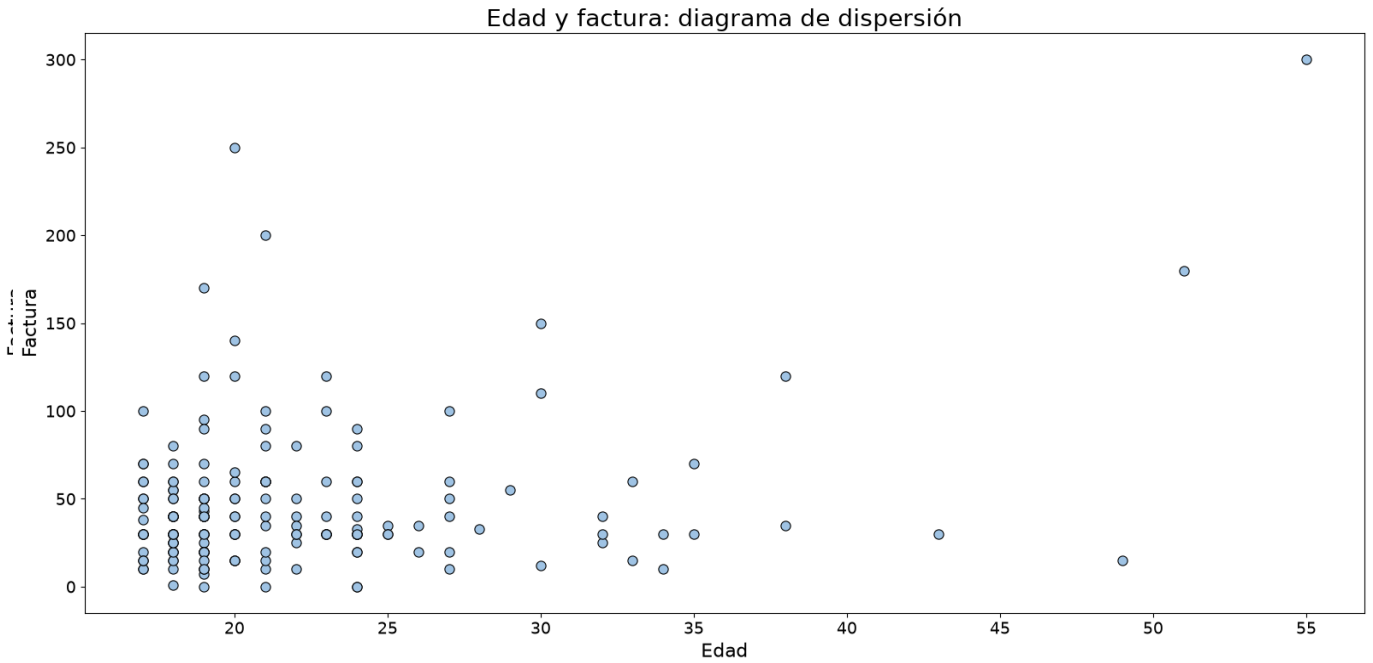
Diagrama de dispersión (*Scatterplot*)

Representa la distribución bivariante de dos variables numéricas.

```
> ## Scatter plot simple
> _ = datos[['Age','Bill']].dropna().plot.scatter(x='Age', y='Bill')
> plt.show()
```

Lectura del diagrama de dispersión

El eje horizontal contiene los valores de la variable explicativa y el eje vertical, de la variable respuesta.



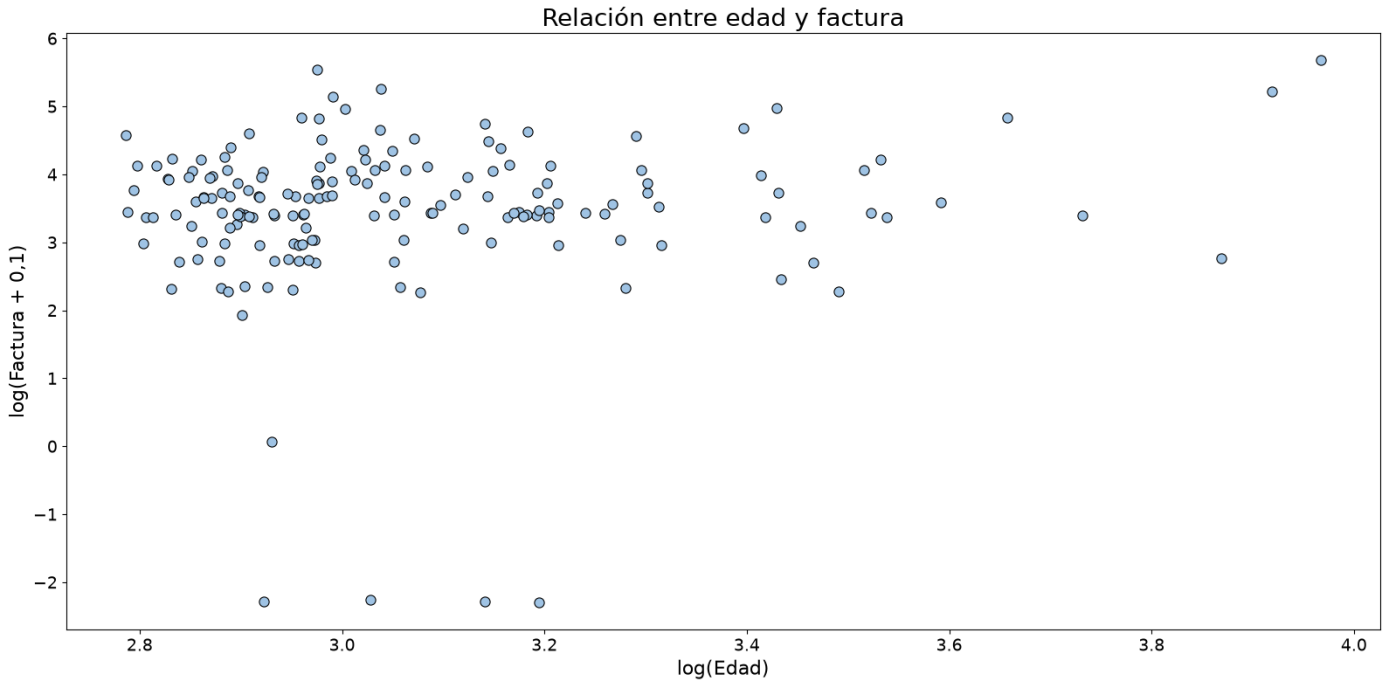
Núm vs Núm - Gráficos

Logaritmos

En ocasiones, los logaritmos "normalizan las variables" (sólo si toman valores estrictamente positivos) permitiendo ver las relaciones de forma más nítida

Conclusión

No parece existir una relación entre el consumo de teléfono y la edad



Núm vs Núm – Indicador numérico

Coeficiente de correlación (r)

Determina la dirección y la intensidad de una relación lineal entre dos variables numéricas

Cálculo

Es resultado de dividir la variación conjunta de X e Y (SXY) entre el producto de las desviaciones estándares de X (SX) e Y (SY)

$$r_{XY} = \frac{S_{XY}}{S_X S_Y} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y}) \Big/ (n-1)}{S_X S_Y} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}$$

n: longitud de la muestra
x_i, y_i: observación i-ésima de x o y
$\bar{x}$, $\bar{y}$: media de x o y
S_x, S_y: desviación de de x o y

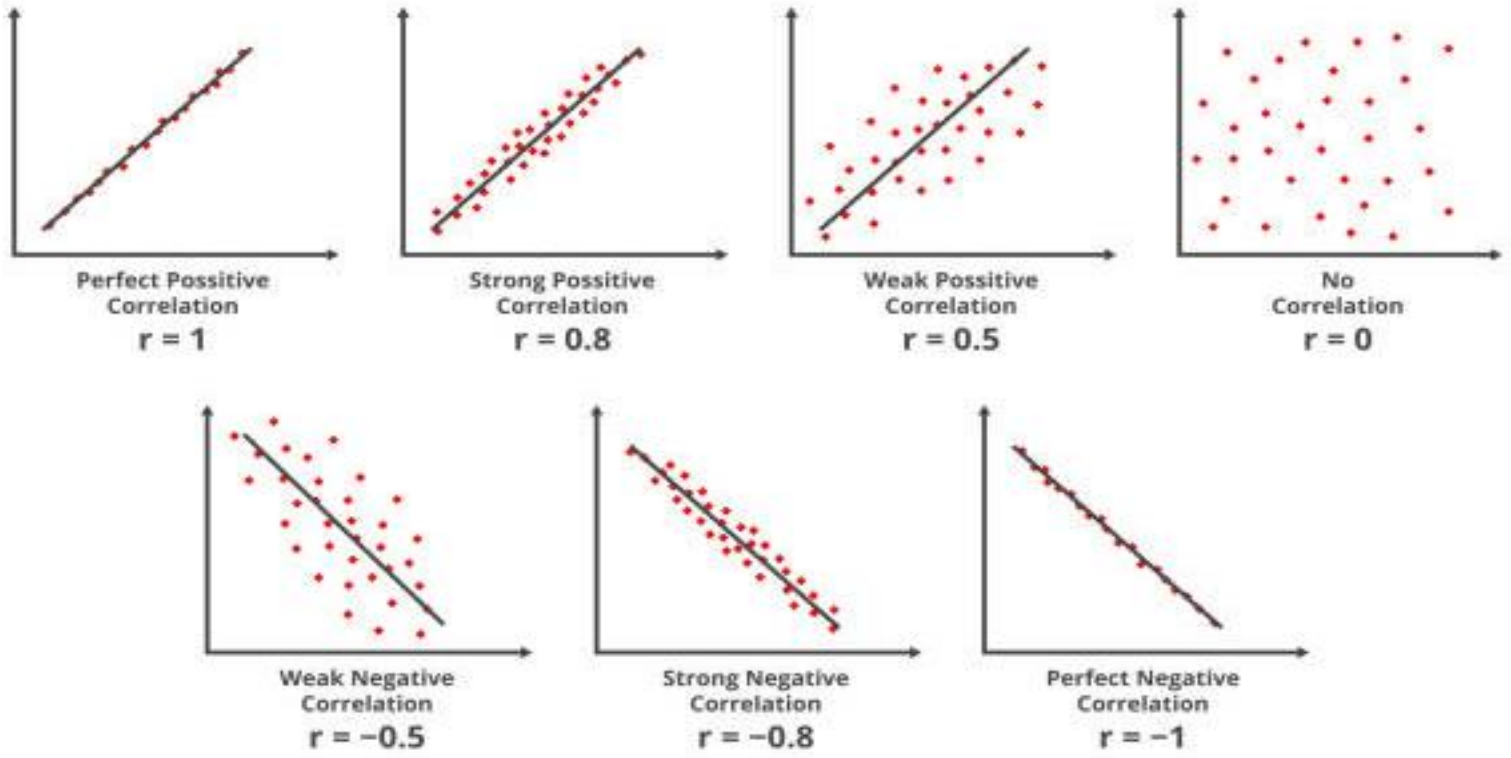
Interpretación

Es un valor entre -1 i +1
El signo indica la dirección de la relación: directa (positivo) o inversa (negativo)
La magnitud en valor absoluto mide la intensidad de la relación
rxy= 0 indica ausencia de relación lineal
rxy = 1 o rxy = -1 indica relación lineal perfecta representable por la recta Y = a + bX

Núm vs Núm – Indicador numérico

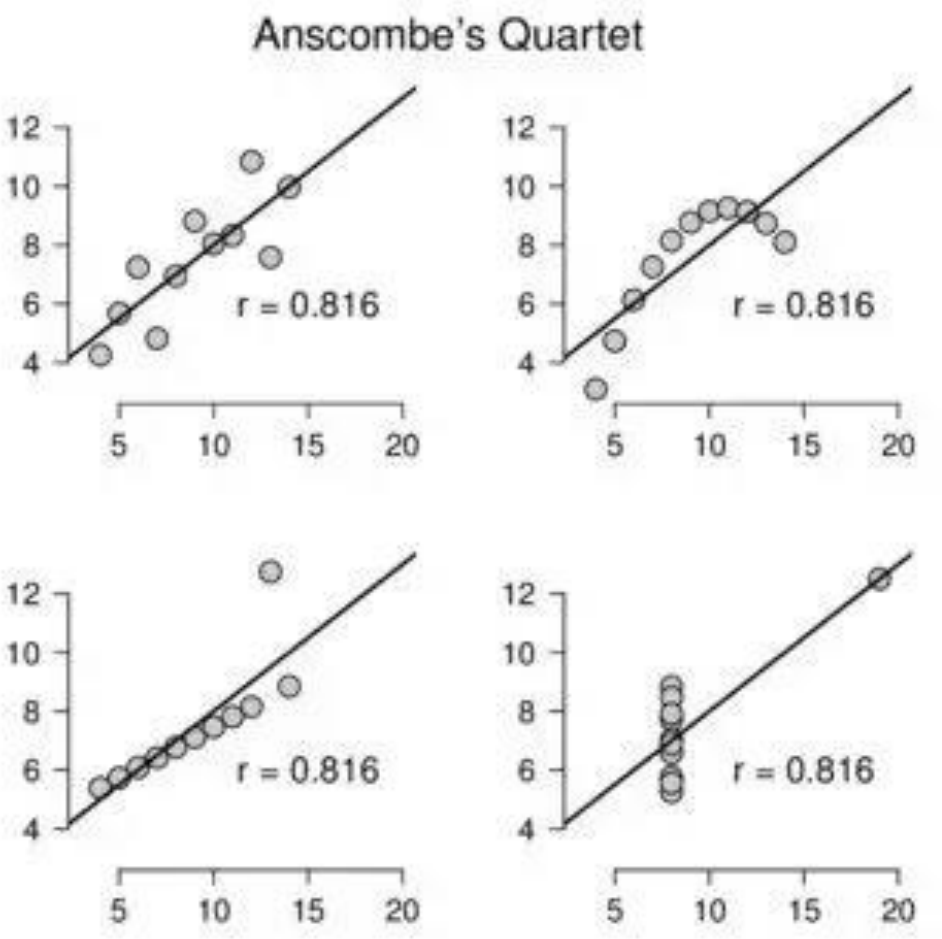
Coeficiente de correlación (r)

Interpretación visual del coeficiente



Núm vs Núm – Indicador numérico

Coeficiente de correlación (r)



La correlación de Pearson mide relaciones lineales

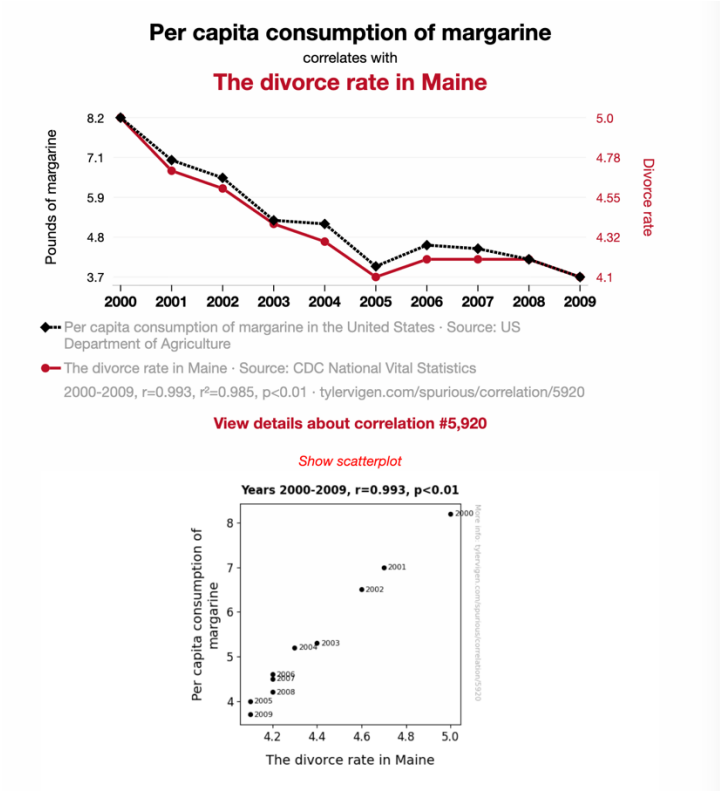
Relaciones monótonas: Spearman o tau de Kendall.

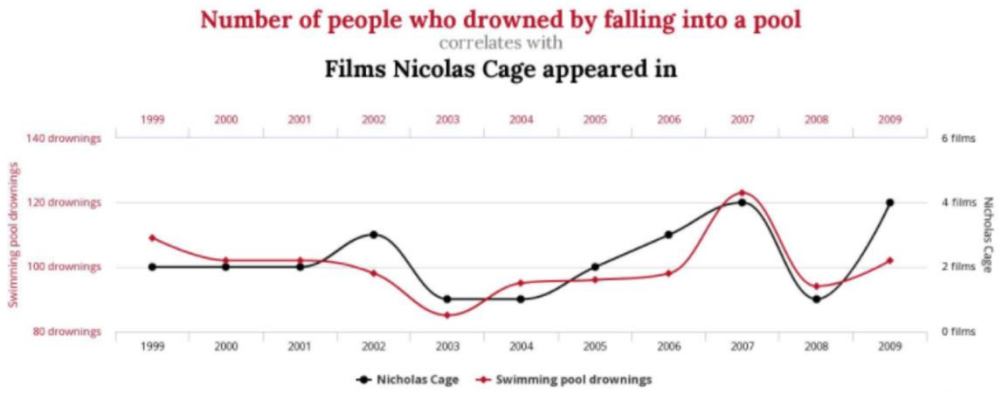
Relaciones no lineales más generales: correlación de distancia o información mutua.

Núm vs Núm – Indicador numérico

Coeficiente de correlación (r)

Correlación no implica causalidad, existe la correlación espuria.





Source: https://tylervigen.com/spurious-correlations

Cat vs Cat – Indicador numérico

Tablas de contingencia



Proporción condicionada: casos de una categoría dentro de un grupo / total del grupo.
Proporción global de esa categoría: casos de la categoría / total de la muestra.
En la tabla global, cada celda representa una combinación / total de la muestra.

```
> pd.crosstab(datos["PlanType"], datos["PrimaryUse"], normalize=normalizacion)
```

Ejemplo SMS: entre Prepaid, 47/98 = 48,0 %; en toda la muestra, 68/174 = 39,1 %.
La proporción condicionada supera la global en 8,9 puntos porcentuales.

Frecuencias

PrimaryUse	Both	Calls	SMS
PlanType			
Plan	33	22	21
Prepaid	35	16	47

Proporciones globales

PrimaryUse	Both	Calls	SMS
PlanType			
Plan	0.189655	0.126437	0.120690
Prepaid	0.201149	0.091954	0.270115

Proporciones por contrato

PrimaryUse	Both	Calls	SMS
PlanType			
Plan	0.434211	0.289474	0.276316
Prepaid	0.357143	0.163265	0.479592

Proporciones por uso

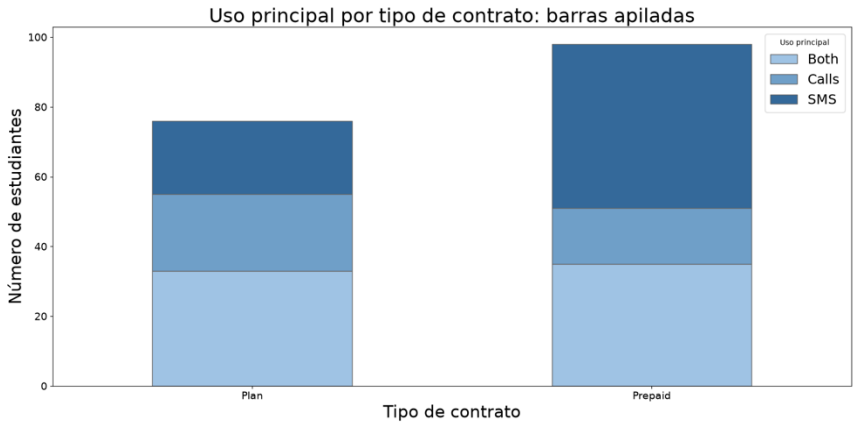
PrimaryUse	Both	Calls	SMS
PlanType			
Plan	0.485294	0.578947	0.308824
Prepaid	0.514706	0.421053	0.691176

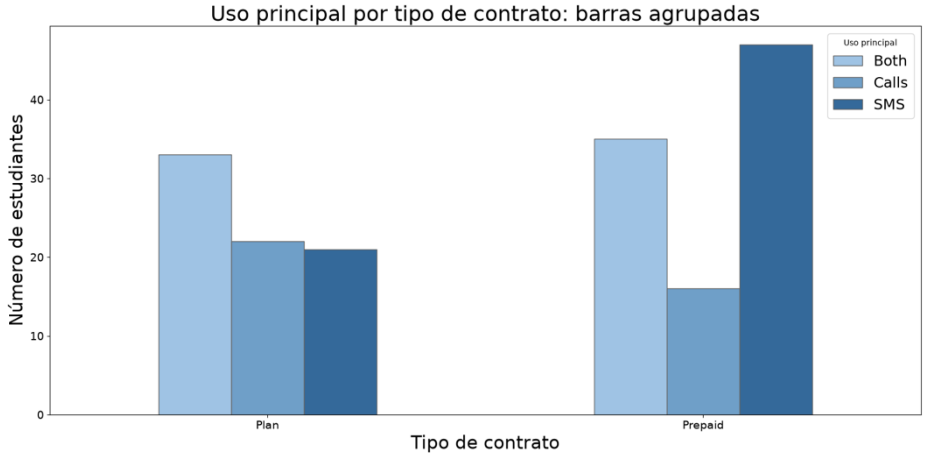
Cat vs Cat – Gráficos

Diagrama de barras (barplot)

Representa las frecuencia de una variable categórica dentro de cada categoría de la otra

```
# Versión simple: recuentos por contrato y uso.
> cruce = pd.crosstab(datos['PlanType'], datos['PrimaryUse'])
> _ = cruce.plot.bar(stacked=True) # stacke=False para tener agrupadas y no apiladas
> plt.show()
```





Cat vs Cat – Gráficos

Diagrama de mosaico (*mosaicplot*)

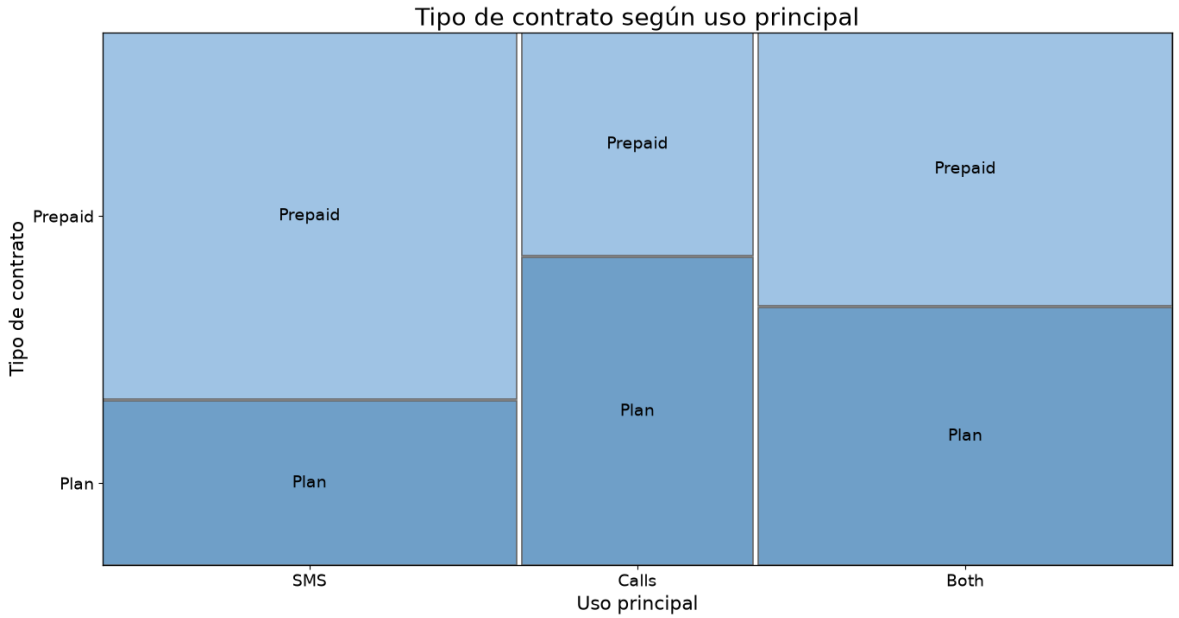
Es la representación gráfica de una tabla de frecuencias entre dos variables categóricas

Cómo se interpreta

Columna: anchura proporcional a la frecuencia de cada categoría de una les variables

Files: altura de cada fila en cada columna proporcional a la frecuencia intra-categoría

```
> ## Mosaic Plot Simple
> from statsmodels.graphics.mosaicplot import mosaic
> mosaic(datos.dropna(subset=['PrimaryUse', 'PlanType']),
['PrimaryUse', 'PlanType'])
```



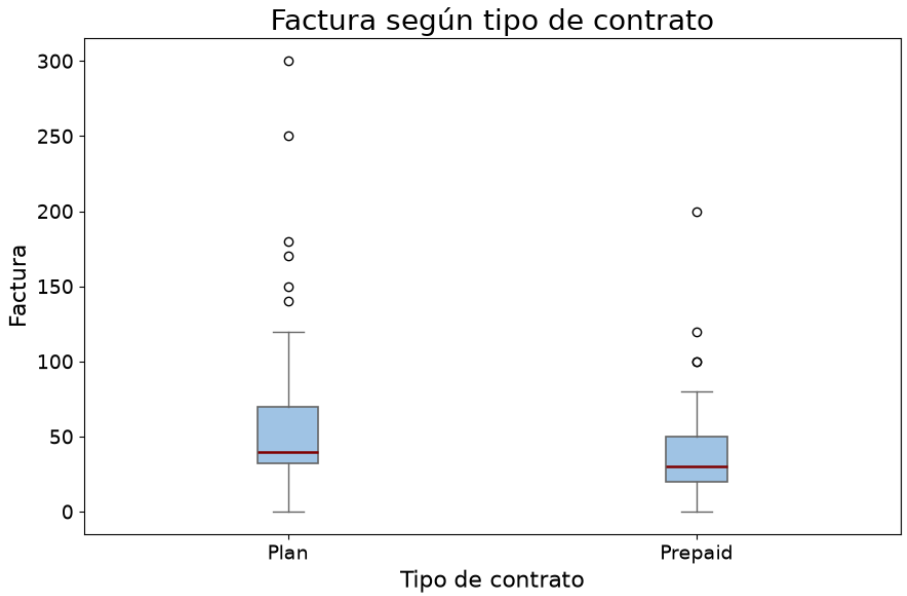
Num vs Cat – Gráficos

Indicadores y Gráficos estratificados

Se hace la descriptiva numérica para cada categoria

```
> ## Indicadores Estratificados
> datos.groupby("PlanType",observed=True)["Bill"].describe()
> ## Bloxplot Simple Estratificado
> _ = datos.boxplot(column='Bill', by='PlanType')
> plt.show()
```

PlanType	count	mean	std	min	25%	50%	75%	max
Plan	76.0	61.171053	51.058499	0.0	32.25	40.0	70.0	300.0
Prepaid	98.0	35.744898	27.966958	0.0	20.00	30.0	50.0	200.0



MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull