MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull

Índice

Inferencia estadística

01 El caso: tres preguntas sobre clientes de telefonía

02 Población, muestra y estimadores

03 Variabilidad muestral e intervalos de confianza

04 Contrastes sobre media, varianza y proporción

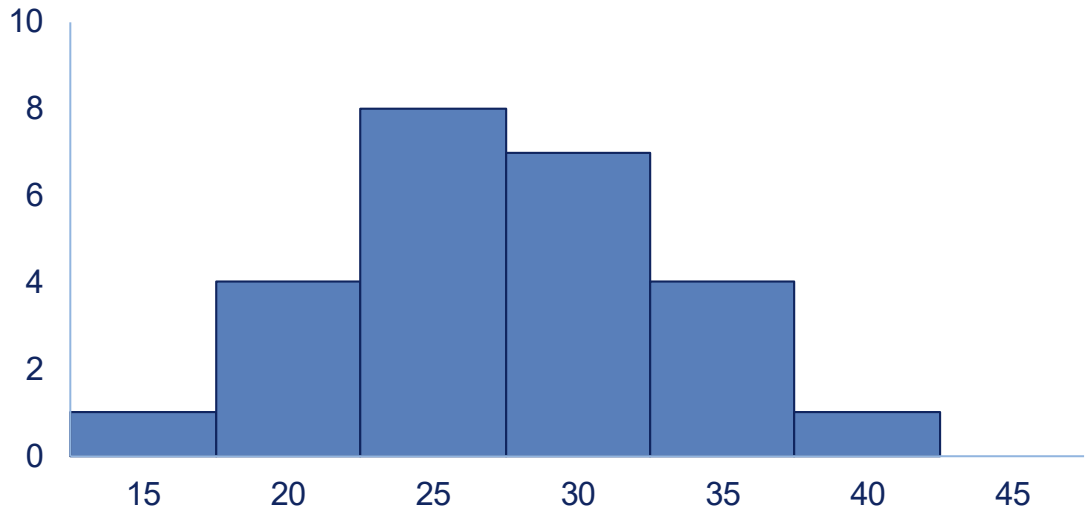
05 Conclusiones del caso de la operadora

06 Anexos: normalidad y bootstrap

Una operadora revisa sus previsiones

Caso sintético: media, variabilidad y proporción

Gasto mensual de 25 clientes (€)



Gasto mensual (€), intervalos de 5 €

27,2 €

Gasto medio observado

¿Media de 30 €?

¿Desviación típica de 8 €?

¿50 % con plan fijo?

¿Qué podemos inferir sobre todos los clientes a partir de esta muestra?

Referencias ilustrativas fijadas antes del análisis. α = 0,05 por contraste.

Inferencia estadística

Introducción

- La inferencia estadística permite **inferir características de una población** a partir de una muestra.



- Cuantifica la **incertidumbre** de esas conclusiones bajo determinados supuestos.

- **Muestreo:** población → muestra (selección y recogida de datos).
- **Deducción:** modelo de población → comportamiento de las muestras.
- **Inducción:** muestra → población (estimar parámetros y contrastar hipótesis).

Inferencia estadística

Conceptos básicos

- **Población**: conjunto de elementos en estudio sobre los cuales deseamos extraer conclusiones
- **Parámetro**: indicador de la población se desea conocer.
- **Muestra**: pieza representativa de la población que sirve para obtener conocimiento de la misma
- **Estadístico**: función de los datos de la muestra
- **Estimador**: estadístico que sirve para estimar un parámetro de la población

Parámetros y estimadores

Ejemplos más representativos

Parámetro (θ) (POBLACIÓN)	Estimador ($\hat{\theta}$) (MUESTRA)
μ (Esperanza, media poblacional)	$\bar{x}$ (media muestral)
σ^2 (varianza poblacional) σ (desviación típica poblacional)	s^2 (varianza muestral) s (desviación típica muestral)
π (probabilidad)	p (proporción)

Las palabras media y desviación se utilizan indistintamente para referirse al parámetro o al estimador llevando a confusión.

Población, muestra y estimación

Ejemplos reales

Población y parámetros	Muestra y estimaciones
Clientes adultos activos durante el mes de estudio	25 clientes seleccionados al azar Una observación por persona
Esperanza del gasto: μ	Media muestral: $\bar{x}$ = 27,2 €
Varianza del gasto: σ^2	Varianza muestral: $s^2 \approx 36{,}06$ €² Desviación típica: $s \approx 6{,}0$ €
Probabilidad de plan fijo: π	Proporción muestral: $\hat{p}$ = 16/25 = 64 %



Seleccionar clientes solo de una tienda o de un plan puede sesgar la muestra.

Estimación puntual

Propiedades de los estimadores

- Inevitablemente, las estimaciones puntuales **fluctúan**: como dependen de la muestra recogida, varían entre las distintas muestras (aunque nosotros sólo observamos una de las posibles muestras).
- Las dos obsesiones de la Estadística son:
  - **Cuantificar** los errores de estimación.
  - **Minimizar** estos errores.
- El **error típico o estándar** informa de cuánto varía el estimador entre muestras del mismo tamaño y, por tanto, de la precisión al estimar el parámetro poblacional.
- No obstante, para una muestra concreta, el **error exacto es desconocido**: su magnitud puede ser superior o inferior al error típico.

Estimación puntual

Los 25 clientes: estimaciones en Python

Gasto mensual de 25 clientes (€).

Media muestral

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 27{,}2\ €$$

Desviación típica muestral

$$S_x = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} \approx 6{,}005\ €$$

Error estándar de la media

$$\mathrm{SE} = \frac{S_x}{\sqrt{n}} \approx 1{,}201\ €$$

```
> from scipy import stats
> n = len(gasto_eur)  # 25

> # Media
> gasto_eur.mean()
[1] 27.2

> # Desviación típica
> gasto_eur.std(ddof=1)
[1] 6.005

> # Error estándar
> stats.sem(gasto_eur)
[1] 1.201
```

La media estima μ y la desviación típica estima σ. *El error estándar mide cuánto varía la media entre muestras.*

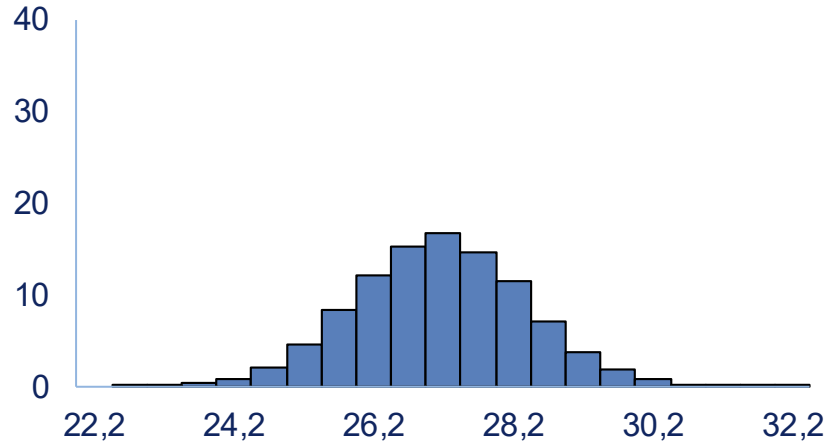
Tamaño muestral y precisión

Medias de muestras de 25 y 100 clientes

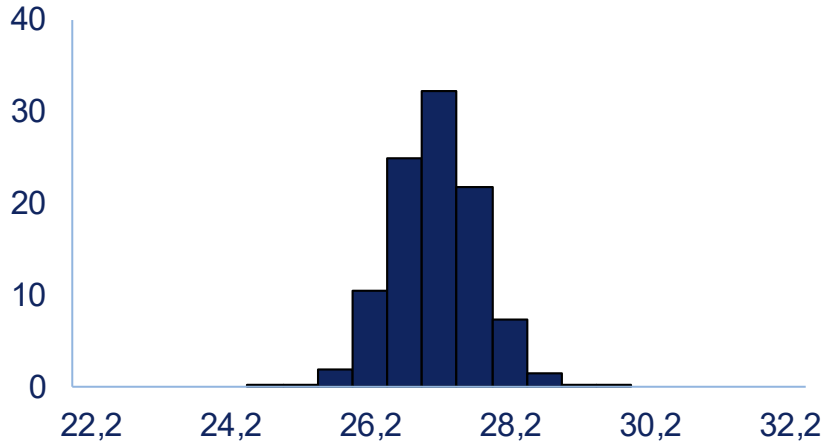
Cuadruplicar n reduce a la mitad el SE de la media.

Si las observaciones son independientes y la variabilidad poblacional no cambia.

25 clientes: SE = 1,2 €



100 clientes: SE = 0,6 €



Medias de muestras (€), no gastos individuales. Altura: % de medias por intervalo.

El error exacto respecto a μ sigue siendo desconocido.

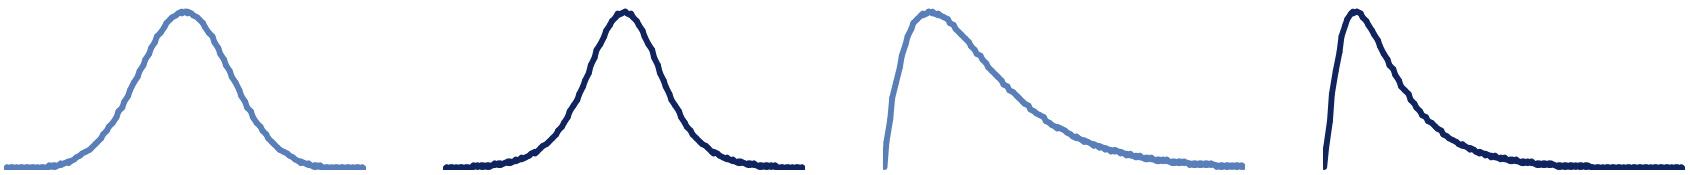
Simulación: μ = 27,2 €, σ = 6 €. 10.000 muestras por tamaño. El caso sigue con 25 clientes.

Distribuciones

Enumeración

- Para poder cuantificar la incertidumbre de nuestras estimaciones, se deben conocer la distribución de los **estimadores/estadísticos** a lo largo de infinitas muestras.
- En el anexo de distribuciones se encuentran las distribuciones más usuales en inferencia estadística.

Normal **t-Student** **Ji-cuadrado** **F de Fisher**



KDE ilustrativas con datos sintéticos. Escalas propias para mostrar la forma de cada distribución.

Normalidad exacta

La media muestral es normal si las observaciones son independientes y proceden de una población normal.

Aproximación normal

Con observaciones independientes de la misma población y varianza finita, se aproxima a una normal al aumentar n. La calidad depende de la población. **Concepto: Teorema Central del Límite**

Seeing Theory: explora las distribuciones y el TCL (Brown University)

Intervalo de confianza para la media (μ)

Pregunta 1: ¿Es el gasto medio de los clientes 30 euros?

El intervalo de confianza (IC) para la media poblacional, con confianza 1 − α, se calcula con la siguiente expresión:

$$IC(\mu, 1-\alpha) = \bar{x} \pm t_{n-1,1-\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}}$$

```
> stats.t.interval(0.95, df=24, loc=27.2,
    scale=stats.sem(gasto_eur))
[1] (24.7212, 29.6788)
```

La amplitud del intervalo depende de:

Confianza (1 − α)

Determina el cuantil t.
A mayor confianza, mayor amplitud y menor precisión.

Variabilidad (s)

Una mayor desviación típica muestral produce un intervalo más amplio.

Tamaño muestral (n)

A mayor tamaño, mayor precisión y un intervalo más corto, manteniendo lo demás constante.

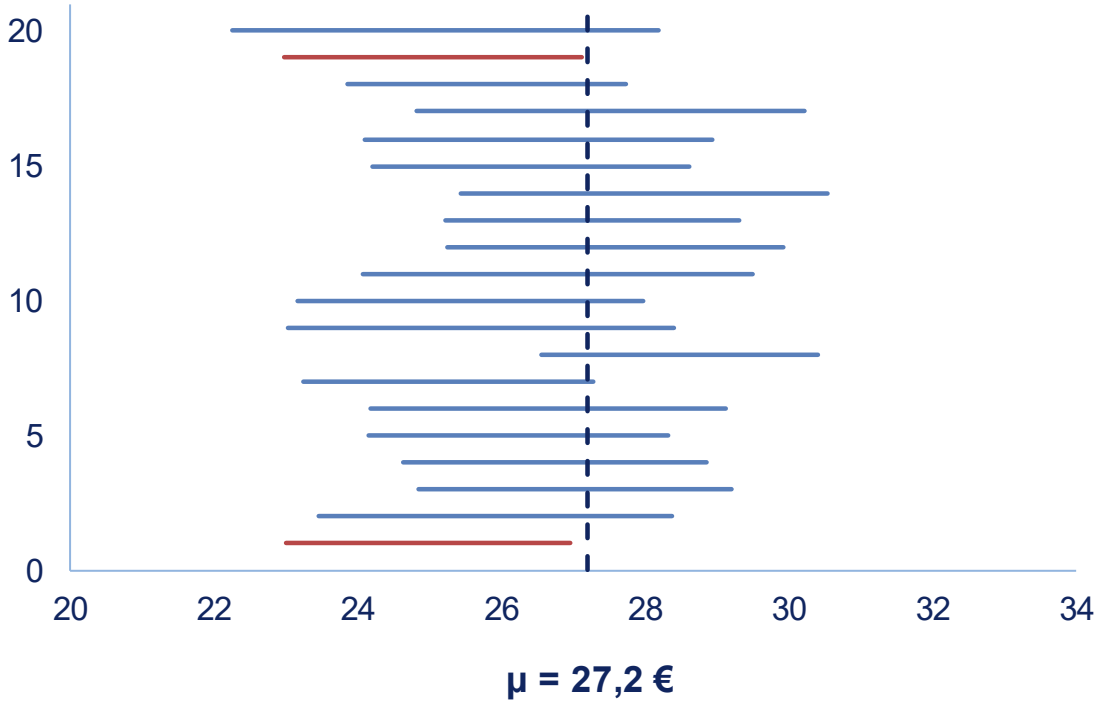
El intervalo t es exacto con datos normales e independientes. Fuera de ese modelo, la aproximación depende del tamaño muestral y de la forma de la población.

La confianza del 95 %

Un parámetro fijo, muchos intervalos

Al repetir el muestreo, el 95 % de los intervalos contendría μ a largo plazo, bajo el modelo.

La media poblacional es fija. Los intervalos cambian de una muestra a otra.



18 de 20

intervalos contienen μ en esta simulación.

No tienen que ser 19 de 20.

En la práctica, no sabemos si un intervalo concreto contiene μ.

Rojo: no contiene μ.

Intervalos para el gasto medio

Cálculo e interpretación con los mismos 25 clientes

Con los mismos datos, más confianza implica un intervalo más amplio.

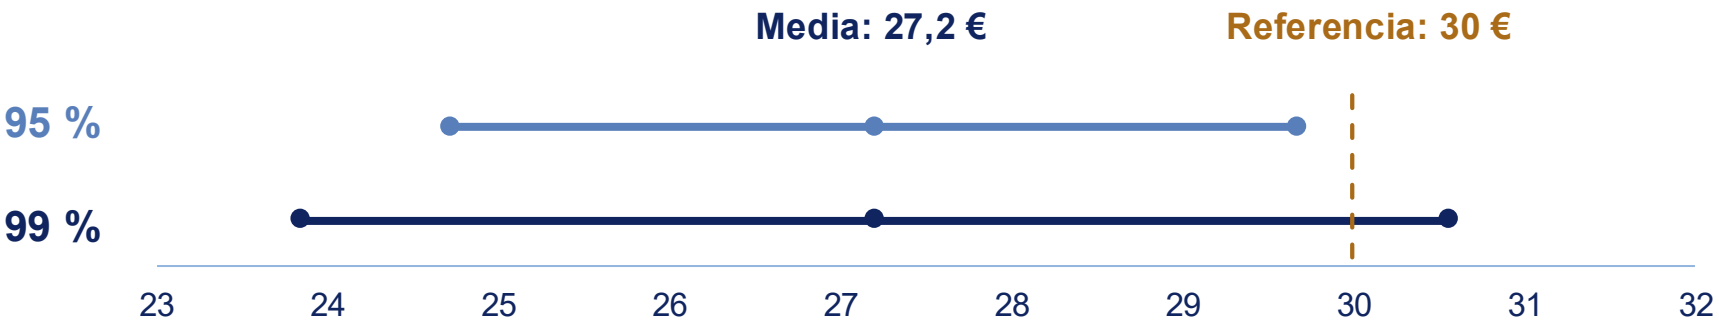
Media: 27,2 €. Intervalo = media muestral ± margen de error.

```
> res = stats.ttest_1samp(gasto_eur, 30)
> res.confidence_interval(0.95)
[1] low=24.7212, high=29.6788
> res.confidence_interval(0.99)
[1] low=23.8408, high=30.5592
```

IC de μ (€)

95 %: [24,72; 29,68]

99 %: [23,84; 30,56]



El IC del 95 % no incluye 30 €. El del 99 % sí.

Intervalo de confianza para la varianza (σ^2)

Pregunta 2: ¿La desviación típica del gasto es de 8 €?

- Queremos estimar cuánto varía el gasto entre clientes. Para ello, calculamos un intervalo de confianza para la **varianza poblacional (σ^2)** mediante la siguiente expresión**:**

$$IC(\sigma^2, 1-\alpha) = \left[\frac{s^2(n-1)}{\chi^2_{n-1,1-\frac{\alpha}{2}}}, \frac{s^2(n-1)}{\chi^2_{n-1,\frac{\alpha}{2}}}\right]$$

- La amplitud depende de los mismos factores (e influyendo en el mismo sentido) que en el caso del IC para una media.
- La premisa es que los datos provengan de una distribución Normal. Atención: **Es especialmente sensible a las desviaciones de la normalidad**, por lo que este supuesto requiere atención.
- A diferencia del IC para una media, este intervalo no es simétrico respecto a la estimación puntual de la **varianza muestral**.

Intervalo de confianza para la varianza (σ^2)

Cálculo e interpretación con los mismos 25 clientes

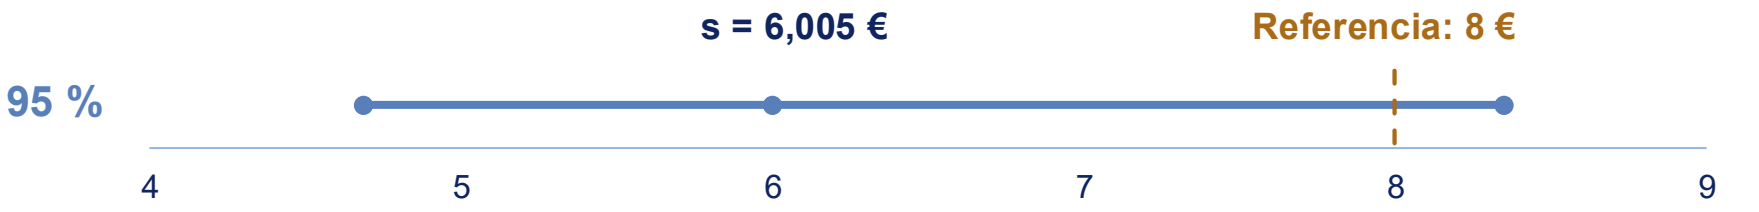
En la muestra: $s = 6{,}005$ € y $s^2 = 36{,}062$ €².

Bajo normalidad e independencia, usamos χ^2 con 24 grados de libertad.

$$\mathrm{IC}_{95\%}(\sigma^2) = \left[\frac{36{,}062 \cdot 24}{39{,}364} ; \frac{36{,}062 \cdot 24}{12{,}401}\right] \approx [21{,}99 ; 69{,}79]\ €^2$$

$$\mathrm{IC}_{95\%}(\sigma) = [\sqrt{21{,}99} ; \sqrt{69{,}79}] \approx [4{,}69 ; 8{,}35]\ €$$

```
> n = len(gasto_eur); s2 = gasto_eur.var(ddof=1)
> ic_var = (n-1)*s2 / stats.chi2.ppf([0.975, 0.025], n-1)
> ic_var
[1] [21.9865 69.7903]
> ic_sigma = ic_var**0.5; ic_sigma
[1] [4.6890 8.3541]
```



El IC del 95 % incluye 8 €.
No hay evidencia suficiente de una dispersión diferente al nivel del 5 %.

Proporción de clientes con plan fijo (π)

Intervalos de confianza para la proporción poblacional

16 clientes con plan fijo y 9 prepago. Proporción muestral: $\hat{p} = 16/25 = 0{,}64$.

Intervalo aproximado de Wald

Puede ser poco fiable
con muestras pequeñas.

$$IC(\pi, 1-\alpha) \approx \hat{p} \pm z_{1-\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Intervalo de Wald con Python

Confianza: 95 % (α = 0,05)

```
> ic = sm.stats.proportion_confint(
    16, 25, alpha=0.05,
    method="normal")
> ic
[1] (0.4518, 0.8282)
```

IC95 % ≈ [0,452; 0,828]

Intervalo binomial exacto

Usamos Clopper–Pearson en este caso.

```
> res = stats.binomtest(16, 25, p=0.5)
> res.proportion_ci(
    confidence_level=0.95)
[1] low=0.4252, high=0.8203
```

IC95 % ≈ [0,425; 0,820]

Ambos intervalos incluyen 0,50.
El 64 % observado no basta para concluir que π difiera del 50 %.

Pruebas de hipótesis

Qué ponemos a prueba y en qué dirección

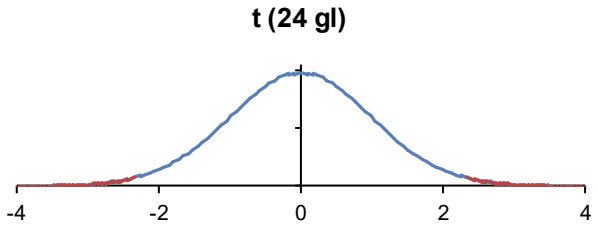
H_0 (nula): establece el valor o conjunto de valores del parámetro poblacional que ponemos a prueba.

H_1 (alternativa): expresa la diferencia que buscamos y determina la dirección del contraste.

Bilateral: elegido para el caso

¿El gasto medio difiere de 30 €?

H_0: $\mu = 30$ € H_1: $\mu \neq 30$ €

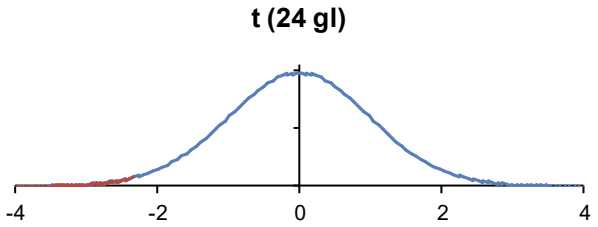


Buscamos diferencias por encima o por debajo de 30 €.

Unilateral: otra pregunta posible

¿El gasto medio es menor que 30 €?

H_0: $\mu \geq 30$ € H_1: $\mu < 30$ €



Buscamos diferencias solo en la dirección fijada: aquí, por debajo.

H_0 y H_1 se formulan sobre la población, antes de analizar los datos.

Pruebas de hipótesis

Aplicación a los mismos 25 clientes

Fijamos las referencias, la dirección y α antes de analizar los datos.

Las referencias representan valores poblacionales que queremos contrastar.

En las tres preguntas elegimos un contraste bilateral con α = 0,05.

Parámetro	Hipótesis nula H_0	Alternativa H_1
Gasto medio	$\mu = 30$ €	$\mu \neq 30$ €
Varianza del gasto	$\sigma^2 = 64$ €²	$\sigma^2 \neq 64$ €²
Proporción con plan fijo	$\pi = 0{,}50$	$\pi \neq 0{,}50$

Una varianza de 64 €² equivale a una desviación típica de 8 €.

Cómo conecta con el intervalo de confianza

En el test t bilateral al 5 %, rechazamos μ = 30 € si 30 € queda fuera del IC t del 95 %.

Pruebas de hipótesis

P-valor

El p-valor es la probabilidad de obtener un estadístico de contraste tan extremo o más que el observado, suponiendo que H_0 es cierta y se cumplen los supuestos del modelo.

Qué consideramos «más extremo» depende de la hipótesis alternativa.

Ejemplo: p = 0,03

Bajo esos supuestos, al repetir el mismo procedimiento de muestreo, aproximadamente un 3 % de las muestras darían resultados al menos tan extremos como el observado.

Fijamos α antes del análisis.

Un valor habitual es α = 0,05.

Si $p \leq \alpha$: rechazamos H_0.

Si $p > \alpha$: no rechazamos H_0.

Falta evidencia para rechazarla, pero esto no demuestra que sea cierta.

El p-valor no es la probabilidad de que H_0 sea cierta.

Contrastes para la media y la proporción

Media (μ)

Distancia a μ_0 dividida por el error estándar de la media.

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}} \sim t_{n-1} \quad bajo\ H_0$$

μ_0: valor de referencia.
s: desviación muestral. n: tamaño muestral.
t de Student exacta bajo H_0 con datos normales e independientes.
Grados de libertad: n − 1 = 24.

t = (27,2 − 30) / 1,201 ≈ −2,331

```
> stats.ttest_1samp(gasto_eur, 30)
[1] t=-2.3313, p=0.0285, df=24
```

Contrastes bilaterales.
Se requieren clientes independientes.

Proporción (π)

Aproximación normal con π_0 en el error estándar bajo H_0.

$$Z = \frac{\hat{p} - \pi_0}{\sqrt{\frac{\pi_0(1 - \pi_0)}{n}}} \approx N(0,1)$$

π_0: proporción de referencia. $\hat{p}$ = X/n.
Datos independientes, con $n\pi_0$ y $n(1-\pi_0)$ suficientemente grandes.

Test Z: aproximación normal

```
> import statsmodels.api as sm
> z, pvalor = sm.stats.proportions_ztest(
    16, 25, value=0.5, prop_var=0.5,
    alternative="two-sided"); z, pvalor
[1] (1.4000, 0.1615)
```

En el caso: binomial exacto

Bajo H_0: X ~ Binomial(25; 0,50)

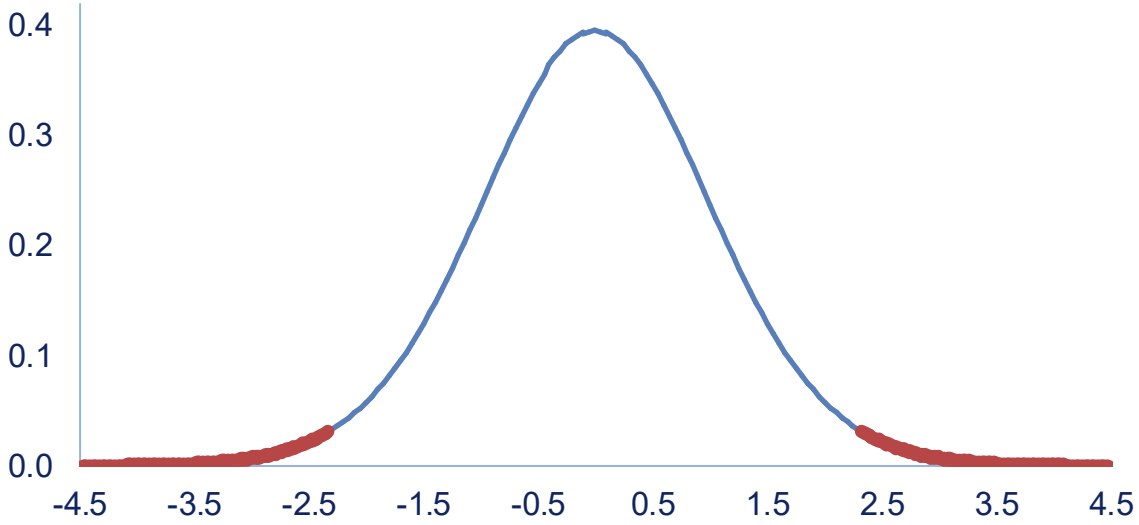
```
> stats.binomtest(16, 25, p=0.5)
[1] statistic=0.6400, pvalue=0.2295
```

La pregunta detrás del p-valor

1. ¿El gasto medio difiere de los 30 € previstos?

Contraste bilateral: H_0: μ = 30 € H_1: μ ≠ 30 €

t observado = (27,2 − 30) / 1,201 ≈ −2,331



t de Student (24 gl). Colas: t ≤ −2,331 o t ≥ 2,331.

El área de ambas colas suma el p-valor.

p ≈ 0,028

Bajo H_0, un 2,85 % de las repeticiones serían al menos tan extremas.

p < 0,05

Rechazamos H_0

La previsión de 30 € merece revisión: observamos 2,8 € menos.

Variabilidad y reparto de planes

Preguntas 2 y 3: ¿se sostienen las otras previsiones?

Pregunta y muestra	Hipótesis bilateral	Contraste y resultado
2. Dispersión del gasto ¿Difiere de 8 €? s ≈ 6,0 € con n = 25	H_0: $\sigma^2 = 64$ €² H_1: $\sigma^2 \neq 64$ €² Referencia: $\sigma = 8$ €	χ^2 de varianza (24 gl) $\chi^2 = 13{,}523$ $p = 0{,}087$ **No rechazamos H_0**
3. Clientes con plan fijo ¿Representan la mitad? 16 de 25 = 64 %	H_0: $\pi = 0{,}50$ H_1: $\pi \neq 0{,}50$	Binomial exacto $p = 0{,}230$ **No rechazamos H_0**

La muestra no permite descartar estas referencias

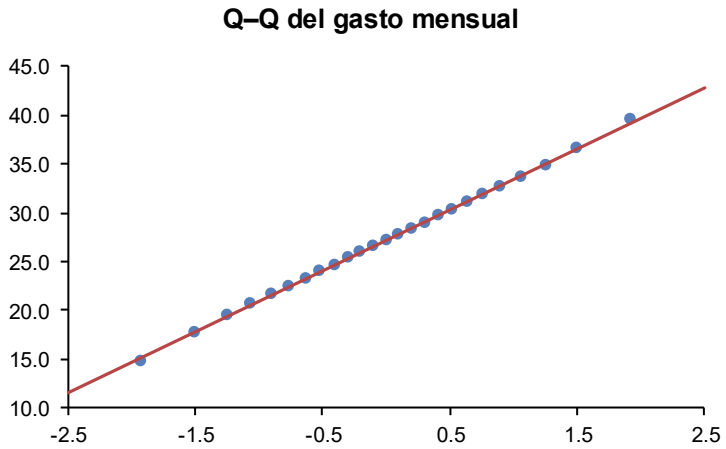
Esto tampoco demuestra que σ sea 8 € ni que π sea exactamente 50 %.

Anexo: comprobación de la normalidad

¿Cómo comprobarla?

- Revisamos la normalidad del gasto antes de usar el contraste de varianza. El Q–Q compara los mismos 25 gastos con cuantiles normales.
- Shapiro–Wilk: un p bajo cuestiona normalidad. Un p alto no la demuestra. KS necesita ajustar la referencia si estimamos μ y σ.
- Estos datos sintéticos se construyeron con cuantiles normales: la alineación del Q–Q resulta esperable.

```
> stats.shapiro(gasto_eur)
[1] W=0.998673, p≈1.000000
> stats.probplot(gasto_eur,
    dist="norm", plot=plt)
```



Revisar también atípicos, selección e independencia.

La alineación apoya el modelo; no demuestra normalidad.

Anexo: intervalo bootstrap

Desviación típica: intervalo percentil no paramétrico

El bootstrap remuestrea los datos observados para aproximar la distribución muestral de un estadístico y estimar su incertidumbre. Requiere una muestra adecuada y un remuestreo que respete su estructura.

Proceso de remuestreo

1. Generar 10.000 remuestras de 25 gastos con reposición a partir de la muestra original. Un gasto puede repetirse y otro no aparecer.
2. Calcular la desviación típica muestral en cada remuestra.
3. Tomar cuantiles de esas desviaciones:

IC95 %: 0,025 y 0,975.

IC90 %: 0,05 y 0,95.

Limitaciones y cautelas

El coste depende de las remuestras y de la complejidad del cálculo. Para 25 gastos, suele ser bajo.

No corrige una muestra sesgada.

Con muestras pequeñas, la cobertura real puede diferir del 95 % o 90 % nominal.

Más remuestras reducen el error de simulación, pero no sustituyen más datos.

Anexo: bootstrap en Python

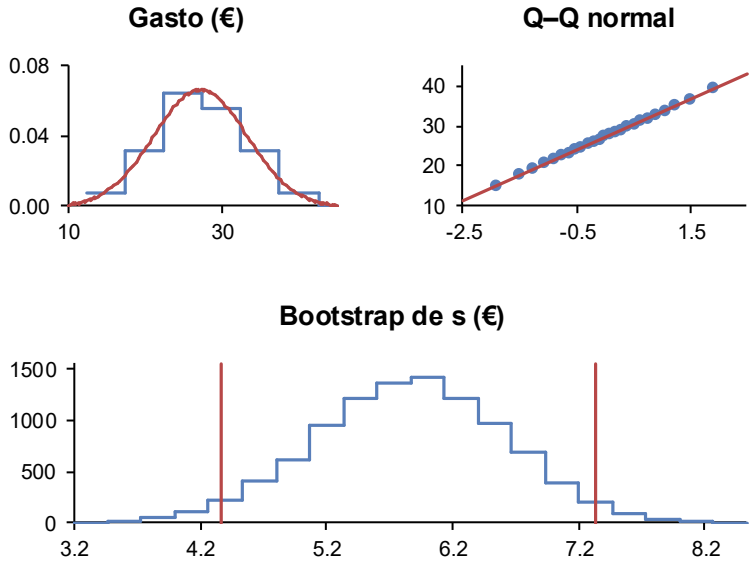
Bootstrap del gasto de los mismos 25 clientes

Remuestreamos los mismos 25 gastos observados, sin generar clientes nuevos.

Creamos 10.000 muestras de tamaño 25 con reposición y calculamos s en cada una.

IC95 % percentil para σ: [4,33; 7,30] €.

Es otro método y puede diferir del IC basado en χ^2. Con n = 25, interpretamos el resultado con cautela.




```
> rng = np.random.default_rng(12345)
> b = rng.choice(gasto_eur, (10000, 25), replace=True)
> m = b.std(axis=1, ddof=1)
> ci = np.quantile(m, [.025, .975])
> print(ci)
[1] [4.3329 7.2995]
```

MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull