# MUBD

## Màster Universitari en Enginyeria de Dades Massives (Big Data)

## Estadística

laSalle ENG
Universitat Ramon Llull

# Índice

## Inferencia estadística


**01** Introducción

**02** Población y estimadores

**03** Estimación e intervalos

**04** Hipótesis, contrastes y Pvalor

**05** Anexos: cuantiles, aproximaciones y remuestreo

Inferencia Estadística

# Introducción

01

laSalle ENG
Universitat Ramon Llull

# Inferencia estadística

## Introducción

- La inferencia estadística permite **inferir características de una población** a partir de una muestra.




- Asimismo, la inferencia estadística define y cuantifica la **incertidumbre** de esas conclusiones bajo determinados supuestos.

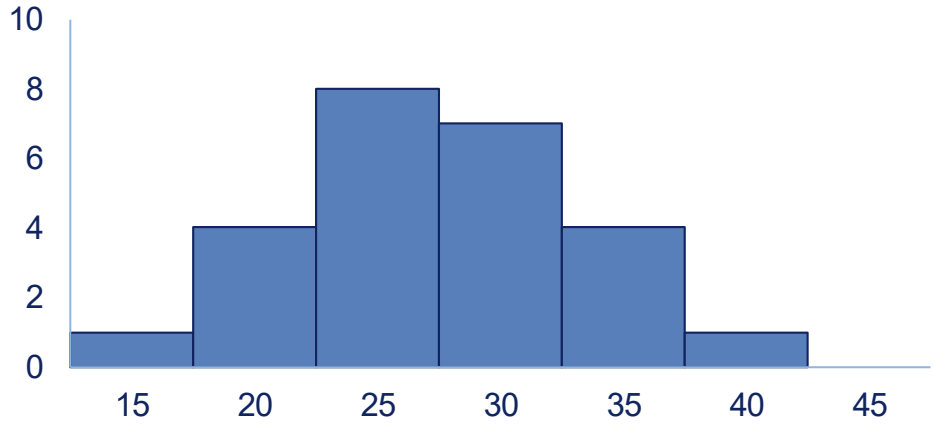
- **Muestreo:** población → muestra (selección y recogida de datos).
- **Deducción:** modelo de población → comportamiento de las muestras.
- **Inducción:** muestra → población (estimar parámetros y contrastar hipótesis).

# Una operadora nos contrata

## Caso práctico: análisis de clientes

Nos encarga analizar el gasto mensual y el tipo de plan de sus clientes.
Partimos de una muestra de 25 clientes para evaluar sus previsiones.

**Gasto mensual de 25 clientes (€)**




Gasto mensual (€), intervalos de 5 €

**27,2 €**

Gasto medio de la muestra

**Preguntas sobre todos los clientes**

¿El gasto medio mensual difiere de 30 €?

¿La desviación típica del gasto difiere de 8 €?

¿La proporción con plan fijo difiere del 50 %?

¿Son compatibles estos datos con las previsiones para todos los clientes?

Inferencia Estadística

# Población y estimadores

02

laSalle ENG
Universitat Ramon Llull

# Inferencia estadística

## Conceptos básicos

- **Población**: conjunto de elementos en estudio sobre los cuales deseamos extraer conclusiones
- **Parámetro**: indicador de la población se desea conocer.
- **Muestra**: pieza representativa de la población que sirve para obtener conocimiento de la misma
- **Estadístico**: función de los datos de la muestra
- **Estimador**: estadístico que sirve para estimar un parámetro de la población

# Parámetros y estimadores

## Ejemplos más representativos

| Parámetro (θ) (POBLACIÓN) | Estimador ($\hat{\theta}$) (MUESTRA) |
|---|---|
| $\mu$ (Esperanza, media poblacional) | $\bar{x}$ (media muestral) |
| $\sigma^2$ (varianza poblacional)<br>$\sigma$ (desviación típica poblacional) | $s^2$ (varianza muestral)<br>$s$ (desviación típica muestral) |
| $\pi$ (probabilidad) | $p$ (proporción) |



Las palabras media y desviación se utilizan indistintamente para referirse al parámetro o al estimador llevando a confusión.

# Población, muestra y estimación

## Caso práctico: población y muestra de la operadora

| Población y parámetros | Muestra y estimaciones |
|---|---|
| Clientes de la empresa telefónica | 25 clientes seleccionados al azar<br>Una observación por persona |
| Esperanza del gasto: $\mu$ | Media muestral: $\bar{x} = 27{,}2$ € |
| Varianza del gasto: $\sigma^2$ | Varianza muestral: $s^2 \approx 36{,}06$ €²<br>Desviación típica: $s \approx 6{,}0$ € |
| Probabilidad de plan fijo: $\pi$ | Proporción muestral: $\hat{p} = 16/25 = 64$ % |

Seleccionar clientes solo de una tienda o de un plan puede sesgar la muestra.

Inferencia Estadística

# Estimación e intervalos

03

laSalle ENG
Universitat Ramon Llull

# Estimación puntual

## Propiedades de los estimadores

- Inevitablemente, las estimaciones puntuales **fluctúan**: como dependen de la muestra recogida, varían entre las distintas muestras (aunque nosotros sólo observamos una de las posibles muestras).
- Las dos obsesiones de la Estadística son:
  - **Cuantificar** los errores de estimación.
  - **Minimizar** estos errores.
- El **error típico o estándar** informa de cuánto varía el estimador entre muestras del mismo tamaño y, por tanto, de la precisión al estimar el parámetro poblacional.
- No obstante, para una muestra concreta, el **error exacto es desconocido**: su magnitud puede ser superior o inferior al error típico.

# Estimación puntual

## Caso práctico: gasto mensual de 25 clientes (€)

### Media muestral

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 27{,}2\ €$$

### Desviación típica muestral

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} \approx 6{,}005\ €$$

### Error estándar de la media

$$\mathrm{SE} = \frac{s}{\sqrt{n}} \approx 1{,}201\ €$$

*Implementación*

```
from scipy import stats
n = len(gasto_eur)  # 25

# Media
gasto_eur.mean()
27.2

# Desviación típica
gasto_eur.std(ddof=1)
6.005

# Error estándar
stats.sem(gasto_eur)
1.201
```

La media estima μ y la desviación típica estima σ.

El SE estima la variación típica de la media muestral al repetir el muestreo con muestras del mismo tamaño y de la misma población.

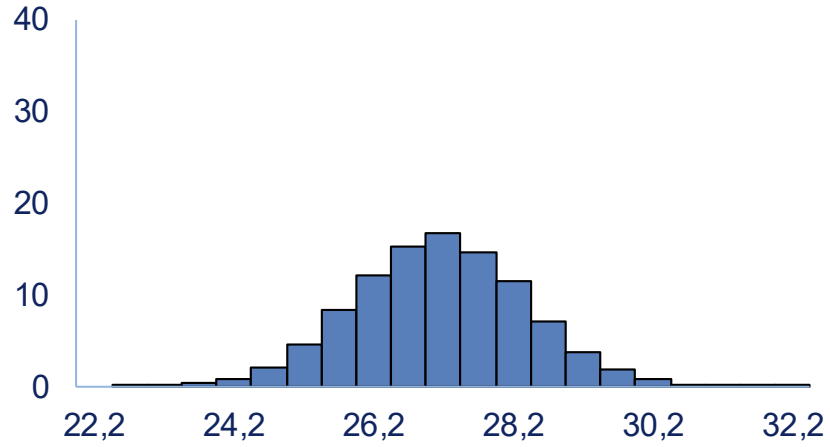
# Tamaño muestral y precisión

## Medias de muestras de 25 y 100 clientes

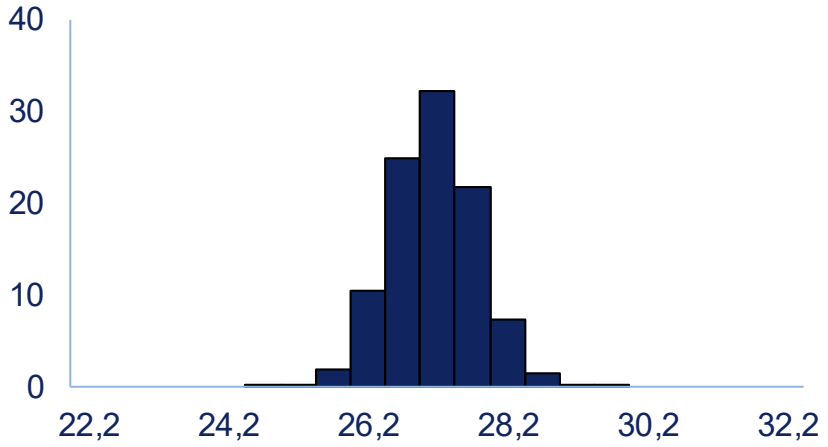
### Cuadruplicar n reduce a la mitad el SE de la media.

Si las observaciones son independientes y la variabilidad poblacional no cambia.

**25 clientes: SE = 1,2 €**




**100 clientes: SE = 0,6 €**




Medias de muestras (€), no gastos individuales.

El error exacto respecto a μ sigue siendo desconocido.

# Distribuciones

## Tipos de Distribuciones

- Para poder cuantificar la incertidumbre de nuestras estimaciones, se deben conocer la distribución de los **estimadores/estadísticos** a lo largo de infinitas muestras.
- La distribución muestral describe cómo varía un estadístico entre muestras.
  Estas distribuciones permiten construir intervalos y contrastes bajo sus supuestos.

**Normal estándar** | **t-Student** | **Ji-cuadrado** | **F de Fisher**



### Normalidad exacta

La media muestral es normal si las observaciones son independientes y proceden de una población normal.

### Aproximación normal

Con observaciones independientes de la misma población y varianza finita, se aproxima a una normal al aumentar n. La calidad depende de la población. **Concepto: Teorema Central del Límite**

Seeing Theory: explora las distribuciones y el TCL (Brown University)

# Cómo obtener los valores críticos

## Tablas online y Python: la misma consulta

Son cuantiles de una distribución: valores que dejan una probabilidad dada a la izquierda.
Para un IC bilateral central: $\alpha = 1 - \text{confianza}$ y $q = 1 - \alpha/2$.

### En las tablas online enlazadas

**Normal Z · Penn State**

Buscar q dentro de la tabla acumulada.
Leer el valor z en la fila y la columna.
Los dos críticos son −z y +z.

**t de Student · NIST**

Elegir la fila de grados de libertad v
y la columna q. Leer t y usar ±t.
Para la media de una muestra: $v = n - 1$.

**Chi-cuadrado $\chi^2$ · NIST**

Elegir la fila v y las columnas α/2 y q.
Leer ambos cuantiles, sin simetría.
Para la varianza de una muestra: $v = n - 1$.

### Cálculo con Python

*Implementación*

```
from scipy import stats
confianza, n = 0.95, 25
alpha = 1 - confianza
q = 1 - alpha/2
gl = n - 1
stats.norm.ppf(q).round(4)
1.9600
stats.t.ppf(q, df=gl).round(4)
2.0639
stats.chi2.ppf(
    [alpha/2, q], df=gl).round(4)
[12.4012, 39.3641]
```

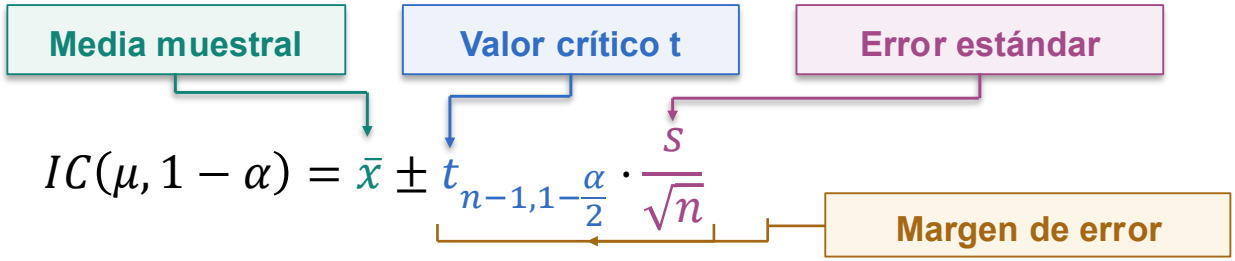
ppf(q) devuelve el cuantil de acumulada q.
confianza se expresa entre 0 y 1.

# Intervalo de confianza para la media (μ)

## Pregunta: ¿qué valores de μ son compatibles con los datos?

Fórmula: media muestral ± cuantil t × SE, con SE = s/√n.

Interpretación: rango para μ, no para el gasto de un cliente.




### ¿De qué depende la amplitud?

**Confianza (1 − α)** — Más confianza exige un cuantil t mayor: el intervalo se amplía y la estimación pierde precisión.

**Variabilidad (s)** — Más dispersión en los datos aumenta el error estándar y produce un intervalo más amplio.

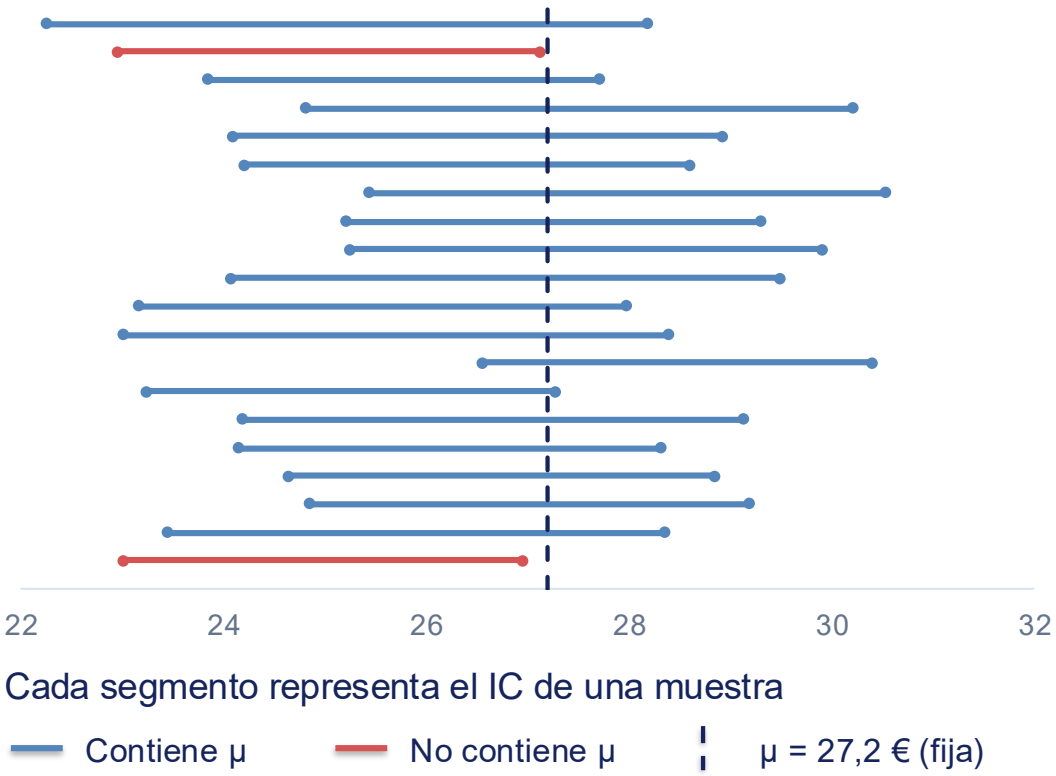
**Tamaño muestral (n)** — Una muestra mayor reduce el error estándar y estrecha el intervalo, manteniendo lo demás constante.

Supuestos: muestra aleatoria, independencia y normalidad para un IC t exacto.
Fuera de ese modelo, la cobertura es aproximada y depende de n y de la población.

# La confianza del 95 %

## Un valor fijo, intervalos que cambian

**20 muestras, 20 intervalos de confianza**




**18 de 20**

contienen μ en esta simulación.

No siempre serán 18.

**95 %**

A largo plazo, el 95 % de los intervalos contendría μ al repetir el muestreo, bajo el modelo.

En la práctica, no sabemos si un intervalo concreto contiene μ.

# Intervalos para el gasto medio

## Cálculo e interpretación con los mismos 25 clientes

**Con los mismos datos, más confianza implica un intervalo más amplio.**

Media: 27,2 €. Intervalo = media muestral ± margen de error.

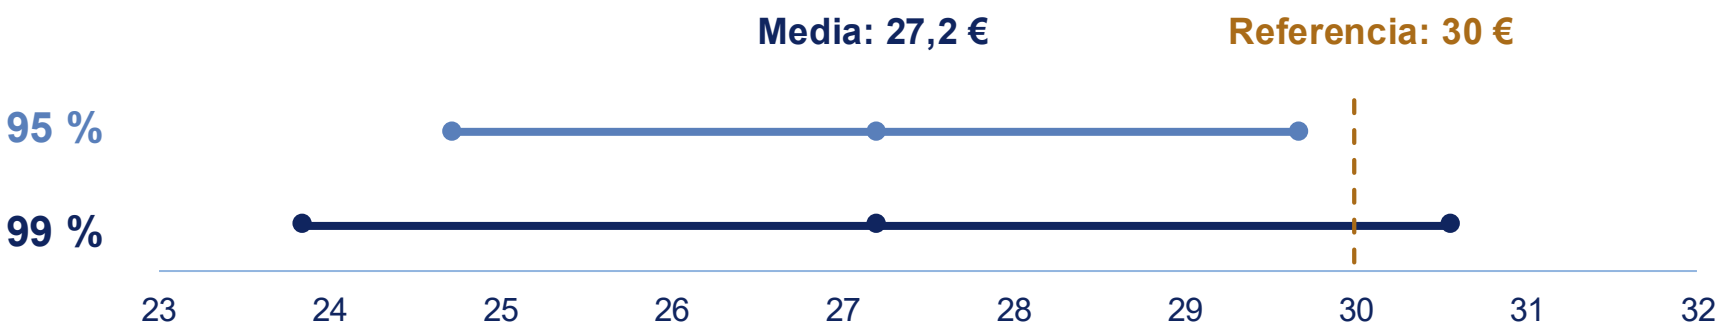
*Implementación*

```
 res = stats.ttest_1samp(gasto_eur, 30)
 res.confidence_interval(0.95)
low=24.7212, high=29.6788
 res.confidence_interval(0.99)
low=23.8408, high=30.5592
```

**IC de μ (€)**

95 %: [24,72; 29,68]

99 %: [23,84; 30,56]

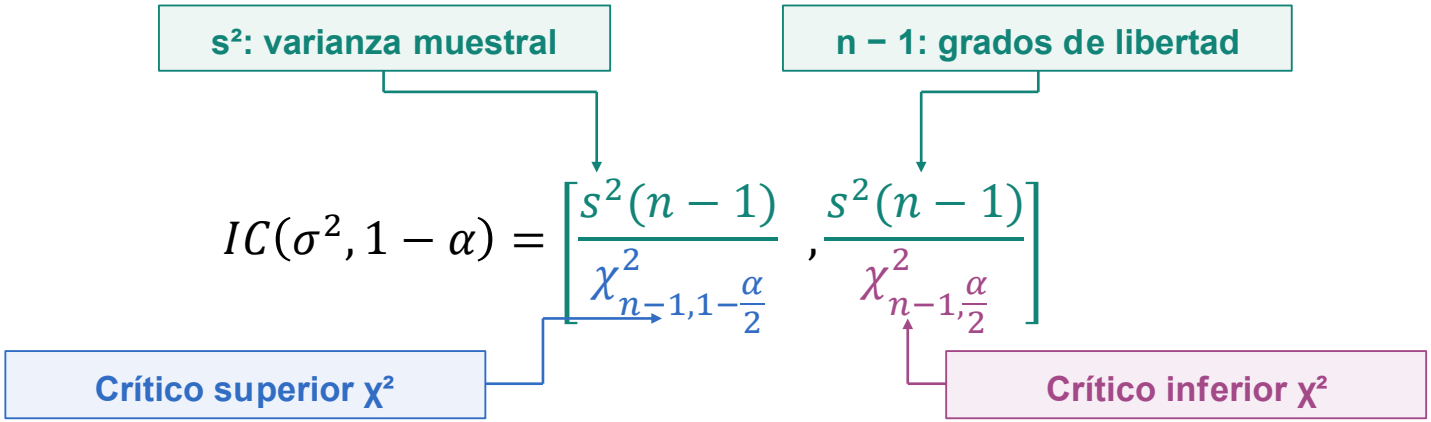



El IC del 95 % no incluye 30 €. El del 99 % sí.

# Intervalo de confianza para la varianza ($\sigma^2$)

## Pregunta: ¿qué valores de $\sigma^2$ son compatibles con los datos?

- Queremos estimar la variabilidad del gasto mediante un intervalo para la varianza poblacional $\sigma^2$.




El crítico mayor va en el denominador del límite inferior, y el menor en el del superior.

La amplitud depende de la confianza, la variabilidad y el tamaño muestral, como en el IC de la media.

Supuestos: muestreo aleatorio, independencia y normalidad. **El método $\chi^2$ es especialmente sensible a la falta de normalidad.**

# Intervalo de confianza para la varianza ($\sigma^2$)

## Cálculo e interpretación con los mismos 25 clientes

En la muestra: $s = 6{,}005$ € y $s^2 = 36{,}062$ €².

- Bajo normalidad e independencia, usamos $\chi^2$ con 24 grados de libertad.

$$IC_{95\%}(\sigma^2) = \left[\frac{36{,}062 \cdot 24}{39{,}364} ; \frac{36{,}062 \cdot 24}{12{,}401}\right] \approx [21{,}99 ; 69{,}79]\ €^2$$

$$IC_{95\%}(\sigma) = [\sqrt{21{,}99} ; \sqrt{69{,}79}] \approx [4{,}69 ; 8{,}35]\ €$$

*Implementación*

```
n = len(gasto_eur); s2 = gasto_eur.var(ddof=1)
ic_var = (n-1)*s2 / stats.chi2.ppf([0.975, 0.025], n-1)
ic_var
[21.9865 69.7903]
ic_sigma = ic_var**0.5; ic_sigma
[4.6890 8.3541]
```



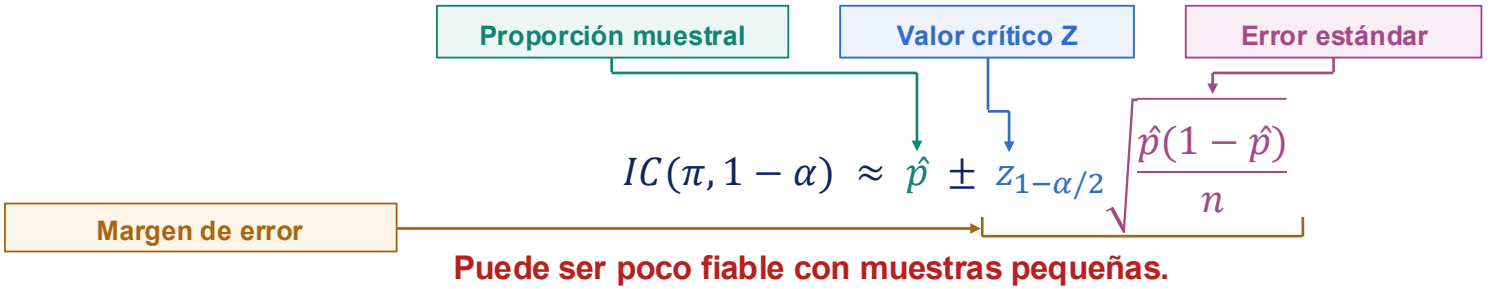

El IC del 95 % incluye 8 €.
No hay evidencia suficiente de una dispersión diferente al nivel del 5 %.

# Proporción de clientes con plan fijo (π)

## Pregunta: ¿qué proporciones son compatibles con los datos?

16 clientes con plan fijo y 9 prepago. Proporción muestral: p̂ = 16/25 = 0,64.

### Intervalo aproximado de Wald




**Puede ser poco fiable con muestras pequeñas.**

### Intervalo de Wald con Python

Confianza: 95 % (α = 0,05)

*Implementación*

```
> ic = sm.stats.proportion_confint(
    16, 25, alpha=0.05,
    method="normal")
> ic
(0.4518, 0.8282)
```

**IC95 % ≈ [0,452; 0,828]**

### Intervalo binomial exacto

Usamos Clopper–Pearson en este caso.

*Implementación*

```
> res = stats.binomtest(16, 25, p=0.5)
> res.proportion_ci(
    confidence_level=0.95)
low=0.4252, high=0.8203
```

**IC95 % ≈ [0,425; 0,820]**

Ambos intervalos incluyen 0,50.
El 64 % observado no basta para concluir que π difiera del 50 %.

Inferencia Estadística

# Hipótesis, Contrastes y Pvalor

04

laSalle ENG
Universitat Ramon Llull

# Pruebas de hipótesis

## Razonamiento y relación con el IC

### Partimos de una hipótesis nula ($H_0$)

$H_0$ fija una referencia sobre la población. Contrastamos si los datos aportan evidencia suficiente para rechazarla frente a $H_1$.

### La conexión con el intervalo de confianza

En un contraste bilateral de nivel α, usamos el IC correspondiente de confianza $1 - \alpha$ y comprobamos dónde queda el valor de $H_0$.

### Valor fuera del IC

Rechazamos $H_0$ al nivel α.
Los datos son incompatibles con ese valor según el criterio del contraste.

### Valor dentro del IC

No rechazamos $H_0$.
Falta evidencia para descartarla, pero esto no demuestra que sea cierta.

Ejemplo: contraste t bilateral al 5 % e IC t del 95 %, con los mismos datos y supuestos.

# Pruebas de hipótesis

## Qué ponemos a prueba y en qué dirección

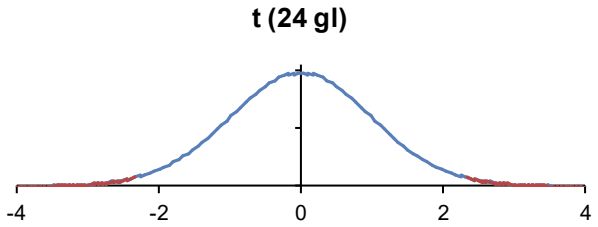
**$H_0$ (nula):** establece el valor o conjunto de valores del parámetro poblacional que ponemos a prueba.

**$H_1$ (alternativa):** expresa la diferencia que buscamos y determina la dirección del contraste.

### Bilateral: elegido para el caso

¿El gasto medio difiere de 30 €?

$H_0$: $\mu = 30$ €  $H_1$: $\mu \neq 30$ €

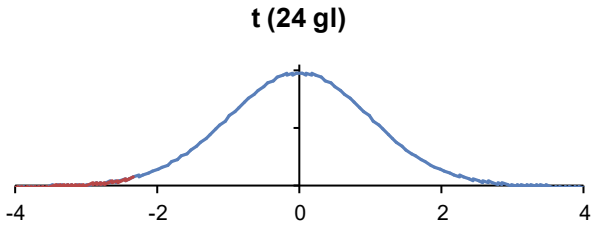



Buscamos diferencias por encima o por debajo de 30 €.

### Unilateral: otra pregunta posible

¿El gasto medio es menor que 30 €?

$H_0$: $\mu \geq 30$ €  $H_1$: $\mu < 30$ €




Buscamos diferencias solo en la dirección fijada: aquí, por debajo.

$H_0$ y $H_1$ se formulan sobre la población, antes de analizar los datos.

# Pruebas de hipótesis

## P-valor

El p-valor es la probabilidad de obtener un estadístico de contraste tan extremo o más que el observado, suponiendo que $H_0$ es cierta y se cumplen los supuestos del modelo.

Qué consideramos «más extremo» depende de la hipótesis alternativa.

**Ejemplo: p = 0,03**

Bajo esos supuestos, al repetir el mismo procedimiento de muestreo, aproximadamente un 3 % de las muestras darían resultados al menos tan extremos como el observado.

**Fijamos α antes del análisis.**

**Un valor habitual es α = 0,05.**

Si $p \leq \alpha$: rechazamos $H_0$.

Si $p > \alpha$: no rechazamos $H_0$.

Falta evidencia para rechazarla, pero esto no demuestra que sea cierta.

El p-valor no es la probabilidad de que $H_0$ sea cierta.

# Contraste para la media

## Pregunta: ¿el gasto medio μ difiere de 30 €?

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

Diferencia con $H_0$

Error estándar

### Cálculo del t observado

$27{,}2 - 30 = -2{,}8$ €

SE = $6{,}005/\sqrt{25} \approx 1{,}201$ €

**t = −2,8/1,201 ≈ −2,331**

Bajo $H_0$: t con 24 grados de libertad

Supuestos: muestra aleatoria, independencia y normalidad. $\mu_0 = 30$ €, n = 25.

### Del estadístico al p-valor bilateral

$p = P(T_{24} \le -2{,}3313) + P(T_{24} \ge 2{,}3313)$

$= 2P(T_{24} \ge 2{,}3313) \approx 0{,}0285$

**p < 0,05: rechazamos $H_0$.**

*Implementación*

```
from scipy import stats
cola = stats.t.sf(2.3313, 24)
cola  # solo la cola derecha
≈ 0.01425
2 * cola  # ambas colas
≈ 0.0285
```

$P(|T_{24}| \ge 2{,}3313)$ ya incluye ambas colas: no se multiplica otra vez por 2.
El p-valor supone $H_0$ cierta. No es la probabilidad de que $H_0$ sea cierta.

# Contraste para la proporción

## Pregunta: ¿la proporción π difiere del 50 %?

$$Z = \frac{\hat{p} - \pi_0}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}}$$

Diferencia con $H_0$

Error estándar

Bajo $H_0$: normal N(0,1) aproximada

### Cálculo del Z observado

$\hat{p}$ = 16/25 = 0,64; $\pi_0$ = 0,50

Diferencia: 0,64 − 0,50 = 0,14

SE = $\sqrt{(0{,}50 \times 0{,}50/25)}$ = 0,10

**Z = 0,14/0,10 = 1,40**

Supuestos: ensayos independientes, π común y $n\pi_0$, $n(1-\pi_0)$ grandes (aquí 12,5).

### Del estadístico al p-valor

$p = 2 \cdot P(Z \geq 1{,}40) \approx 0{,}1615$

Sumamos las dos colas.

**p > 0,05: no rechazamos $H_0$.**

*Implementación*

```
from scipy import stats
z = (0.64 - 0.50)/0.10
2 * stats.norm.sf(abs(z))
0.1615
```

sf(z) da la cola derecha. Multiplicamos por 2 porque el contraste es bilateral.

# Contraste binomial exacto

## Pregunta: ¿la proporción π difiere del 50 %?

### 1. Lo observado

16 clientes con plan fijo de 25.

Proporción muestral: 16/25 = 0,64.

### 2. Supuestos bajo $H_0$

Ensayos independientes, $\pi_0 = 0{,}50$ común.

$K \sim \text{Binomial}(25, 0{,}50)$, n fijo.

### 3. Fórmula bilateral para este caso simétrico

$p = P(K \leq 9) + P(K \geq 16) \approx 0{,}2295$

La suma simétrica vale aquí porque $\pi_0 = 0{,}50$.

*Implementación*

```
from scipy import stats
stats.binomtest(16, 25, p=0.5)
statistic=0.6400, pvalue=0.2295
stats.binom.cdf(9, 25, 0.5) + stats.binom.sf(15, 25, 0.5)
0.2295
```

**$p = 0{,}2295 > 0{,}05$: no rechazamos $H_0$.**

No hay evidencia suficiente de que la proporción difiera del 50 %.

Inferencia Estadística

# Conclusiones del caso 05

laSalle ENG
Universitat Ramon Llull

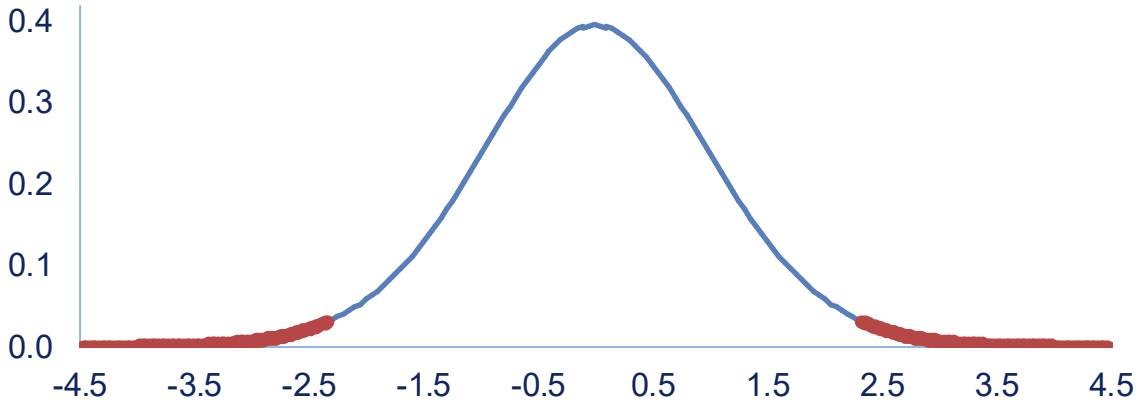
# La pregunta detrás del p-valor

## 1. ¿El gasto medio difiere de los 30 € previstos?

**Contraste bilateral: $H_0$: μ = 30 €  $H_1$: μ ≠ 30 €**

$$t_{\text{observado}} = \frac{27{,}2 - 30}{1{,}201} \approx -2{,}331$$

Diferencia con $H_0$ | Error estándar | t observado




**p ≈ 0,028**

Bajo $H_0$, un 2,85 % de las repeticiones serían al menos tan extremas.

**p < 0,05**

**Rechazamos $H_0$**

Supuestos: normalidad e independencia.
Las dos colas suman el p-valor.

Diferencia: −2,8 €. Rechazo al 5 % por prueba, sin ajuste múltiple.

# Variabilidad y reparto de planes

## Caso práctico: respuestas sobre dispersión y plan fijo

| Pregunta y muestra | Hipótesis bilateral | Contraste y resultado |
|---|---|---|
| **2. Dispersión del gasto**<br>¿Difiere de 8 €?<br>$s \approx 6{,}0$ € con $n = 25$ | $H_0$: $\sigma^2 = 64$ €²<br>$H_1$: $\sigma^2 \neq 64$ €²<br>Referencia: $\sigma = 8$ € | $Q = (n-1)s^2/\sigma_0^2 = 13{,}523$<br>Bajo $H_0$: $Q \sim \chi^2_{24}$<br>**p = 0,0866 > α**<br>No rechazamos $H_0$ |
| **3. Clientes con plan fijo**<br>¿Representan la mitad?<br>16 de 25 = 64 % | $H_0$: $\pi = 0{,}50$<br>$H_1$: $\pi \neq 0{,}50$ | $K \sim$ Binomial(25, 0,50)<br>Test binomial exacto<br>**p = 0,2295 > α**<br>No rechazamos $H_0$ |

Supuestos: clientes independientes y muestra representativa. $\chi^2$ exige normalidad. No rechazar $H_0$ no demuestra que $\sigma = 8$ € o que $\pi = 0{,}50$. $\alpha = 0{,}05$ por prueba.

Inferencia Estadística

# Anexos

06

laSalle ENG
Universitat Ramon Llull

# Anexo: comprobación de la normalidad

## Pregunta: ¿es compatible la muestra con normalidad?

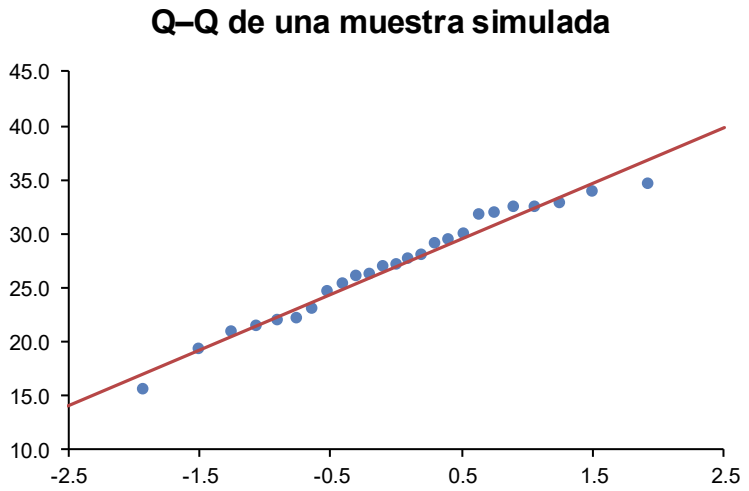
- Q–Q: compara datos ordenados con cuantiles normales.
- Shapiro–Wilk: $H_0$ de normalidad, observaciones independientes.
- $W = (\Sigma\, a_i x_{(i)})^2 / \Sigma(x_i - \bar{x})^2$. Un p alto no demuestra $H_0$.

*Implementación*

```
rng = np.random.default_rng(42)
ejemplo = rng.normal(27.2, 6, 25)
stats.shapiro(ejemplo)
W=0.9668, p=0.5650
stats.probplot(ejemplo,
    dist="norm", plot=plt)
```

Simulación independiente del caso.

p = 0,565 > 0,05: no rechazamos normalidad.




La cercanía a la recta es compatible con normalidad, pero no la demuestra.

# Anexo: intervalo bootstrap

## Pregunta: ¿qué valores de σ sugiere el remuestreo?

Fórmula percentil: IC de σ = [q*(α/2), q*(1−α/2)], cuantiles de las s* remuestreadas.
Supuestos: muestra representativa y observaciones independientes.
Este intervalo es aproximado.

### Proceso de remuestreo

1. Generar 10.000 remuestras de 25 gastos con reposición a partir de la muestra original. Un gasto puede repetirse y otro no aparecer.

2. Calcular la desviación típica muestral en cada remuestra.

3. Tomar cuantiles de esas desviaciones:

IC95 %: 0,025 y 0,975.

IC90 %: 0,05 y 0,95.

### Limitaciones y cautelas

El coste depende de las remuestras y de la complejidad del cálculo. Para 25 gastos, suele ser bajo.

No corrige una muestra sesgada.

Con muestras pequeñas, la cobertura real puede diferir del 95 % o 90 % nominal.



Más remuestras reducen el error de simulación, pero no sustituyen más datos.

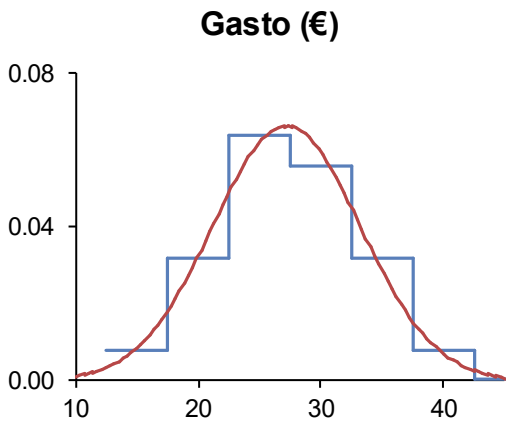
# Anexo: bootstrap de los gastos

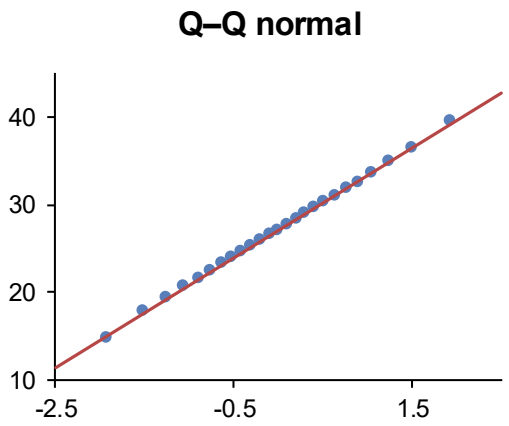
## Caso práctico: bootstrap de los 25 gastos

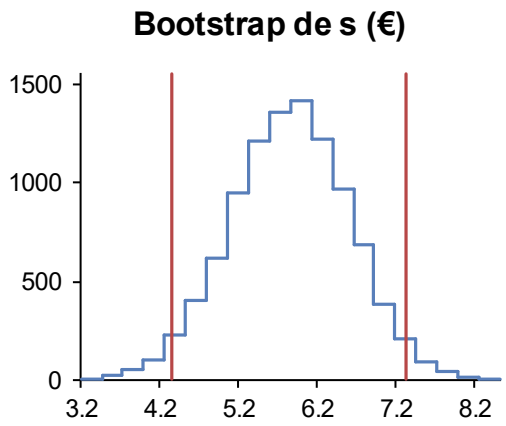
Pregunta: ¿qué valores de σ sugiere el bootstrap?
IC percentil = [q*(0,025), q*(0,975)].
Supuestos: muestra representativa e independencia.
IC del 95 %: [4,33; 7,30] €. Cobertura aproximada con n = 25. Puede diferir del IC $\chi^2$.

*Implementación*

```
rng = np.random.default_rng(12345)
b = rng.choice(gasto_eur, (10000, 25), replace=True)
m = b.std(axis=1, ddof=1)
ci = np.quantile(m, [.025, .975])
print(ci)
[4.3329 7.2995]
```



# MUBD

## Màster Universitari en Enginyeria de Dades Massives (Big Data)

## Estadística

laSalle ENG
Universitat Ramon Llull