MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull

Índice

Inferencia estadística

01 Introducción

02 Población, muestra y estimadores

03 Variabilidad muestral e intervalos de confianza

04 Contrastes sobre media y proporción

05 P-valor

06 Anexos: normalidad y bootstrap

Inferencia Estadística

Introducción

01

laSalle ENG
Universitat Ramon Llull

Inferencia estadística

Introducción

- La inferencia estadística permite **inferir características de una población** a partir de una muestra.



- Asimismo, la inferencia estadística define y cuantifica la **incertidumbre** de esas conclusiones bajo determinados supuestos.

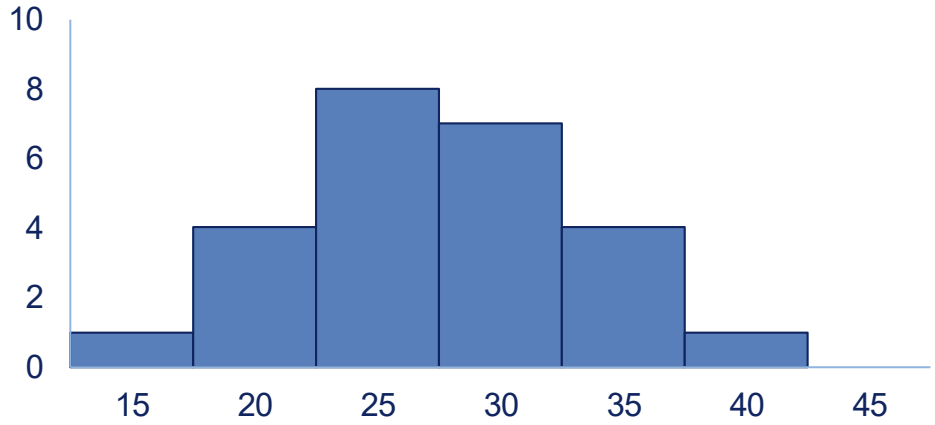
- **Muestreo:** población → muestra (selección y recogida de datos).
- **Deducción:** modelo de población → comportamiento de las muestras.
- **Inducción:** muestra → población (estimar parámetros y contrastar hipótesis).

Una operadora nos contrata

Caso práctico: análisis de clientes

Nos encarga analizar el gasto mensual y el tipo de plan de sus clientes.
Partimos de una muestra de 25 clientes para evaluar sus previsiones.

Gasto mensual de 25 clientes (€)



Gasto mensual (€), intervalos de 5 €

27,2 €

Gasto medio de la muestra

Preguntas sobre todos los clientes

¿El gasto medio mensual difiere de 30 €?

¿La desviación típica del gasto difiere de 8 €?

¿La proporción con plan fijo difiere del 50 %?

¿Son compatibles estos datos con las previsiones para todos los clientes?

Inferencia Estadística

Población y estimadores

02

laSalle ENG
Universitat Ramon Llull

Inferencia estadística

Conceptos básicos

- **Población**: conjunto de elementos en estudio sobre los cuales deseamos extraer conclusiones
- **Parámetro**: indicador de la población se desea conocer.
- **Muestra**: pieza representativa de la población que sirve para obtener conocimiento de la misma
- **Estadístico**: función de los datos de la muestra
- **Estimador**: estadístico que sirve para estimar un parámetro de la población

Parámetros y estimadores

Ejemplos más representativos

Parámetro (θ) (POBLACIÓN)	Estimador ($\hat{\theta}$) (MUESTRA)
μ (Esperanza, media poblacional)	$\bar{x}$ (media muestral)
σ^2 (varianza poblacional) σ (desviación típica poblacional)	s^2 (varianza muestral) s (desviación típica muestral)
π (probabilidad)	p (proporción)

Las palabras media y desviación se utilizan indistintamente para referirse al parámetro o al estimador llevando a confusión.

Población, muestra y estimación

Caso práctico: población y muestra de la operadora

Población y parámetros	Muestra y estimaciones
Clientes de la empresa telefónica	25 clientes seleccionados al azar Una observación por persona
Esperanza del gasto: μ	Media muestral: $\bar{x} = 27{,}2$ €
Varianza del gasto: σ^2	Varianza muestral: $s^2 \approx 36{,}06$ €² Desviación típica: $s \approx 6{,}0$ €
Probabilidad de plan fijo: π	Proporción muestral: $\hat{p} = 16/25 = 64$ %

Seleccionar clientes solo de una tienda o de un plan puede sesgar la muestra.

Inferencia Estadística

Estimación e intervalos

03

laSalle ENG
Universitat Ramon Llull

Estimación puntual

Propiedades de los estimadores

- Inevitablemente, las estimaciones puntuales **fluctúan**: como dependen de la muestra recogida, varían entre las distintas muestras (aunque nosotros sólo observamos una de las posibles muestras).
- Las dos obsesiones de la Estadística son:
  - **Cuantificar** los errores de estimación.
  - **Minimizar** estos errores.
- El **error típico o estándar** informa de cuánto varía el estimador entre muestras del mismo tamaño y, por tanto, de la precisión al estimar el parámetro poblacional.
- No obstante, para una muestra concreta, el **error exacto es desconocido**: su magnitud puede ser superior o inferior al error típico.

Estimación puntual

Caso práctico: gasto mensual de 25 clientes (€)

Media muestral

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 27{,}2\ €$$

Desviación típica muestral

$$S_x = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} \approx 6{,}005\ €$$

Error estándar de la media

$$\mathrm{SE} = \frac{S_x}{\sqrt{n}} \approx 1{,}201\ €$$

Implementación

```
> from scipy import stats
> n = len(gasto_eur)  # 25

> # Media
> gasto_eur.mean()
[1] 27.2

> # Desviación típica
> gasto_eur.std(ddof=1)
[1] 6.005

> # Error estándar
> stats.sem(gasto_eur)
[1] 1.201
```

La media estima μ y la desviación típica estima σ.

El SE estima la variación típica de la media muestral al repetir el muestreo con muestras del mismo tamaño y de la misma población.

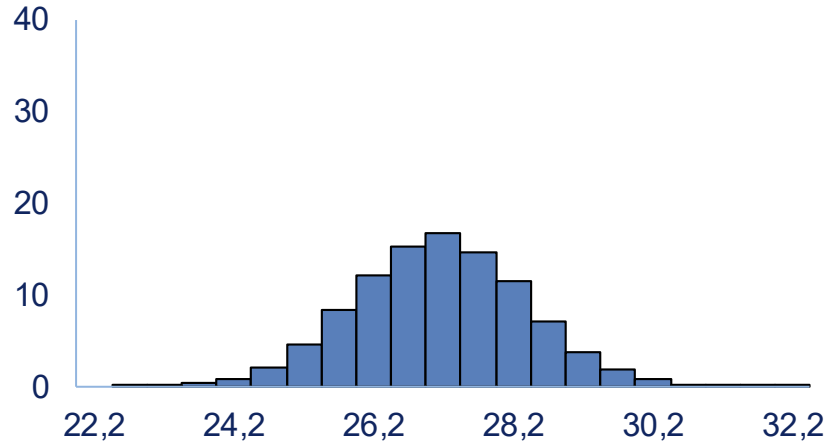
Tamaño muestral y precisión

Medias de muestras de 25 y 100 clientes

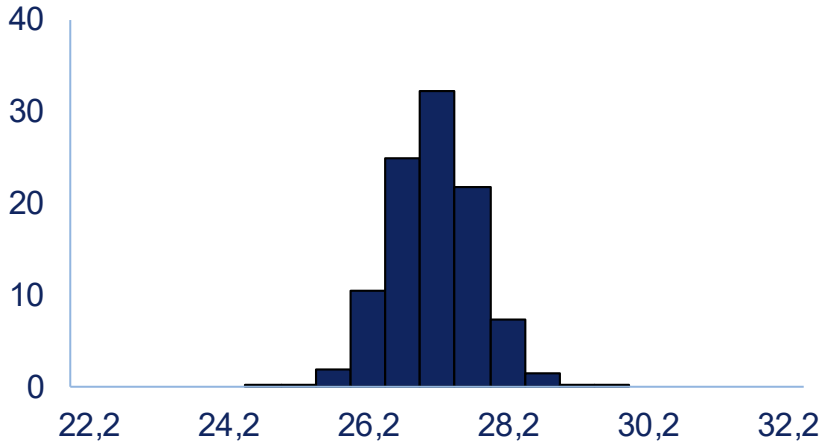
Cuadruplicar n reduce a la mitad el SE de la media.

Si las observaciones son independientes y la variabilidad poblacional no cambia.

25 clientes: SE = 1,2 €



100 clientes: SE = 0,6 €



Medias de muestras (€), no gastos individuales.

El error exacto respecto a μ sigue siendo desconocido.

Distribuciones

Tipos de Distribuciones

- Para poder cuantificar la incertidumbre de nuestras estimaciones, se deben conocer la distribución de los **estimadores/estadísticos** a lo largo de infinitas muestras.
- En el anexo de distribuciones se encuentran las distribuciones más usuales en inferencia estadística.

Normal estándar **t-Student** **Ji-cuadrado** **F de Fisher**



KDE ilustrativas con datos sintéticos. Escalas propias para mostrar la forma de cada distribución.

Normalidad exacta

La media muestral es normal si las observaciones son independientes y proceden de una población normal.

Aproximación normal

Con observaciones independientes de la misma población y varianza finita, se aproxima a una normal al aumentar n. La calidad depende de la población. **Concepto: Teorema Central del Límite**

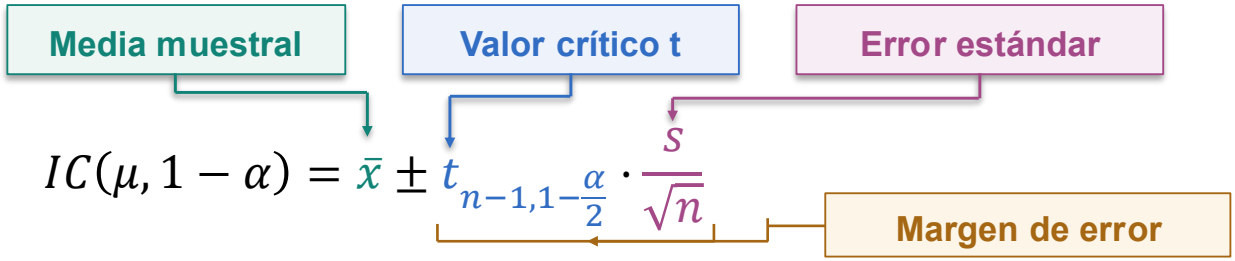
Seeing Theory: explora las distribuciones y el TCL (Brown University)

Intervalo de confianza para la media (μ)

Caso práctico (1): ¿el gasto medio difiere de 30 €?

El IC combina la media muestral con un margen de error.

La confianza 1 − α determina el cuantil t con n − 1 grados de libertad.



¿De qué depende la amplitud?

Confianza (1 − α) — Más confianza exige un cuantil t mayor: el intervalo se amplía y la estimación pierde precisión.

Variabilidad (s) — Más dispersión en los datos aumenta el error estándar y produce un intervalo más amplio.

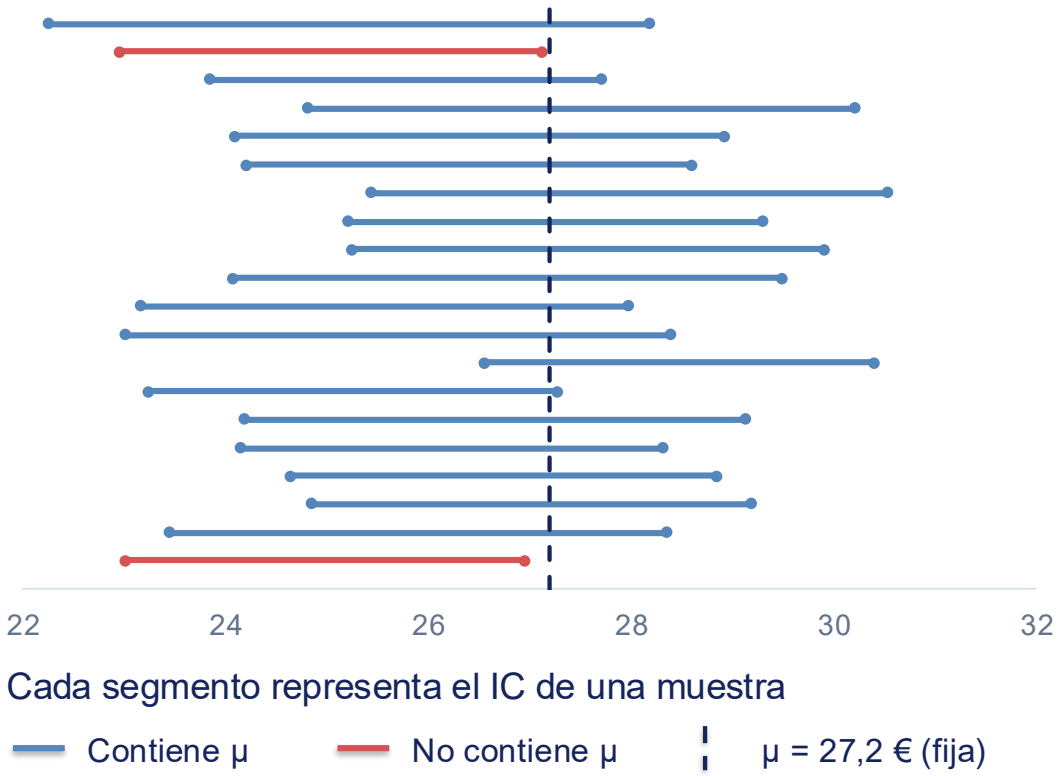
Tamaño muestral (n) — Una muestra mayor reduce el error estándar y estrecha el intervalo, manteniendo lo demás constante.

El intervalo t es exacto con datos normales e independientes. Fuera de ese modelo, la aproximación depende del tamaño muestral y de la forma de la población.

La confianza del 95 %

Un valor fijo, intervalos que cambian

20 muestras, 20 intervalos de confianza



18 de 20

contienen μ en esta simulación.

No siempre serán 18.

95 %

A largo plazo, el 95 % de los intervalos contendría μ al repetir el muestreo, bajo el modelo.

En la práctica, no sabemos si un intervalo concreto contiene μ.

Cómo obtener los valores críticos

Tablas online y Python: la misma consulta

Son cuantiles de una distribución: valores que dejan una probabilidad dada a la izquierda.
Para un IC bilateral central: $\alpha = 1 - \text{confianza}$ y $q = 1 - \alpha/2$.

En las tablas online enlazadas

Normal Z · Penn State

Buscar q dentro de la tabla acumulada.
Leer el valor z en la fila y la columna.
Los dos críticos son −z y +z.

t de Student · NIST

Elegir la fila de grados de libertad v
y la columna q. Leer t y usar ±t.
Para la media de una muestra: $v = n - 1$.

Chi-cuadrado χ^2 · NIST

Elegir la fila v y las columnas α/2 y q.
Leer ambos cuantiles, sin simetría.
Para la varianza de una muestra: $v = n - 1$.

Cálculo con Python

Implementación

```
> from scipy import stats
> confianza, n = 0.95, 25
> alpha = 1 - confianza
> q = 1 - alpha/2
> gl = n - 1
> stats.norm.ppf(q).round(4)
[1] 1.9600
> stats.t.ppf(q, df=gl).round(4)
[1] 2.0639
> stats.chi2.ppf(
    [alpha/2, q], df=gl).round(4)
[1] [12.4012, 39.3641]
```

ppf(q) devuelve el cuantil de acumulada q.
confianza se expresa entre 0 y 1.

Intervalos para el gasto medio

Cálculo e interpretación con los mismos 25 clientes

Con los mismos datos, más confianza implica un intervalo más amplio.

Media: 27,2 €. Intervalo = media muestral ± margen de error.

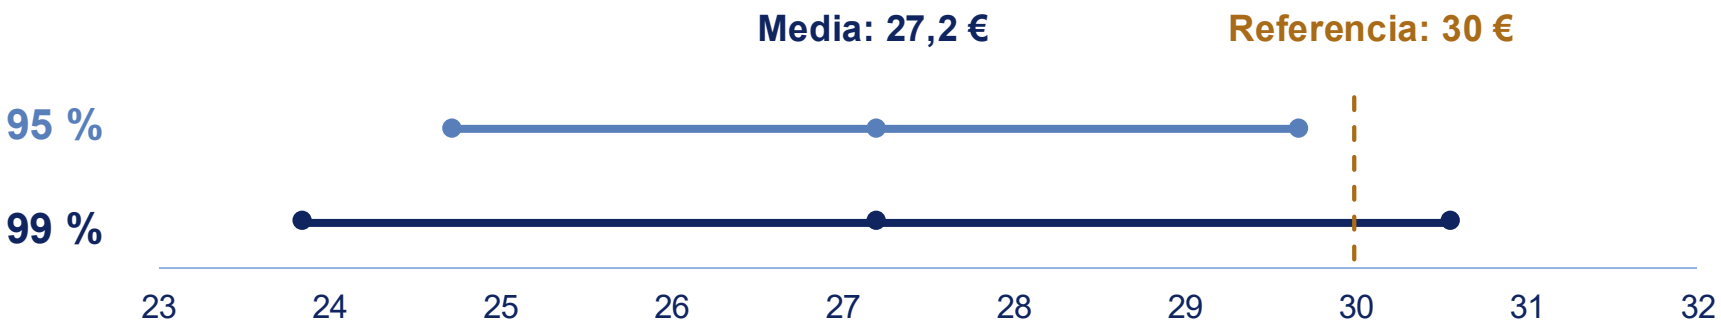
Implementación

```
> res = stats.ttest_1samp(gasto_eur, 30)
> res.confidence_interval(0.95)
[1] low=24.7212, high=29.6788
> res.confidence_interval(0.99)
[1] low=23.8408, high=30.5592
```

IC de μ (€)

95 %: [24,72; 29,68]

99 %: [23,84; 30,56]

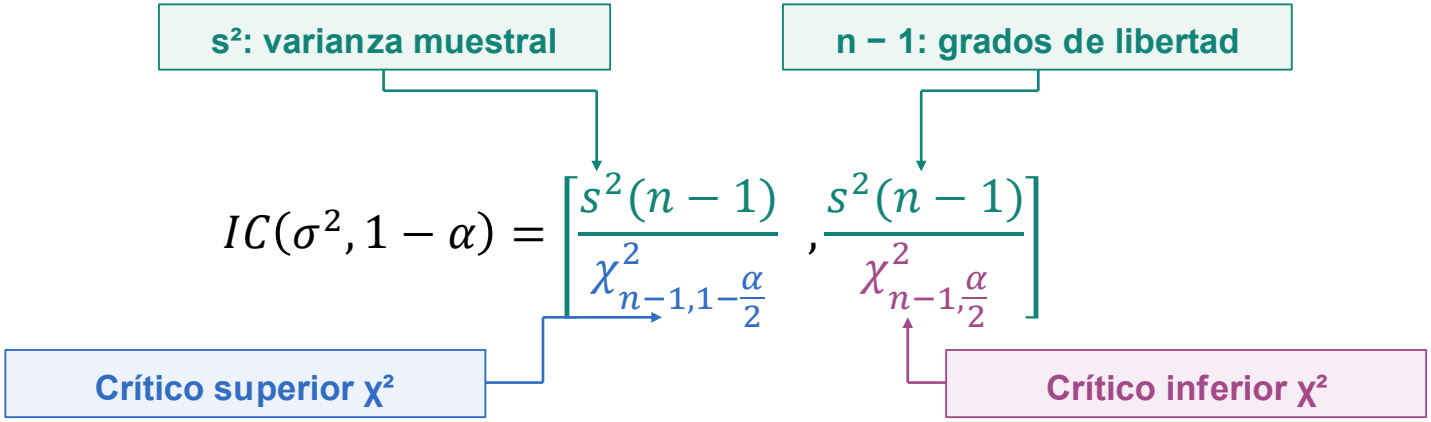


El IC del 95 % no incluye 30 €. El del 99 % sí.

Intervalo de confianza para la varianza (σ^2)

Caso práctico (2): ¿la desviación típica difiere de 8 €?

- Queremos estimar la variabilidad del gasto mediante un intervalo para la varianza poblacional σ^2.



El crítico mayor va en el denominador del límite inferior, y el menor en el del superior.

La amplitud depende de la confianza, la variabilidad y el tamaño muestral, como en el IC de la media.

Requiere normalidad y es especialmente sensible a su incumplimiento. El intervalo es asimétrico respecto a s^2: no tiene un único margen ±.

Intervalo de confianza para la varianza (σ^2)

Cálculo e interpretación con los mismos 25 clientes

En la muestra: $s = 6{,}005$ € y $s^2 = 36{,}062$ €².

- Bajo normalidad e independencia, usamos χ^2 con 24 grados de libertad.

$$\mathrm{IC}_{95\%}(\sigma^2) = \left[\frac{36{,}062 \cdot 24}{39{,}364} ; \frac{36{,}062 \cdot 24}{12{,}401}\right] \approx [21{,}99 ; 69{,}79]\ €^2$$

$$\mathrm{IC}_{95\%}(\sigma) = [\sqrt{21{,}99} ; \sqrt{69{,}79}] \approx [4{,}69 ; 8{,}35]\ €$$

Implementación

```
> n = len(gasto_eur); s2 = gasto_eur.var(ddof=1)
> ic_var = (n-1)*s2 / stats.chi2.ppf([0.975, 0.025], n-1)
> ic_var
[1] [21.9865 69.7903]
> ic_sigma = ic_var**0.5; ic_sigma
[1] [4.6890 8.3541]
```



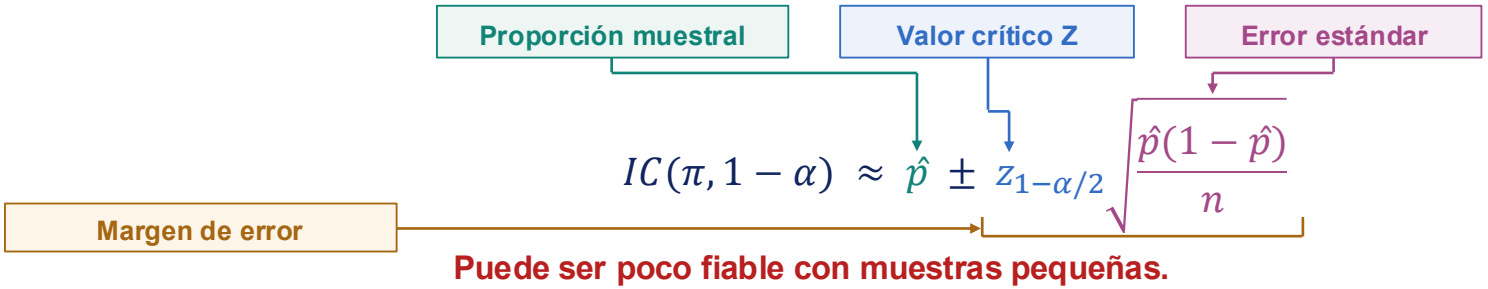
El IC del 95 % incluye 8 €.
No hay evidencia suficiente de una dispersión diferente al nivel del 5 %.

Proporción de clientes con plan fijo (π)

Caso práctico (3): proporción de clientes con plan fijo

16 clientes con plan fijo y 9 prepago. Proporción muestral: p̂ = 16/25 = 0,64.

Intervalo aproximado de Wald



Intervalo de Wald con Python

Confianza: 95 % (α = 0,05)

Implementación

```
> ic = sm.stats.proportion_confint(
    16, 25, alpha=0.05,
    method="normal")
> ic
[1] (0.4518, 0.8282)
```

IC95 % ≈ [0,452; 0,828]

Intervalo binomial exacto

Usamos Clopper–Pearson en este caso.

Implementación

```
> res = stats.binomtest(16, 25, p=0.5)
> res.proportion_ci(
    confidence_level=0.95)
[1] low=0.4252, high=0.8203
```

IC95 % ≈ [0,425; 0,820]

Ambos intervalos incluyen 0,50.
El 64 % observado no basta para concluir que π difiera del 50 %.

Inferencia Estadística

Contrastes de hipótesis

04

laSalle ENG
Universitat Ramon Llull

Pruebas de hipótesis

Razonamiento y relación con el IC

Partimos de una hipótesis nula (H_0)

H_0 fija una referencia sobre la población. Contrastamos si los datos aportan evidencia suficiente para rechazarla frente a H_1.

La conexión con el intervalo de confianza

En un contraste bilateral de nivel α, usamos el IC correspondiente de confianza $1 - \alpha$ y comprobamos dónde queda el valor de H_0.

Valor fuera del IC

Rechazamos H_0 al nivel α.
Los datos son incompatibles con ese valor según el criterio del contraste.

Valor dentro del IC

No rechazamos H_0.
Falta evidencia para descartarla, pero esto no demuestra que sea cierta.

Ejemplo: contraste t bilateral al 5 % e IC t del 95 %, con los mismos datos y supuestos.

Pruebas de hipótesis

Qué ponemos a prueba y en qué dirección

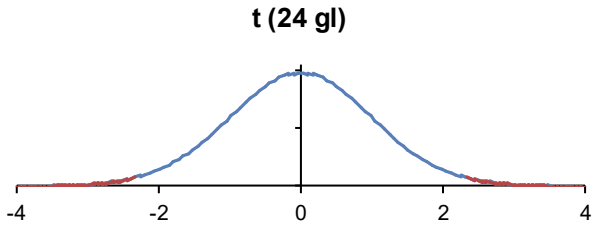
H_0 (nula): establece el valor o conjunto de valores del parámetro poblacional que ponemos a prueba.

H_1 (alternativa): expresa la diferencia que buscamos y determina la dirección del contraste.

Bilateral: elegido para el caso

¿El gasto medio difiere de 30 €?

H_0: $\mu = 30$ € H_1: $\mu \neq 30$ €

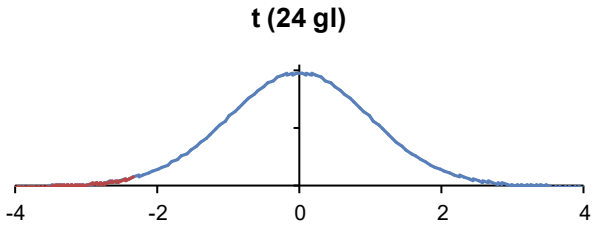


Buscamos diferencias por encima o por debajo de 30 €.

Unilateral: otra pregunta posible

¿El gasto medio es menor que 30 €?

H_0: $\mu \geq 30$ € H_1: $\mu < 30$ €



Buscamos diferencias solo en la dirección fijada: aquí, por debajo.

H_0 y H_1 se formulan sobre la población, antes de analizar los datos.

Pruebas de hipótesis

Caso práctico: las tres hipótesis

Las referencias representan valores poblacionales que queremos contrastar.

En las dos preguntas elegimos un contraste bilateral con $\alpha = 0{,}05$.

Parámetro	Hipótesis nula H_0	Alternativa H_1
Gasto medio	$\mu = 30$ €	$\mu \neq 30$ €
Proporción con plan fijo	$\pi = 0{,}50$	$\pi \neq 0{,}50$

Fijamos las referencias, la dirección y α antes de analizar los datos.

Cómo conecta con el intervalo de confianza
En el test t bilateral al 5 %, rechazamos $\mu = 30$ € si 30 € queda fuera del IC t del 95 %.

Pruebas de hipótesis

P-valor

El p-valor es la probabilidad de obtener un estadístico de contraste tan extremo o más que el observado, suponiendo que H_0 es cierta y se cumplen los supuestos del modelo.

Qué consideramos «más extremo» depende de la hipótesis alternativa.

Ejemplo: p = 0,03

Bajo esos supuestos, al repetir el mismo procedimiento de muestreo, aproximadamente un 3 % de las muestras darían resultados al menos tan extremos como el observado.

Fijamos α antes del análisis.

Un valor habitual es α = 0,05.

Si $p \leq \alpha$: rechazamos H_0.

Si $p > \alpha$: no rechazamos H_0.

Falta evidencia para rechazarla, pero esto no demuestra que sea cierta.

El p-valor no es la probabilidad de que H_0 sea cierta.

Contraste para la media

Media (μ)

$$t = \frac{\bar{x} - \mu_0}{\frac{s}{\sqrt{n}}}$$

Diferencia con H_0

Error estándar

Cálculo del t observado

$27{,}2 - 30 = -2{,}8$ €

$EE = 6{,}005/\sqrt{25} \approx 1{,}201$ €

$t = -2{,}8/1{,}201 \approx -2{,}331$

Bajo H_0: t con 24 grados de libertad

$\mu_0 = 30$ €, $s \approx 6{,}005$ €, $n = 25$. Datos normales e independientes.

Del estadístico al p-valor bilateral

$p = P(T_{24} \leq -2{,}3313) + P(T_{24} \geq 2{,}3313) = 2P(T_{24} \geq 2{,}3313) \approx 0{,}0285$

$p < 0{,}05$: rechazamos H_0.

Implementación

```
> from scipy import stats
> cola = stats.t.sf(2.3313, 24)
> cola  # solo la cola derecha
[1] ≈ 0.01425
> 2 * cola  # ambas colas
[1] ≈ 0.0285
```

$P(|T_{24}| \geq 2{,}3313)$ ya incluye ambas colas: no se multiplica otra vez por 2.
El p-valor supone H_0 cierta. No es la probabilidad de que H_0 sea cierta.

Contraste para la proporción

Proporción: aproximación normal

$$Z = \frac{\hat{p} - \pi_0}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}}$$

Diferencia con H_0

Error estándar

Bajo H_0: normal N(0,1) aproximada

Cálculo del Z observado

$\hat{p}$ = 16/25 = 0,64; π_0 = 0,50

Diferencia: 0,64 − 0,50 = 0,14

EE = $\sqrt{(0{,}50 \times 0{,}50/25)}$ = 0,10

Z = 0,14/0,10 = 1,40

Datos independientes, con $n\pi_0$ y $n(1-\pi_0)$ suficientemente grandes.

Del estadístico al p-valor

$p = 2 \cdot P(Z \geq 1{,}40) \approx 0{,}1615$

Sumamos las dos colas.

p > 0,05: no rechazamos H_0.

Implementación

```
> from scipy import stats
> z = (0.64 - 0.50)/0.10
> 2 * stats.norm.sf(abs(z))
[1] 0.1615
```

sf(z) da la cola derecha. Multiplicamos por 2 porque el contraste es bilateral.

Contraste binomial exacto

Proporción: del recuento observado al p-valor

1. Lo observado

16 clientes con plan fijo de 25.

Proporción muestral: 16/25 = 0,64.

2. Lo que supone H_0

$\pi_0 = 0{,}50$, clientes independientes.

$X \sim \text{Binomial}(25; 0{,}50)$.

3. Sumamos resultados tan extremos o más

$p = P(X \leq 9) + P(X \geq 16) \approx 0{,}2295$

La cola $X \geq 16$ se calcula con sf(15).

Implementación

```
> from scipy import stats
> stats.binomtest(16, 25, p=0.5)
[1] statistic=0.6400, pvalue=0.2295
> stats.binom.cdf(9, 25, 0.5) + stats.binom.sf(15, 25, 0.5)
[1] 0.2295
```

$p = 0{,}2295 > 0{,}05$: no rechazamos H_0.

No hay evidencia suficiente de que la proporción difiera del 50 %.

Inferencia Estadística

Conclusiones del caso

05

laSalle ENG
Universitat Ramon Llull

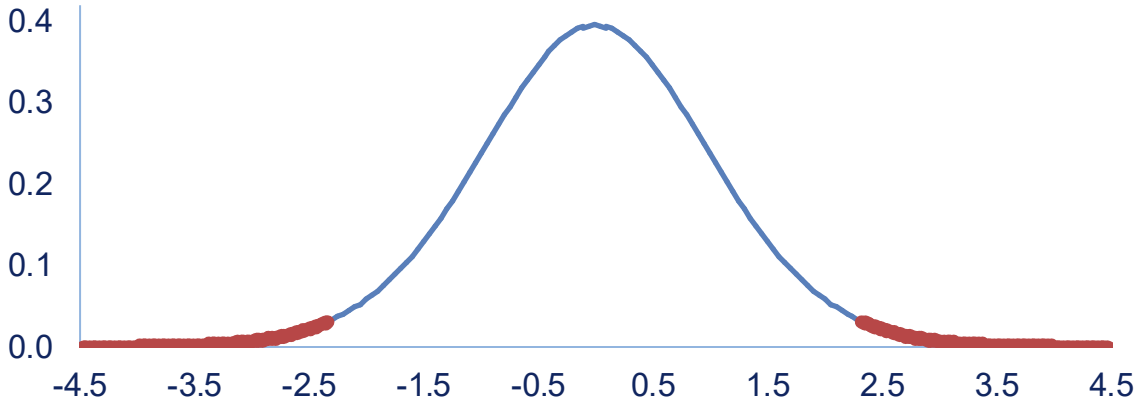
La pregunta detrás del p-valor

1. ¿El gasto medio difiere de los 30 € previstos?

Contraste bilateral: H_0: μ = 30 € H_1: μ ≠ 30 €

$$t_{\text{observado}} = \frac{27{,}2 - 30}{1{,}201} \approx -2{,}331$$

Diferencia con H_0 | Error estándar | t observado



Colas t ≤ −2,331 o t ≥ 2,331:
sus áreas suman el p-valor.

p ≈ 0,028

Bajo H_0, un 2,85 % de las repeticiones serían al menos tan extremas.

p < 0,05

Rechazamos H_0

Para la operadora: revisar la previsión de 30 €. Observamos 2,8 € menos.

Variabilidad y reparto de planes

Caso práctico: respuestas sobre dispersión y plan fijo

Pregunta y muestra	Hipótesis bilateral	Contraste y resultado
2. Dispersión del gasto ¿Difiere de 8 €? $s \approx 6{,}0$ € con $n = 25$	H_0: $\sigma^2 = 64$ €² H_1: $\sigma^2 \neq 64$ €² Referencia: $\sigma = 8$ €	χ^2 de varianza (24 gl) $\chi^2 = 13{,}523$ $p = 0{,}087$ **No rechazamos H_0**
3. Clientes con plan fijo ¿Representan la mitad? 16 de 25 = 64 %	H_0: $\pi = 0{,}50$ H_1: $\pi \neq 0{,}50$	Binomial exacto $p = 0{,}230$ **No rechazamos H_0**

La muestra no permite descartar estas referencias
Esto tampoco demuestra que σ sea 8 € ni que π sea exactamente 50 %.

Inferencia Estadística

Anexos

06

laSalle ENG
Universitat Ramon Llull

Anexo: comprobación de la normalidad

Ejemplo simulado: aproximación a la normalidad

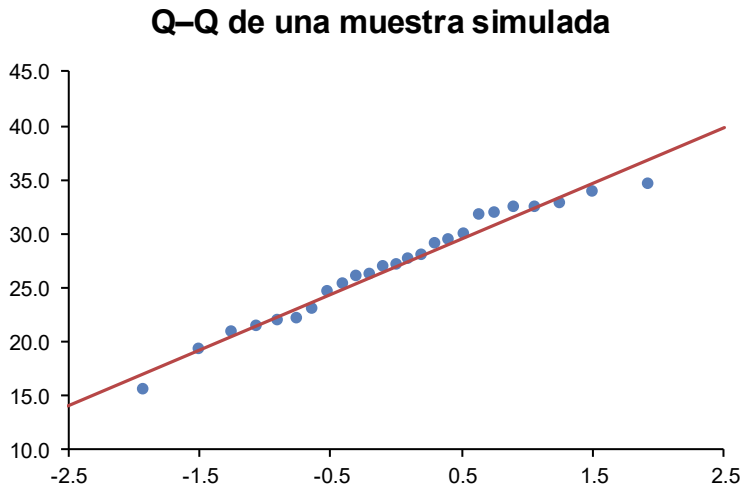
- El Q–Q compara los valores ordenados de una muestra con cuantiles normales.
- Una muestra puede aproximarse a la recta sin coincidir exactamente con ella.
- Shapiro–Wilk: un p bajo cuestiona normalidad. Un p alto no la demuestra.

Implementación

```
> rng = np.random.default_rng(42)
> ejemplo = rng.normal(27.2, 6, 25)
> stats.shapiro(ejemplo)
[1] W=0.9668, p=0.5650
> stats.probplot(ejemplo,
    dist="norm", plot=plt)
```

Simulación ilustrativa, no datos de clientes.

Revisar también atípicos e independencia.



La cercanía a la recta es compatible con normalidad, pero no la demuestra.

Anexo: intervalo bootstrap

Desviación típica: intervalo percentil no paramétrico

El bootstrap remuestrea los datos observados para aproximar la distribución muestral de un estadístico y estimar su incertidumbre. Requiere una muestra adecuada y un remuestreo que respete su estructura.

Proceso de remuestreo

1. Generar 10.000 remuestras de 25 gastos con reposición a partir de la muestra original. Un gasto puede repetirse y otro no aparecer.
2. Calcular la desviación típica muestral en cada remuestra.
3. Tomar cuantiles de esas desviaciones:

IC95 %: 0,025 y 0,975.

IC90 %: 0,05 y 0,95.

Limitaciones y cautelas

El coste depende de las remuestras y de la complejidad del cálculo. Para 25 gastos, suele ser bajo.

No corrige una muestra sesgada.

Con muestras pequeñas, la cobertura real puede diferir del 95 % o 90 % nominal.

Más remuestras reducen el error de simulación, pero no sustituyen más datos.

Anexo: bootstrap de los gastos

Caso práctico: bootstrap de los 25 gastos

Remuestreamos los mismos 25 gastos observados, sin generar clientes nuevos.

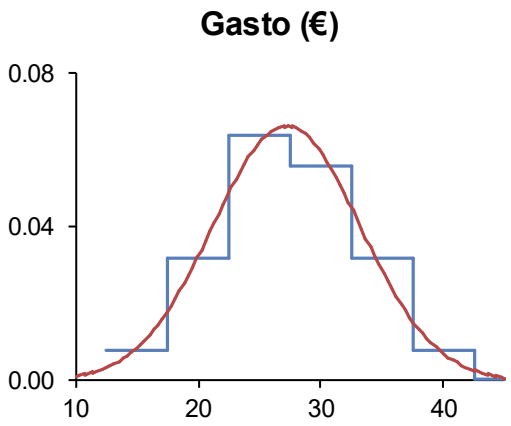
Creamos 10.000 muestras de tamaño 25 con reposición y calculamos s en cada una.

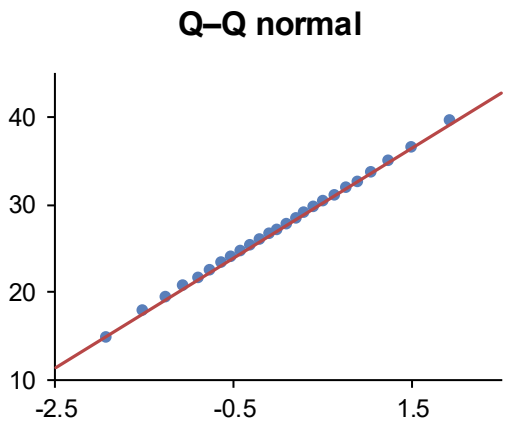
IC95 % percentil para σ: [4,33; 7,30] €.

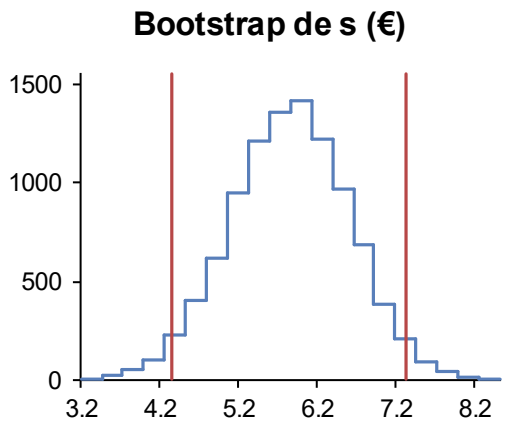
Es otro método y puede diferir del IC basado en χ^2. Con n = 25, interpretamos el resultado con cautela.

Implementación

```
> rng = np.random.default_rng(12345)
> b = rng.choice(gasto_eur, (10000, 25), replace=True)
> m = b.std(axis=1, ddof=1)
> ci = np.quantile(m, [.025, .975])
> print(ci)
[1] [4.3329 7.2995]
```







MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull