MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull

Índice

Inferencia estadística: comparación de poblaciones

01 Diseño de experimentos

02 Comparación de medias (μ_1 y μ_2)

- Muestras independientes
- Muestras apareadas

03 Comparación de varianzas (σ_1^2 y σ_2^2)

04 Comparación de proporciones (π_1 y π_2)

05 Tipos de errores en los contrastes de hipótesis

Inferencia Estadística

Introducción

01

laSalle ENG
Universitat Ramon Llull

Diseño de experimentos

Tipos de diseño según la variable y la recogida de datos

- **Según el tipo de variable**
  - **Numérica.** Comparación de medias o varianzas.
    Ejemplo: gasto mensual (€) de clientes con plan fijo y prepago.
  - **Dicotómica.** Comparación de proporciones.
    Ejemplo: proporción de clientes con plan fijo en dos regiones.
- **Según la recogida de datos**
  - **Muestras independientes.** Clientes distintos en cada grupo.
    Ejemplo: plan fijo frente a prepago en el mismo mes.
  - **Muestras apareadas.** Dos medidas del mismo individuo/elemento.
    Ejemplo: gasto del mes 1 y del mes 2, unidos por el identificador de cliente.



Inferencia Estadística

Comparación de medias

02

laSalle ENG
Universitat Ramon Llull

Caso práctico: comparación de dos grupos

¿Difiere el gasto medio entre plan fijo y prepago?

A: plan fijo	B: prepago
16 clientes	**9 clientes**
Gasto medio: 26,41 €	Gasto medio: 28,60 €

Misma muestra: 16 con plan fijo y 9 prepago

Outputs: tamaño, media (€) y desviación típica muestral (€).

Implementación

```
> A, B = gasto_eur[fijo], gasto_eur[~fijo]
> print(len(A), round(A.mean(), 2), round(A.std(ddof=1), 2))
[1] 16 26.41 4.88
> print(len(B), round(B.mean(), 2), round(B.std(ddof=1), 2))
[1] 9 28.6 7.75
> round(A.mean() - B.mean(), 2)  # Diferencia observada (€)
[1] -2.19
```

Medias independientes: Student

Pregunta 1a. ¿Difiere el gasto entre planes?

- Prueba formal

$$\begin{cases} H_0: \mu_1 = \mu_2 \\ H_1: \mu_1 \neq \mu_2 \end{cases} \Leftrightarrow \begin{cases} H_0: \mu_1 - \mu_2 = 0 \\ H_1: \mu_1 - \mu_2 \neq 0 \end{cases}$$

- **Premisas**: Variables a comparar normales y varianzas iguales en ambas muestras.

- Bajo H_0 se cumple

Diferencia de medias → $\hat{t} = \dfrac{(\bar{x}_1 - \bar{x}_2)}{s_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}} \sim t_{n_1+n_2-2}$ ← **t de Student** $n_1 + n_2 - 2$ **gl**

Error estándar → $s_p\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}$

- Con varianzas poblacionales iguales, estimamos una varianza conjunta:

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

Información útil: Tabla t (NIST): fila gl = $n_1 + n_2 - 2$. Al 5 % bilateral, columna 0,975.
Comparamos $|t|$ con el valor crítico. Si lo supera, rechazamos H_0.

Medias independientes: Welch

La misma pregunta, sin suponer varianzas iguales

- Prueba formal

$$\begin{cases} H_0: \mu_1 = \mu_2 \\ H_1: \mu_1 \neq \mu_2 \end{cases} \Leftrightarrow \begin{cases} H_0: \mu_1 - \mu_2 = 0 \\ H_1: \mu_1 - \mu_2 \neq 0 \end{cases}$$

- **Premisas**: Variables a comparar normales.
- Bajo H_0, el estadístico sigue aproximadamente una distribución t de Student:

Diferencia de medias

$$\hat{t} = \frac{\overline{X}_1 - \overline{X}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \sim t_\nu$$

Error estándar

t de Student
ν gl aproximados

- Grados de libertad aproximados mediante Welch–Satterthwaite:

$$\nu = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}$$

Información útil: Tabla t (NIST): gl = ν y columna 0,975 para un contraste bilateral al 5 %.
Si ν no es entero, la fila inferior da una comparación conservadora.

Gasto medio: plan fijo frente a prepago

Caso práctico: Student y Welch

$H_0: \mu_A = \mu_B$ • Diferencia observada $A - B = -2{,}1875$ €

Student

$$s_p{}^2 = \frac{15 \cdot 23{,}7905 + 8 \cdot 60{,}1325}{16 + 9 - 2} \approx 36{,}4312$$

$$SE = \sqrt{36{,}4312\left(\frac{1}{16} + \frac{1}{9}\right)} \approx 2{,}5149$$

$$t = \frac{-2{,}1875}{2{,}5149} \approx -0{,}8698$$

$$gl = 16 + 9 - 2 = 23$$

Welch

$$sA^2 = 23{,}7905 \quad sB^2 = 60{,}1325$$

$$SE = \sqrt{\frac{23{,}7905}{16} + \frac{60{,}1325}{9}} \approx 2{,}8580$$

$$t = \frac{-2{,}1875}{2{,}8580} \approx -0{,}7654$$

$$\nu = \frac{(23{,}7905/16 + 60{,}1325/9)^2}{(23{,}7905/16)^2/15 + (60{,}1325/9)^2/8} \approx 11{,}65$$

Del estadístico t al p-valor

Caso práctico: contraste bilateral sin Python

$$p = 2\,P(T_\nu \geq |t|) = 2\,[1 - F_\nu(|t|)]$$

F_ν es la probabilidad acumulada de la distribución t.
Multiplicamos por 2 para contar ambas colas.

Student · 23 grados de libertad

$$p = 2\,[1 - F_{23}(0{,}8698)]$$

$$p \approx 0{,}3934$$

Welch · ≈11,65 grados de libertad

$$p = 2\,[1 - F_{11{,}65}(0{,}7654)]$$

$$p \approx 0{,}4593$$

Información útil: Tabla t de Student (NIST)

NIST: fila de grados de libertad y columna 0,975 para $\alpha = 0{,}05$ bilateral.
Para Welch, usamos la fila 11 de forma conservadora ($\nu \approx 11{,}65$).

Comprobación en Python

Caso práctico: resultados de Student y Welch

$H_0: \mu_A = \mu_B$ • Diferencia observada $A - B = -2{,}1875$ €

Estadístico t, p bilateral e intervalo de confianza del 95 %

Implementación

```
> student = stats.ttest_ind(A, B, equal_var=True)
> welch = stats.ttest_ind(A, B, equal_var=False)

> print("t=%.4f, p=%.4f" % (student.statistic, student.pvalue))
[1] t=-0.8698, p=0.3934

> print("t=%.4f, p=%.4f" % (welch.statistic, welch.pvalue))
[1] t=-0.7654, p=0.4593

> print("IC95%% = [%.2f, %.2f]" % welch.confidence_interval())
[1] IC95% = [-8.44, 4.06]
```

p de Welch = 0,459: no rechazamos H_0. El intervalo incluye 0.
No hay evidencia suficiente de una diferencia de medias.

Medias apareadas: cambio entre meses

Pregunta 1b. ¿Difiere el gasto entre meses?

- Retomamos los 25 clientes del caso y nos dan un segundo mes. Definimos D = mes 1 − mes 2 y analizamos la diferencia como una única muestra.
- El estudio se basa en la variable D:

$$H_0: \mu_A - \mu_B = 0 \rightarrow H_0: \mu_D = 0$$

- Por tanto, el estadístico es equivalente al de la PH de μ para una muestra

Media de las diferencias → $\overline{D}$

$$\hat{t} = \frac{\overline{D}}{S_D/\sqrt{n}} \sim t_{n-1}$$

Error estándar de la media → $S_D/\sqrt{n}$

← **t de Student n − 1 gl**

  - $\overline{D}$: media de la variable diferencia (D)
  - S_D : desviación típica de D
  - μ_D : valor a contrastar (0 en caso de igualdad)

Información útil: Tabla t (NIST): fila gl = n − 1. Bilateral al 5 %: compara $|t|$ con la columna 0,975.

Medias: los mismos clientes

Caso práctico: 25 clientes, segundo mes simulado

$H_0\colon \mu_D = 0 \quad H_1\colon \mu_D \neq 0$ Nivel de significación: $\alpha = 0{,}05$.

Supuestos: clientes independientes y diferencias aproximadamente normales.

$$\overline{D} = \frac{\Sigma D_i}{25} = \frac{36}{25} = 1{,}44\,€ \qquad s_D = \sqrt{\frac{56{,}16}{24}} \approx 1{,}5297\,€$$

$$SE = \frac{1{,}5297}{\sqrt{25}} \approx 0{,}3059\,€ \qquad t = \frac{1{,}44 - 0}{0{,}30594} \approx 4{,}7068$$

Información útil: Tabla t (NIST): fila 24 y columna 0,975 para un contraste bilateral al 5 %.
Al 5 % bilateral, el valor crítico es 2,0639. Como $4{,}7068 > 2{,}0639$, rechazamos H_0.

$$p = 2\,P(T_{24} \geq |4{,}7068|) \approx 0{,}0000875 < 0{,}05$$

Rechazamos H_0: el gasto medio disminuye en el mes 2

Medias apareadas en Python

Caso práctico: comprobación del segundo mes simulado

Implementación

```
> D = mes1 - mes2
> par = stats.ttest_rel(mes1, mes2)

> print("media=%.2f, sD=%.4f, EE=%.4f" %
...       (D.mean(), D.std(ddof=1), stats.sem(D)))
[1] media=1.44, sD=1.5297, EE=0.3059

> print("t=%.4f, gl=%.0f, p=%.7f" %
...       (par.statistic, par.df, par.pvalue))
[1] t=4.7068, gl=24, p=0.0000875

> print("IC95%% = [%.2f, %.2f]" % par.confidence_interval())
[1] IC95% = [0.81, 2.07]
```

Información útil: Tabla t (NIST): fila 24, columna 0,975: |4,7068| > 2,064. Rechazamos H_0.

Interpretación del cambio entre meses

¿Un cambio constante en euros o en porcentaje?

La diferencia de medias resume el cambio promedio, Δ.
En los mismos clientes, equivale a la media de las diferencias entre meses.

Efecto aditivo

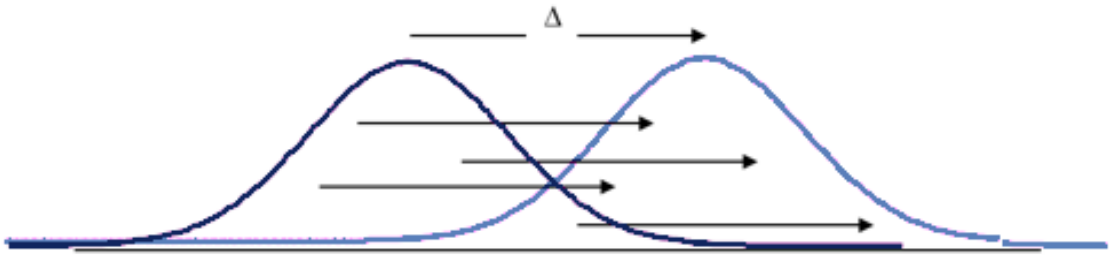
Cambio aproximadamente constante en euros.

2 € menos: de 20 a 18 € y de 40 a 38 €.

Efecto multiplicativo

Cambio proporcional al gasto inicial.

10 % menos: de 20 a 18 € y de 40 a 36 €.



Desplazamiento aditivo Δ. Esquema y ejemplos ilustrativos, no datos del caso.

La media resume mejor el cambio si este no depende del gasto inicial.
El promedio no implica un cambio idéntico en cada cliente.

Bland–Altman: patrón del cambio

Caso práctico ampliado: patrón del cambio entre meses

Cada punto es un cliente

Eje X: gasto medio de los dos meses.

Eje Y: diferencia de gasto mes 1 − mes 2.

Qué indica el patrón

Sin tendencia

Banda horizontal compatible con un cambio aproximadamente constante en euros.

Con tendencia

El cambio varía con el gasto.
Una única media puede ocultar ese patrón.

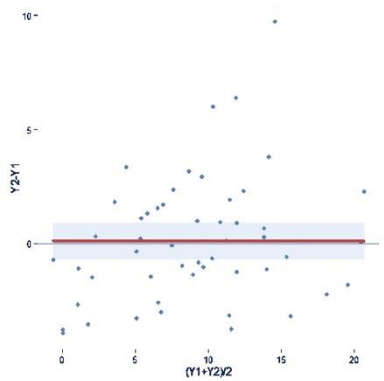
Implementación

```
> import statsmodels.api as sm
> import matplotlib.pyplot as plt
> sm.graphics.mean_diff_plot(mes1, mes2)
> plt.show()
```

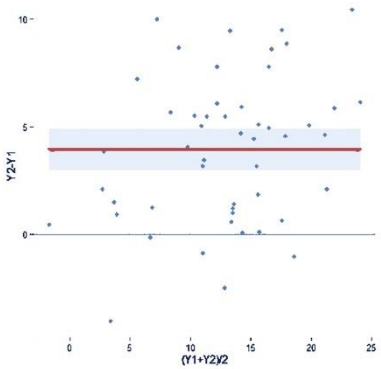
Bland–Altman: cuatro patrones posibles

Patrones ilustrativos, no resultados del caso práctico

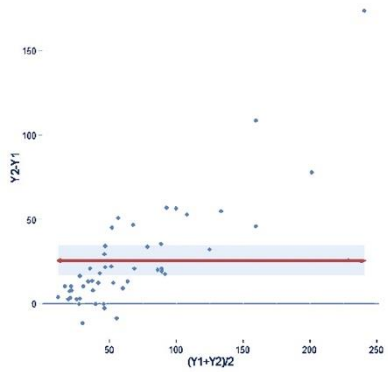
Sin efecto



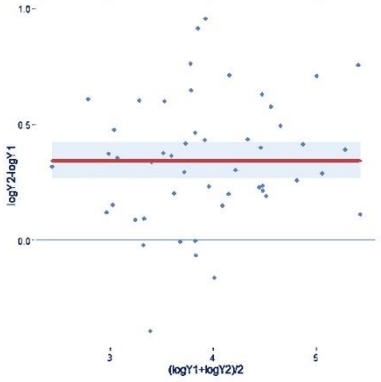
Efecto aditivo



Efecto multiplicativo



Efecto aditivo después de Log



Se observan 4 situaciones:

- Ausencia de efecto: las diferencias son cero en promedio
- Efecto aditivo: existe un efecto aditivo que no depende de las magnitudes de la variable
- Efecto multiplicativo: Cuánto mayor, son los valores, mayor es el efecto
- Efecto multiplicativo corregido con logaritmos: al sacar logaritmos de las variables, el efecto se convierte en aditivo y se puede proceder con el método habitual

Inferencia Estadística

Comparación de varianzas

03

laSalle ENG
Universitat Ramon Llull

Varianzas independientes: prueba F

Pregunta 2. ¿Difiere la dispersión entre planes?

- Prueba formal:

$$\begin{cases} H_0\colon \sigma_1^2 = \sigma_2^2 \\ H_1\colon \sigma_1^2 \neq \sigma_2^2 \end{cases}$$

- Bajo H_0, se tiene:

Varianza muestral 1 → s_1^2

Varianza muestral 2 → s_2^2

$$\hat{F} = \frac{s_1^2}{s_2^2} \sim F_{n_1-1,n_2-1}$$

F **de Fisher** $(n_1 - 1, n_2 - 1)$ **gl**

- Premisas: normalidad e independencia de las observaciones.
- Bilateral: $p = 2 \times$ la menor probabilidad de cola. Si invertimos el cociente de varianzas, intercambiamos también los grados de libertad.
- Unilateral: todo α se sitúa en la cola indicada por el sentido de H_1.

Información útil: Tabla F: columna gl_1 (numerador), fila gl_2 (denominador).

Bilateral al 5 %: cola 0,025. Límite inferior: inverso del crítico con gl intercambiados.

Dispersión por tipo de plan

Caso práctico: dispersión y cálculo con la tabla F

$H_0: \sigma_A^2 = \sigma_B^2 \quad H_1: \sigma_A^2 \neq \sigma_B^2 \quad \alpha = 0{,}05$

Plan fijo: $n_A = 16$, $s_A^2 = 23{,}7905$ €²

Prepago: $n_B = 9$, $s_B^2 = 60{,}1325$ €²

1. Cociente de varianzas (B/A)

Mayor / menor

$$F = \frac{60{,}1325}{23{,}7905} \approx 2{,}5276$$

2. Grados de libertad

Numerador: 8. Denominador: 15.

3. Decisión: dos métodos equivalentes

Por valor crítico (tabla F)

Mayor varianza arriba: buscamos un F demasiado grande, en la cola superior.

Bilateral: $\alpha/2 = 0{,}025$ por cola.

$$2{,}5276 < 3{,}199$$

Por p-valor

Inferior = 0,9421. Superior = 0,0579.

Duplicamos la menor probabilidad:

$$p = 2 \times 0{,}0579 = 0{,}1158 > 0{,}05$$

Misma conclusión: no rechazamos H_0.

Información útil: Tabla F: cola 0,025, columna $gl_1 = 8$ y fila $gl_2 = 15$.

Dispersión por tipo de plan

Caso práctico: dispersión en Python y conclusión

Prueba F bilateral: el mismo cociente B/A y los mismos gl (8, 15)

Implementación

```
> F = B.var(ddof=1) / A.var(ddof=1)
> df1, df2 = len(B)-1, len(A)-1
> pF = 2*min(stats.f.cdf(F,df1,df2), stats.f.sf(F,df1,df2))
> print("F=%.4f, p=%.4f" % (F, pF))
[1] F=2.5276, p=0.1158

> print(A.std(ddof=1).round(4), B.std(ddof=1).round(4))
[1] 4.8776  7.7545

> print(stats.levene(A,B).pvalue.round(4))  # contraste complementario
[1] 0.1781
```

$2{,}528 < 3{,}199$ y $p = 0{,}1158 > 0{,}05$: no rechazamos H_0.
No hay evidencia suficiente de varianzas distintas.

Inferencia Estadística

Comparación de proporciones

04

laSalle ENG
Universitat Ramon Llull

Comparación de proporciones

Caso práctico ampliado: plan fijo por región

- Prueba formal:

$$\begin{cases} H_0: \pi_1 = \pi_2 \\ H_1: \pi_1 \neq \pi_2 \end{cases}$$

- Bajo H_0, se tiene:

Diferencia respecto a H_0

$$\hat{z} = \frac{(P_1 - P_2) - (\pi_1 - \pi_2)}{\sqrt{\frac{P(1-P)}{n_1} + \frac{P(1-P)}{n_2}}} \sim N(0,1)$$

Error estándar bajo H_0

Normal $N(0,1)$ aproximada

con $P = \frac{n_1 \cdot P_1 + n_2 \cdot P_2}{n_1 + n_2}$; $P_1 = \frac{X_1}{n_1}$; $P_2 = \frac{X_2}{n_2}$

- Premisas: muestras no muy pequeñas
- Sin corrección de continuidad, $\chi^2 = z^2$. La decisión puede variar con el método.

Información útil: Tabla Z (NIST): busca $|z|$. El área A va de 0 a $|z|$: p bilateral = 1 − 2A.
Información útil: Tabla χ^2 (NIST): gl = 1 y columna 0,95. Compara χ^2 con 3,841 (cola derecha).

Proporciones entre regiones

Caso práctico ampliado: cálculo con la tabla Z

$$H_0: \pi_N = \pi_S \quad H_1: \pi_N \neq \pi_S \quad \alpha = 0{,}05$$

Clientes en el Norte: muestra original de 25 clientes, 16 con plan fijo (64 %).

Clientes en el Sur: nueva muestra simulada de 25 clientes, 9 con plan fijo (36 %).

1. Proporción conjunta bajo H_0

$$P = \frac{16 + 9}{25 + 25} = 0{,}50$$

2. Error estándar y estadístico z (sin corrección)

$$SE = \sqrt{\frac{0{,}50 \times (1 - 0{,}50)}{25} + \frac{0{,}50 \times (1 - 0{,}50)}{25}} \approx 0{,}1414$$

$$z = \frac{0{,}64 - 0{,}36}{0{,}1414} \approx 1{,}980$$

3. Tabla Z: contraste bilateral al 5 %

Información útil: Tabla Z: área entre 0 y $z = 0{,}4750$. Valor crítico bilateral: ±1,96.

Proporciones entre regiones

Caso práctico ampliado: contraste Z en Python

Norte: muestra original $(16/25)$. Sur: simulación $(9/25)$.

Implementación

```
> from statsmodels.stats.proportion import proportions_ztest
> z, p = proportions_ztest([16, 9], [25, 25])
> print(f"z={z:.3f}, p={p:.4f}")
[1] z=1.980, p=0.0477
```

Mismo contraste bilateral que en el cálculo manual:

$|z| = 1{,}980$ frente al valor crítico 1,96.

Con la aproximación normal sin corrección, $p = 0{,}0477$: rechazamos H_0 al 5 %.
El resultado está muy cerca del umbral de 0,05.

Inferencia Estadística

Errores en los contrastes

05

laSalle ENG
Universitat Ramon Llull

Tipos de errores en una prueba de hipótesis

Del resultado estadístico a la decisión: tipo I

- En el mismo caso práctico, la operadora decide si revisa su oferta. Rechazar o no rechazar H_0 puede llevar a decisiones equivocadas.
- Si el objetivo es tomar una decisión, se debe tener un criterio **a priori** que fije un límite α por debajo del cual, el p-valor aporte evidencia de rechazo de H_0
- Si se repite la decisión 'n' veces, como en un proceso de control de calidad, α informa de una frecuencia de errores determinada:
  - **En un $100 * \alpha$ % de los casos en que H_0 es verdadera, la rechazaremos erróneamente.**
- **Error de tipo I.** Al poner a prueba una hipótesis sobre los parámetros poblacionales, se puede cometer el error de actuar como si la hipótesis nula (H_0) fuera falsa cuando no lo es. La probabilidad de este error es:

$$\alpha = P(\text{“concluir } H_1 \text{ siendo } H_0 \text{ cierta”})$$

[Por diseño, esta probabilidad está fijada]

Tipos de errores en una prueba de hipótesis

Una diferencia real puede pasar inadvertida: tipo II

- También se puede producir la situación complementaria.
- **Error de tipo II.** En la misma situación, se puede cometer el error de no encontrar evidencia en contra de la hipótesis nula (H_0) cuando realmente es falsa. La probabilidad de este error se expresa como:

$$\beta = P(\text{“concluir } H_0 \text{ siendo } H_1 \text{ cierta”})$$

- En general esta probabilidad no es controlable ya que su valor depende del valor real del parámetro testeado (que es desconocido).

Tipos de errores		**Decisión**	
		A_0	A_1
Realidad	H_0	**Decisión correcta**	**Error Tipo I (α)**
	H_1	**Error Tipo II (β)**	**Decisión correcta**

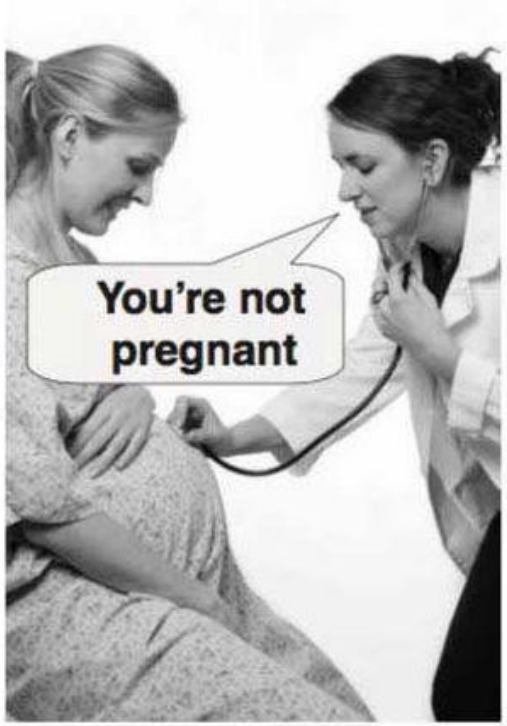
Falsos positivos y negativos

Ejemplo independiente del caso: errores de tipo I y II

Type I error
(false positive)

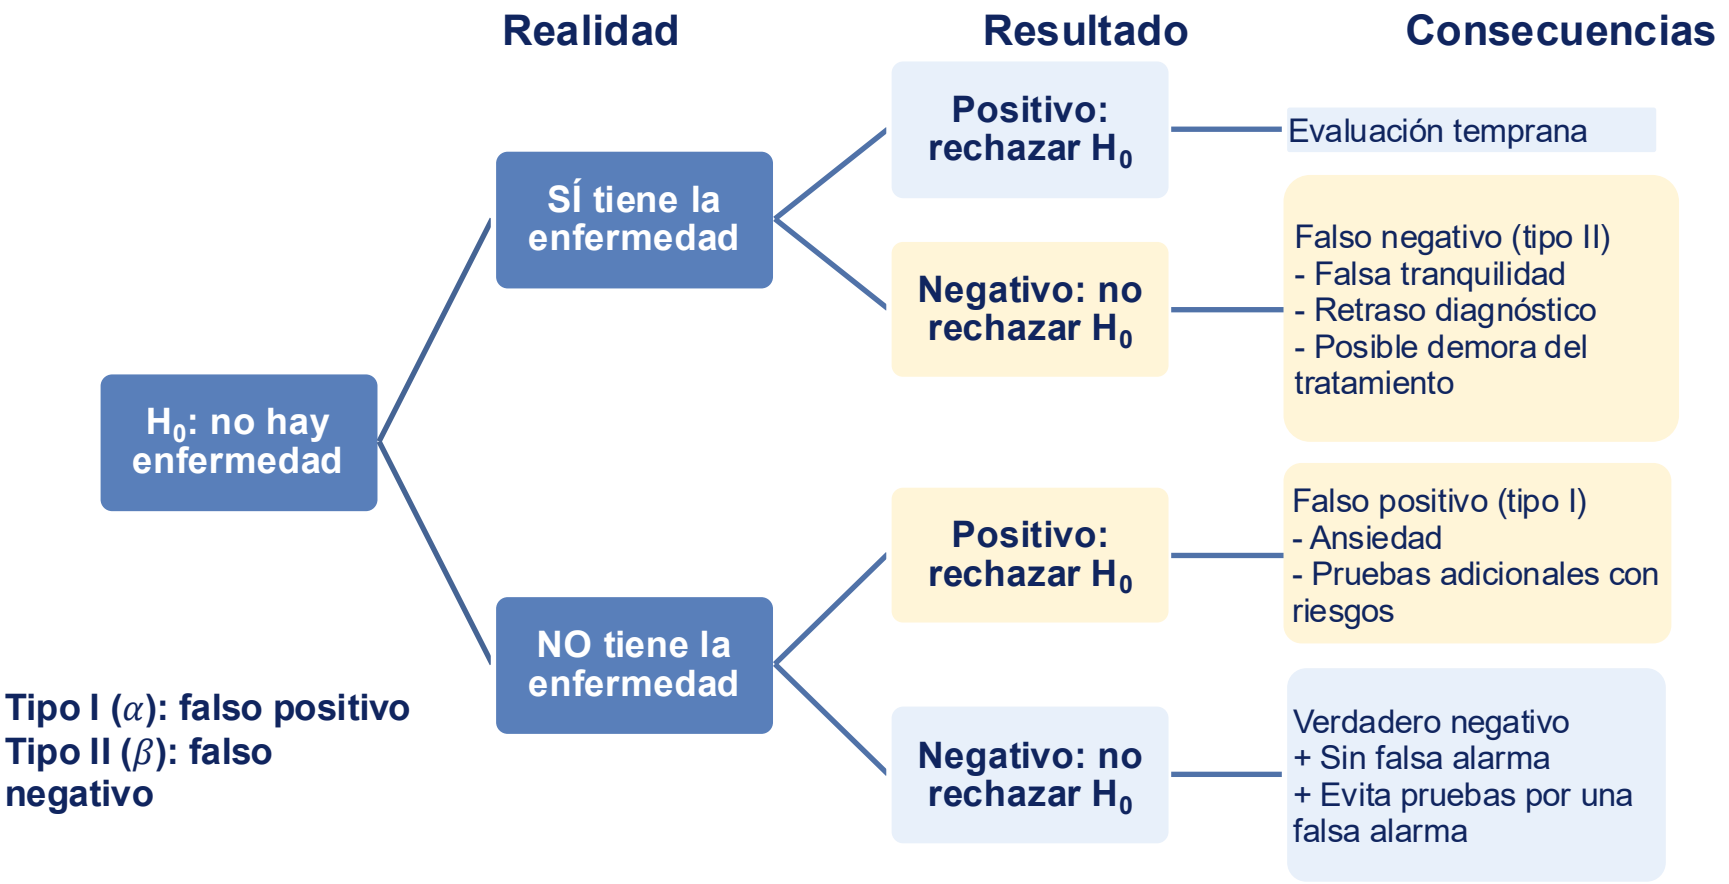


Type II error
(false negative)



Detección de una enfermedad grave

Ejemplo independiente del caso: prueba de cribado



Tipo I (α): falso positivo
Tipo II (β): falso negativo

Un resultado negativo no descarta por completo la enfermedad.

Inferencia Estadística

Anexo: Yates y Fisher

06

laSalle ENG
Universitat Ramon Llull

Annexo: Corrección de Yates y test de Fisher

Caso práctico ampliado: Yates y Fisher por región

Yates: corrección de continuidad

Los recuentos son discretos, pero la distribución χ^2 es continua.
En tablas 2×2, Yates ajusta la aproximación: reduce χ^2 y aumenta p.
Puede ser conservadora. No es una corrección obligatoria en todos los casos.

Fisher: un contraste exacto distinto

Calcula p a partir de las tablas posibles con los mismos márgenes.
No depende de la aproximación χ^2 y resulta útil con recuentos pequeños.

En el ejemplo: sin corrección $\boldsymbol{p} = 0{,}0477$; Yates $\boldsymbol{p} = 0{,}0897$; Fisher $\boldsymbol{p} = 0{,}0887$.
Especificar el método permite reproducir y entender la decisión al 5 %.

Lecturas para ampliar

Información útil: Dohm · Mike's Biostatistics Book, §9.3: Yates continuity correction
Información útil: Hitchcock (2009) · Yates and Contingency Tables: 75 Years Later
Información útil: SciPy · fisher_exact: definición, supuestos y ejemplo de cálculo

MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull