MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull

Índice

Regresión lineal

01 Introducción al modelo lineal

02 Fases de estimación del modelo

1. Formulación
2. Estimación de los parámetros
3. Interpretación de los coeficientes
4. Selección de variables
   a. Colinealidad
5. Validación de las premisas

03 Predicción

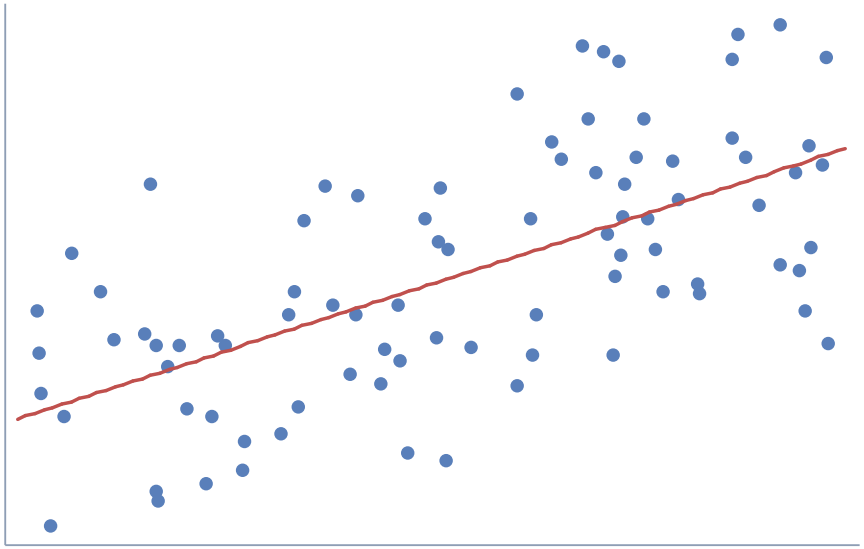
04 Muestra de entrenamiento y test

El caso de la cementera

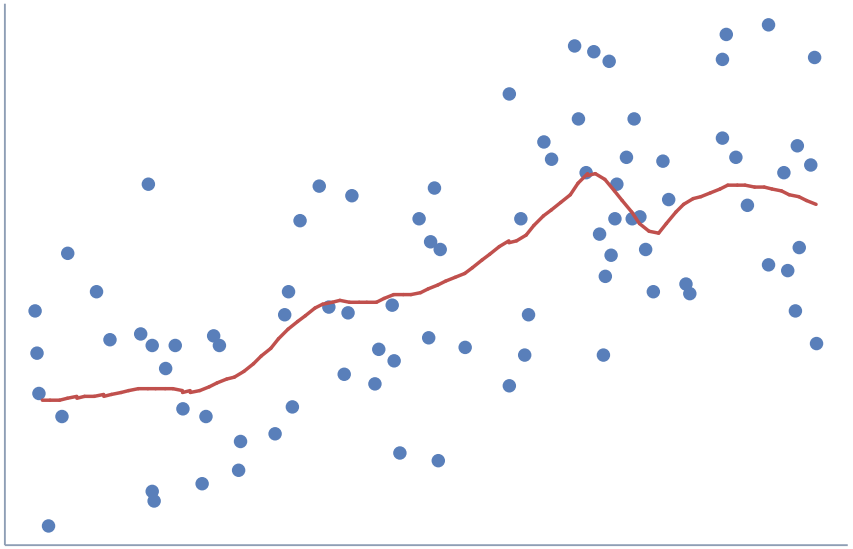
Tres preguntas sobre la resistencia

1. ¿Qué variables se asocian con la resistencia, manteniendo las demás constantes?
2. ¿Qué resistencia e intervalo esperamos para un nuevo ensayo?
3. ¿Qué error comete el modelo al predecir observaciones nuevas?

Modelo lineal

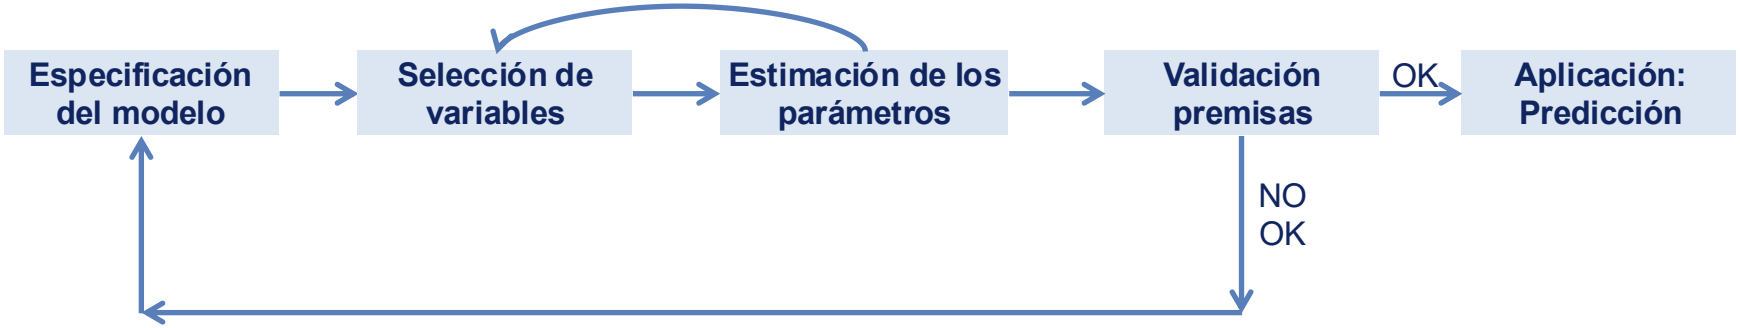


Modelo no paramétrico



Diseño de un modelo

Fases



- **Especificar:** definir qué respuesta explicar, qué predictores considerar, cómo relacionarlos y qué supuestos asumir sobre el error.
- **Estimar:** calcular con los datos los coeficientes del modelo definido.
- **Validar:** comprobar los supuestos antes de interpretar o predecir. Si fallan, revisar transformaciones, buscar otros predictores o plantear otro modelo.

Modelo lineal

Formulación

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i$$

$$\varepsilon_i \sim N(0, \sigma^2) \quad (k = 1, \ldots, p;\ i = 1, \ldots, n)$$

- Y_i: valor de la variable respuesta en el caso i-ésimo.
- X_{ki}: valor de la variable predictora k en el caso i-ésimo.
- β_0: término independiente.
- β_k: coeficiente (pendiente) de la variable X_k (k = 1, …, p).
- ε_i: error.
- σ: desviación típica de los errores (desviación residual).

- Los parámetros a estimar del modelo son β_0, β_k y σ^2.
- El modelo lineal simple contiene únicamente una variable predictora.
- En las variables categóricas se estiman **tantos coeficientes como categorías menos uno**. Cada coeficiente mide el efecto respecto a una categoría de referencia (que se denomina contraste basal).

Modelo lineal

Estimación de los parámetros

β_0, β_k y σ^2 son parámetros poblacionales desconocidos. Al estimar los coeficientes β obtenemos la recta o el hiperplano ajustado:

$$\hat{y}_i = b_0 + b_1 X_{1i} + \cdots + b_p X_{pi}$$

Cada observación tiene un residuo: la diferencia entre su valor observado y la predicción del modelo.

$$e_i = y_i - \hat{y}_i$$

La estimación por mínimos cuadrados elige los coeficientes que minimizan la suma de los residuos al cuadrado. En el caso simple:

$$\sum_{i=1}^{n} {e_i}^2 = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2$$

Al elevar al cuadrado, los signos no se cancelan y los errores grandes pesan más. Buscamos el mejor ajuste conjunto, no que cada residuo sea cero.

Modelo lineal

Ejemplo: significado de los coeficientes

```
> modelo = sm.OLS(y_train, X_train).fit()
> print(modelo.summary())
```

Antes del ajuste: aprendemos con train y reservamos test para la evaluación final.

```
[1] Referencia histórica (extracto)
                        coef    std err          t      P>|t|
    const            -18.78742   45.34568   -0.414   0.678925
    Cement             0.11391    0.01466    7.772   1.11e-13
    BlastFurnaceSlag    0.10193    0.01793    5.683   3.01e-08
    FlyAsh              0.08609    0.02235    3.852   0.000142
    Water              -0.16940    0.06732   -2.517   0.012349
    Superplasticizer    0.20413    0.16432    1.242   0.215076
    CoarseAggregate     0.01583    0.01645    0.962   0.336727
    FineAggregate       0.02437    0.01895    1.286   0.199477
    Age                 0.12058    0.01048   11.507    < 2e-16

    R-squared: 0.5973     Adj. R-squared: 0.5871
    F-statistic: 58.41    Prob (F-statistic): < 2.2e-16
    Df Model: 8          Df Residuals: 315
    Desviación residual del ajuste original: 11.08
```

Cement: +0,11391

Cambio medio por unidad más de Cement, con el resto constante.

Intercepto: −18,78742

Predicción con todos los predictores a cero. Aquí no tiene sentido físico.

Centrar en la media

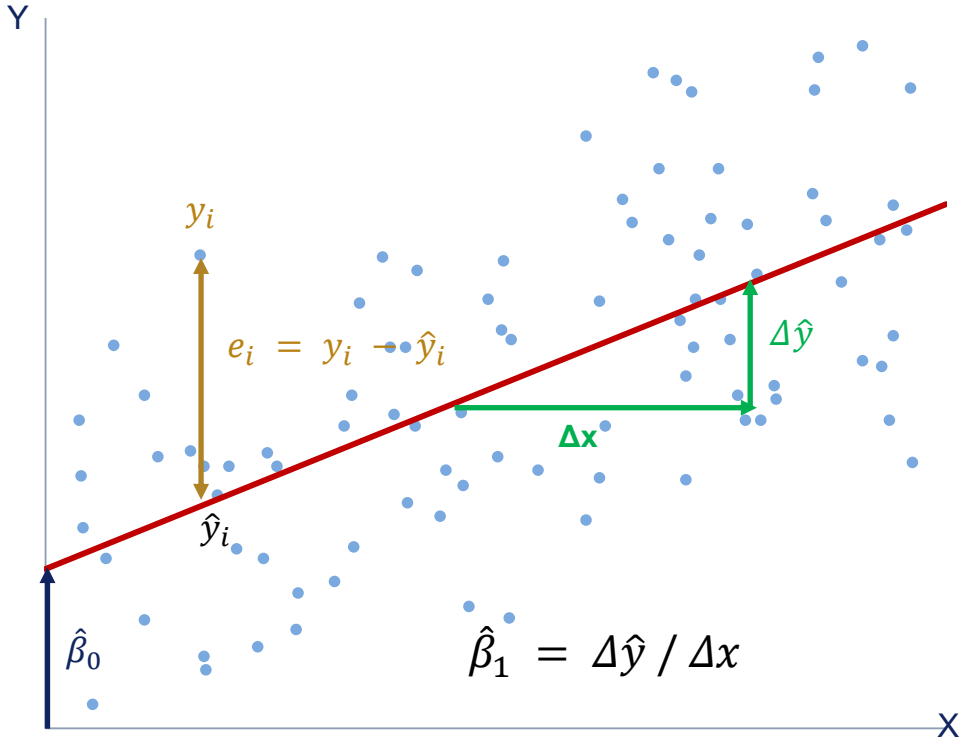
Restar la media a cada predictor sitúa el intercepto en valores medios. Las predicciones no cambian.

Modelo lineal

Interpretación de los coeficientes

- β_0 representa el valor esperado de la respuesta cuando todos los predictores valen cero.
- Si X_1 es continua, β_1 es el cambio esperado en la respuesta por cada unidad más de X_1, con los demás predictores constantes.
- Si X_1 es categórica, cada coeficiente compara una categoría con la de referencia, con los demás predictores constantes.
- En la recta estimada, $e_i = y_i - \hat{y}_i$ es el residuo. El error teórico ε_i mide la distancia a la media poblacional.

Regresión simple: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$



Esquema ilustrativo con puntos aproximados.

Selección de variables

Concepto: Capacidad explicativa

- R^2 indica qué proporción de la variabilidad de Y explica el modelo en la muestra de ajuste, frente a predecir siempre la media.

En mínimos cuadrados con intercepto: total = explicada + residual

$$\sum_i (y_i - \bar{y})^2 = \sum_i (\hat{y}_i - \bar{y})^2 + \sum_i (y_i - \hat{y}_i)^2$$

Total: datos respecto a la media | Explicada: ajuste respecto a la media | Residual: datos respecto al ajuste

$$R^2 = \frac{Explicada}{Total} = 1 - \frac{Residual}{Total}$$

- R^2 = 0,5973: el modelo explica el 59,73 % de la variabilidad. El 40,27 % queda en los residuos.

R^2 ajustado = 0,5871: penaliza añadir predictores y ayuda a comparar modelos con distinta complejidad.

```
> print(modelo.rsquared)
> print(modelo.rsquared_adj)
```

Referencia histórica, no ejecución con train

```
[1] 0.5973
[1] 0.5871
```

- Con intercepto, $0 \leq R^2 \leq 1$ en el ajuste. Un R^2 alto no garantiza buenos resultados en datos nuevos: evalúa en test, donde R^2 puede ser negativo si el modelo supera el error de predecir su media.

Selección de variables

Concepto: Colinealidad y VIF

Información compartida. Predictores muy relacionados aportan información redundante. Esto dificulta separar la asociación de cada uno con la respuesta.

Qué mide el VIF. Resume la colinealidad del predictor j con el conjunto de los demás predictores.

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}$$

Cómo obtenemos R^2_j. Ajustamos una regresión auxiliar: X_j es la respuesta y los demás predictores son sus explicativas. No incluimos la respuesta Y del modelo original.

Cómo interpretarlo. Con intercepto, R^2_j va de 0 a 1. Cuanto más se acerca a 1, mejor explican los demás a X_j y mayor es su VIF.

Umbral orientativo. VIF = 5 equivale a $R^2_j = 0{,}80$: los demás explican el 80 % de la variabilidad de X_j. VIF > 5 pide revisar, no eliminar automáticamente.

Consecuencia. La colinealidad aumenta los errores estándar y reduce la precisión de los coeficientes estimados.

Selección de variables

Concepto: Colinealidad y VIF, ejemplo en Python

- Varios predictores pueden aportar información parecida. Esto dificulta separar sus asociaciones con la variable respuesta.

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}$$

```
> from statsmodels.stats.outliers_influence import (
>     variance_inflation_factor)
> X = modelo.model.exog
> vif = pd.Series(
>     [variance_inflation_factor(X, j)
>      for j in range(1, X.shape[1])],
>     index=modelo.model.exog_names[1:])
> print(vif)
```

$$\mathrm{VIF}_j > 5 \quad \mathrm{VIF}_j = 5 \Leftrightarrow R_j^2 = 0{,}80$$



R^2_j mide el ajuste de un predictor con los demás. La colinealidad aumenta la incertidumbre. Un VIF alto pide revisión, no borrado automático.

Selección de variables

Métodos automáticos

La selección automática compara modelos mediante AIC (criterio de Akaike) o BIC (criterio bayesiano). Un valor menor indica una mejor comparación relativa.

$$\mathrm{AIC} = 2k - 2\log(L) \quad \mathrm{BIC} = k\log(n) - 2\log(L)$$

k es el número de parámetros, n el tamaño muestral y L la verosimilitud maximizada. Ambos criterios equilibran ajuste y complejidad.

AIC y BIC favorecen modelos parsimoniosos. BIC penaliza más el número de parámetros cuando n > 7.

Forward: parte del modelo sin predictores y añade, en cada paso, la variable que más mejora el AIC o BIC.

Backward: parte del modelo completo y elimina, en cada paso, la variable cuya retirada más mejora el criterio.

Forward-backward: combina pasos de incorporación y eliminación de variables.

LASSO: es otra alternativa basada en penalización de coeficientes. No se desarrolla en este bloque.

Selección de variables

Metodología manual

1. Cribado inicial. Ajustar cada predictor por separado y preseleccionar los que tengan $p < 0{,}10$. Conservar también las variables relevantes por criterio técnico.

2. Modelo conjunto. Ajustar una regresión múltiple con las variables seleccionadas, usando los datos de entrenamiento.

3. Retirada de variables. Evaluar una a una las variables con $p > 0{,}05$, empezando por el mayor p-valor. Antes de retirar cada candidata:

a) Comparar los modelos. Usar el R^2 ajustado, que penaliza añadir predictores. Considerar la retirada si se mantiene o aumenta, con las mismas observaciones.

b) Revisar los coeficientes. Si alguno de los demás cambia más de un 10 %, conservar la candidata y estudiar posible confusión. El 10 % es orientativo.

c) Revisar la colinealidad. Un VIF > 5 alerta de información compartida. Revisar las variables implicadas, sin eliminar ninguna automáticamente.

4. Repetir y cerrar. Reajustar tras cada retirada y revisar el resto de candidatas. Comparar la predicción en validación y fijar el modelo antes de evaluar test.

Modelo lineal

Ejemplo: incertidumbre y selección de variables

```
> modelo = sm.OLS(y_train, X_train).fit()
> print(modelo.summary())
```

```
[1] Referencia histórica (extracto)
                       coef    std err          t      P>|t|
const            -18.78742   45.34568   -0.414   0.678925
Cement             0.11391    0.01466    7.772   1.11e-13
BlastFurnaceSlag    0.10193    0.01793    5.683   3.01e-08
FlyAsh              0.08609    0.02235    3.852   0.000142
Water              -0.16940    0.06732   -2.517   0.012349
Superplasticizer    0.20413    0.16432    1.242   0.215076
CoarseAggregate     0.01583    0.01645    0.962   0.336727
FineAggregate       0.02437    0.01895    1.286   0.199477
Age                 0.12058    0.01048   11.507    < 2e-16

R-squared: 0.5973      Adj. R-squared: 0.5871
F-statistic: 58.41     Prob (F-statistic): < 2.2e-16
Df Model: 8           Df Residuals: 315
Desviación residual del ajuste original: 11.08
```

Cement: +0,11391 en la respuesta por unidad más, con el resto constante.

$p = 1{,}11 \times 10^{-13}$: evidencia contra H_0: $\beta = 0$, dado el resto de predictores.

Error estándar: 0,01466. Mide la incertidumbre del coeficiente estimado.

$R^2 = 0{,}5973$: explica el 59,73% de la variabilidad en la muestra de ajuste.

Desviación residual: 11,08. Estima la dispersión de los errores del modelo.

Resultados históricos. Un p-valor aislado no basta para decidir qué variable retirar.

Validación

Supuestos para interpretar y predecir

- Linealidad: la media de Y sigue la combinación de predictores propuesta. Una curva en los residuos sugiere revisar esa forma.

$$E(Y_i \mid X) = \beta_0 + \sum_{k=1}^{p} \beta_k X_{ki}$$

- Error medio nulo: sin sesgo sistemático.

$$E(\varepsilon_i \mid X) = 0$$

- Homoscedasticidad: la varianza del error es constante para cualquier X.

$$Var(\varepsilon_i \mid X) = \sigma^2$$

- Independencia: conocer el error de una observación no aporta información sobre el de otra.

$$\varepsilon_i \perp \varepsilon_j \mid X, \qquad i \neq j$$

- Sin colinealidad perfecta: ningún predictor se obtiene exactamente a partir de los demás. Así podemos identificar sus coeficientes.

$$rank(X) = p + 1$$

- Normalidad: los errores siguen una distribución normal. Permite la inferencia clásica exacta en muestras pequeñas.

$$\varepsilon_i \mid X \sim N(0, \sigma^2)$$

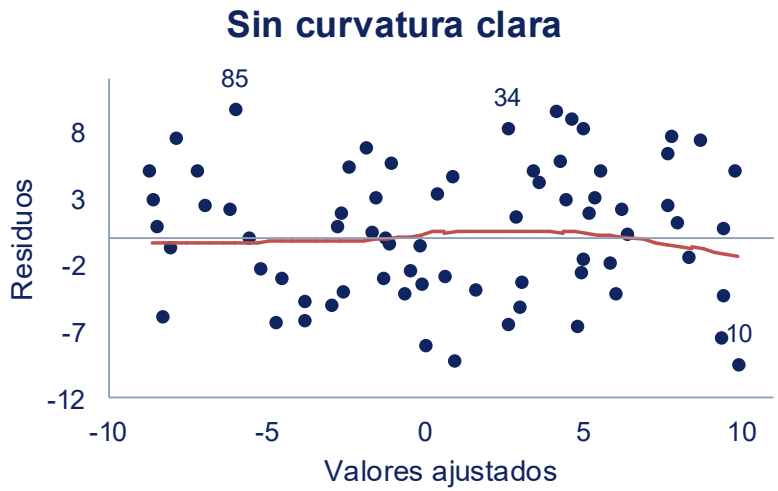
BLUE: estimador lineal insesgado de menor varianza, bajo los supuestos de Gauss–Markov. No requiere normalidad.

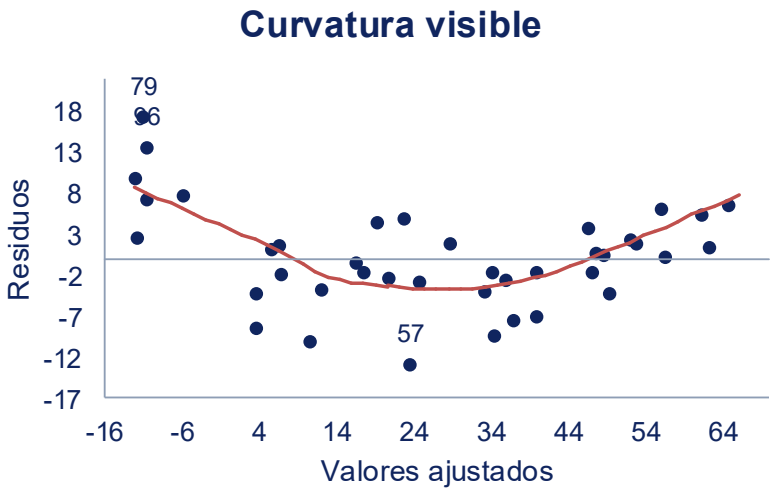
Validación

Premisas - Linealidad

- El residuo es el valor observado menos el predicho. Al representarlo frente al valor ajustado, buscamos una nube centrada en cero.
- Una curva persistente indica que el modelo deja una relación sin recoger.

```
> plt.scatter(modelo.fittedvalues, modelo.resid)
```



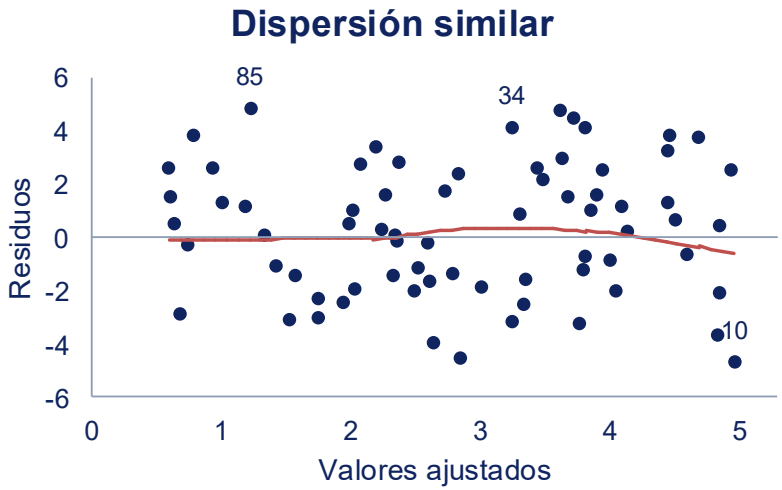


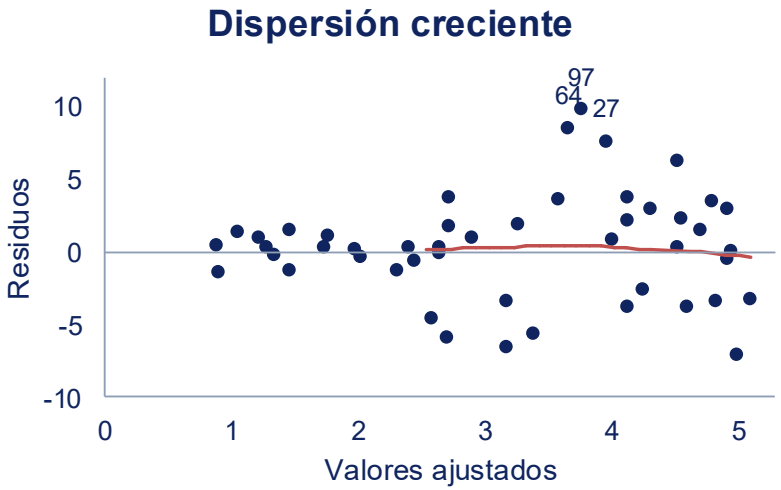
Si aparece curvatura: revisar transformaciones o términos adicionales y volver a comprobar los residuos.

Validación

Premisas - Homoscedasticidad

- Homoscedasticidad significa que la variabilidad del error se mantiene constante. En el gráfico, buscamos una amplitud vertical similar.
- Un abanico o embudo sugiere heteroscedasticidad: la precisión cambia según el nivel de la respuesta.





Si cambia la varianza: revisar la especificación y considerar errores estándar robustos para la inferencia.

Validación

Premisas – Normalidad de los errores

- El Q–Q compara los cuantiles de los residuos con los de una normal. Puntos próximos a la recta son compatibles con normalidad.
- Desviaciones sistemáticas, sobre todo en los extremos, sugieren asimetría o colas distintas.

```
> sm.qqplot(modelo.resid, line="s")
```





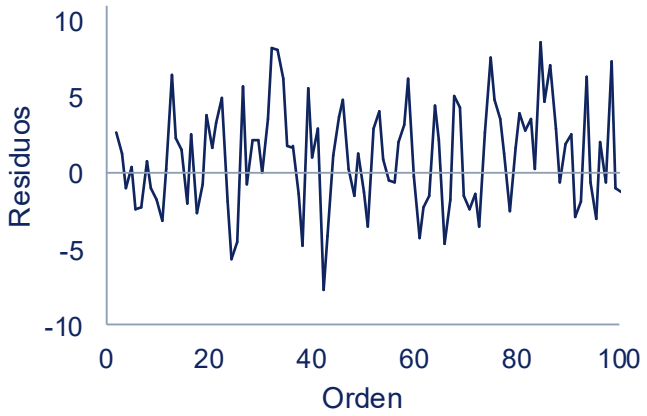
Si hay desviaciones: revisar casos extremos y la forma del modelo. No exigimos que Y ni los predictores sean normales.

Validación

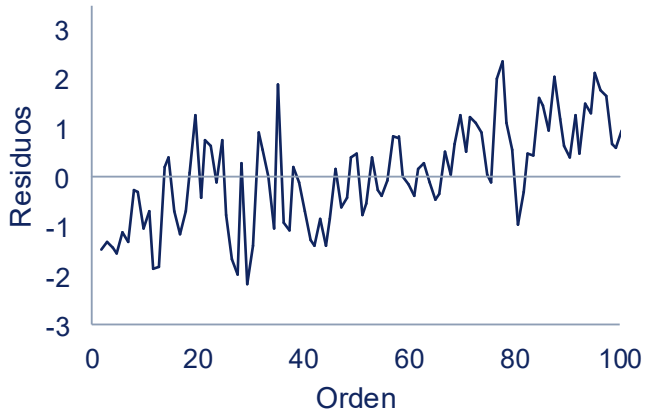
Premisas – Independencia

- Los errores pueden estar relacionados entre observaciones cercanas en el tiempo o del mismo grupo. Un orden arbitrario de filas no permite detectarlo.
- Con el orden temporal real, buscamos rachas, ciclos o tendencias en los residuos.

Sin patrón claro



Tendencia temporal



Una tendencia como esta sugiere estructura temporal que el modelo no recoge.

Si hay dependencia: modelar su estructura y separar grupos o periodos al evaluar la predicción.

Validación

Transformaciones

Los patrones de los residuos orientan la transformación. Cambiar Y puede estabilizar la varianza y mejorar la normalidad de los errores. Cambiar X puede corregir curvatura.

VARIABLE RESPUESTA: cambiamos la escala de Y

Logaritmo, si Y > 0. Comprime valores altos. Puede ayudar cuando la dispersión de los residuos aumenta con el nivel de la respuesta.

$$Y' = log(Y) = \beta_0 + \beta_1 X + \varepsilon$$

Box–Cox, si Y > 0. Familia de transformaciones controlada por λ. Incluye el logaritmo cuando λ = 0.

$$Y^{(\lambda)} = \begin{cases} \dfrac{Y^{\lambda} - 1}{\lambda} & si\ \lambda \neq 0 \\ log(Y) & si\ \lambda = 0 \end{cases}$$

Elegimos λ con entrenamiento y revisamos los residuos del modelo completo. Box–Cox no garantiza resolver todos los problemas.

VARIABLES PREDICTORAS: cambiamos la forma de la relación

Representamos los residuos frente a cada X. Si aparece curvatura, probamos una transformación adecuada, como log(X) para X > 0, y reajustamos el modelo completo.

Tras transformar, repetimos los diagnósticos y comparamos en validación, sin usar test.

Validación

Transformaciones: ejemplo en Python

- Una transformación cambia la forma de la relación. En este ejemplo, log(Age) permite que el cambio en la respuesta por un año adicional dependa de la edad.

```
> import numpy as np
> X_log = X_train.copy()
> X_log["Age"] = np.log(train["Age"])
> modelo_log = sm.OLS(y_train, X_log).fit()
> print(modelo_log.summary())
```

- log(Age) exige valores positivos. La respuesta conserva su escala, pero el coeficiente ahora multiplica al logaritmo de Age.
- Box–Cox transforma la respuesta positiva mediante λ. Estimar λ solo con entrenamiento y revisar de nuevo los residuos.
- Comparar candidatos dentro de train, sin usar test. Si transformamos Y, deshacer la transformación exige cuidar el sesgo y los intervalos.

Validación

Observaciones influyentes

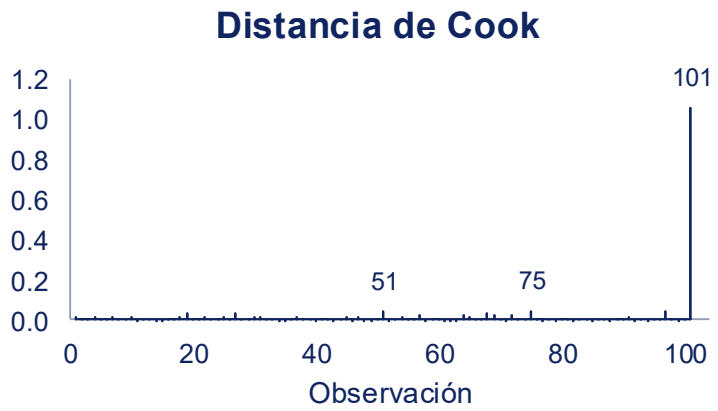
- **Qué mide.** Una observación es influyente si, al retirarla y reajustar el modelo, cambian mucho los coeficientes y las predicciones.
- **Cómo lo resume Cook.** Compara las predicciones para todos los casos, con y sin la observación i. Suma sus diferencias al cuadrado y las normaliza.
- **De qué depende.** Del residuo y del leverage: lo inusual de sus valores de X. Un leverage alto, por sí solo, no implica influencia.

```
> cook = modelo.get_influence().cooks_distance[0]
> casos = train.loc[cook > 4 / len(train)]
```

$$D_i > \frac{4}{n}$$

4/n y 1 son umbrales orientativos. Revisar los picos del gráfico. n es el número de casos del ajuste.

- Reajustar sin el caso y comparar coeficientes y predicciones: ¿cambian las conclusiones?
- Verificar errores y contexto. Conservar los datos válidos y documentar cualquier exclusión.



Reconstrucción aproximada de la imagen original. Datos editables.

Modelo lineal

Predicción: valor individual y valor esperado

Con los mismos valores de los predictores, podemos plantear dos objetivos.

Valor individual: una observación concreta

Predecimos la respuesta de una observación nueva. El intervalo de predicción recoge la incertidumbre de la media y la variación entre observaciones.

Valor esperado: el promedio de observaciones iguales en X

Estimamos la media de la respuesta para esos predictores. El intervalo de confianza cuantifica la incertidumbre al estimar esa media.

La estimación puntual es la misma en ambos casos

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \cdots + \hat{\beta}_p x_{0p}$$

"Puntual" significa un único número. El intervalo de predicción es más amplio porque una observación puede alejarse de la media, aun con los mismos X.

Modelo lineal

Ejemplo: predicción en observaciones nuevas

- Valor individual: ¿qué resistencia tendrá un nuevo ensayo con esta composición y edad? Usamos un intervalo de predicción.
- Valor esperado: ¿cuál es la resistencia media de los ensayos con esa misma composición y edad? Usamos un intervalo de confianza para la media.

```
> X_test = sm.add_constant(test[cols], has_constant="add")
> X_test = X_test[X_train.columns]
> nueva = X_test.iloc[[0]]  # incluye const
> pred = modelo.get_prediction(nueva)
> intervalos = pred.summary_frame(alpha=0.05)
```

- mean: estimación puntual común a ambos objetivos.
- mean_ci_lower / upper: intervalo de confianza del 95% para la media.
- obs_ci_lower / upper: intervalo de predicción del 95% para un ensayo nuevo, más amplio. Evitar extrapolar fuera del rango de entrenamiento.

Capacidad predictiva

Separación de entrenamiento y test

Antes de ajustar el modelo, separamos los datos: aprendemos con train y reservamos test para estimar cómo predecirá en observaciones nuevas.

Ejemplo ilustrativo: 100 observaciones independientes, reparto aleatorio 80/20

TRAIN · 80 observaciones (80 %)	TEST 20 (20 %)

TRAIN: desarrollar el modelo

Ajustar coeficientes, elegir variables y transformaciones. Comparar alternativas con validación dentro de train.

TEST: evaluación final

Aplicar el modelo ya fijado y medir sus errores. No usar estos resultados para elegir o retocar el modelo.

```
> from sklearn.model_selection import train_test_split
> train, test = train_test_split(datos, test_size=0.20, random_state=42)
```

random_state fija un reparto reproducible. El 80/20 es un ejemplo, no una regla universal.

Si hay fechas o grupos, el split debe respetarlos para evitar compartir información entre train y test.

Capacidad predictiva

Ejemplo en Python: evaluación en test

- Evaluamos la tercera pregunta con el test reservado. El modelo debe quedar fijado antes de mirar sus errores.

```
> y_test = test["Strength"]
> y_pred = modelo.predict(X_test)
> rmse = np.sqrt(mean_squared_error(y_test, y_pred))
> mae = mean_absolute_error(y_test, y_pred)
> r2 = r2_score(y_test, y_pred)
```

- RMSE y MAE se expresan en las unidades de Strength. Un valor menor indica errores más pequeños.
- La comparación con modelos alternativos ocurre antes, mediante validación dentro de train. Test estima el rendimiento final.

Capacidad predictiva

Interpretación de las métricas

Raíz del error cuadrático medio (RMSE):

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Error absoluto medio (MAE):

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Error porcentual absoluto medio (MAPE):

$$\mathrm{MAPE} = \frac{100}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|$$

Coeficiente de determinación en test:

$$R^2_{\mathrm{test}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

RMSE penaliza más los errores grandes. MAE resume el error absoluto medio. Ambos usan las unidades de la respuesta.

y_i: valor observado · $\hat{y}_i$: predicción · n: casos de test · $\bar{y}$: media observada en test

MAPE expresa error porcentual, pero no está definido con valores observados iguales a cero y es inestable cerca de cero. R^2 de test puede ser negativo.

Conclusiones del modelo lineal

Las tres preguntas del caso, al cierre

1. ¿Qué variables se asocian con la resistencia?

Los coeficientes describen asociaciones con el resto constante.
Los errores estándar, el VIF y los residuos ayudan a valorar su interpretación.

2. ¿Qué esperamos para un nuevo ensayo?

La estimación puntual coincide para la media y para un individuo.
El intervalo de predicción individual incorpora más incertidumbre.

3. ¿Qué error cometemos con datos nuevos?

Se estima con el modelo fijado y el test reservado, mediante RMSE, MAE o R^2.
Aquí queda pendiente calcular esas métricas con los datos reales.

Ajuste, diagnósticos y evaluación en test sostienen el uso del modelo.

Anexo: derivaciones

Regresión lineal: mínimos cuadrados y máxima verosimilitud

Material de ampliación · MUBD

laSalle ENG
Universitat Ramon Llull

Anexo: Modelo lineal

Caso simple: derivadas y primera ecuación normal

1. Minimizamos la suma de cuadrados. Todas las sumas van de i = 1 a n.

$$S(b_0, b_1) = \sum(y_i - b_0 - b_1 x_i)^2$$

2. Aplicamos la regla de la cadena e igualamos las derivadas a cero.

$$\frac{\partial S}{\partial b_0} = -2\sum(y_i - b_0 - b_1 x_i) = 0$$

$$\frac{\partial S}{\partial b_1} = -2\sum x_i(y_i - b_0 - b_1 x_i) = 0$$

3. En la primera ecuación, abrimos la suma y dividimos por n.

$$\sum y_i - n b_0 - b_1 \sum x_i = 0$$

$$\bar{y} - b_0 - b_1 \bar{x} = 0 \Rightarrow b_0 = \bar{y} - b_1 \bar{x}$$

Anexo: Modelo lineal

Caso simple: sustitución y despeje de la pendiente

4. Sustituimos $b_0 = \bar{y} - b_1\bar{x}$ en la segunda ecuación normal.

$$\sum x_i[y_i - \bar{y} - b_1(x_i - \bar{x})] = 0$$

5. Escribimos $x_i = (x_i - \bar{x}) + \bar{x}$. Las sumas de desviaciones son cero.

$$\sum(x_i - \bar{x})(y_i - \bar{y}) - b_1\sum(x_i - \bar{x})^2 = 0$$

6. Aislamos b_1 y recuperamos el intercepto.

$$b_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$$

$$b_0 = \bar{y} - b_1\bar{x}$$

Si x varía, el denominador es positivo y el mínimo es único. La recta ajustada pasa por el punto $(\bar{x}, \bar{y})$.

Anexo: Modelo lineal

Caso múltiple: verosimilitud del modelo normal

1. Suponemos errores normales independientes con varianza común. X incluye una columna de unos y p predictores.

$$y = X\beta + \varepsilon \quad \varepsilon \mid X \sim N(0, \sigma^2 I)$$

2. Por independencia, multiplicamos las densidades de las observaciones.

$$L(\beta, \sigma^2 \mid y, X) = (2\pi\sigma^2)^{-n/2} \, exp[-\frac{(y - X\beta)^T (y - X\beta)}{2\sigma^2}]$$

3. Tomamos logaritmos para convertir el producto en una suma.

$$\ell(\beta, \sigma^2) = -\frac{n}{2} log(2\pi\sigma^2) - \frac{(y - X\beta)^T (y - X\beta)}{2\sigma^2}$$

Para σ² fija, maximizar ℓ respecto a β equivale a minimizar la suma de cuadrados. La normalidad conecta ambos métodos.

Anexo: Modelo lineal

Caso múltiple: máximo y ecuaciones normales

4. Derivamos la log-verosimilitud respecto al vector β.

$$\frac{\partial \ell}{\partial \beta} = \frac{1}{\sigma^2} X^T (y - X\beta)$$

5. Igualamos a cero y obtenemos las mismas ecuaciones normales.

$$X^T y - X^T X\hat{\beta} = 0 \Rightarrow X^T X\hat{\beta} = X^T y$$

6. Con rango completo de columnas, despejamos el estimador.

$$\hat{\beta}_{MV} = (X^T X)^{-1} X^T y = \hat{\beta}_{MCO}$$

La Hessiana es negativa definida con rango completo: el máximo es único.

$$\frac{\partial^2 \ell}{\partial \beta \partial \beta^T} = -\frac{1}{\sigma^2} X^T X$$

MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull