MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull

Índice

Regresión logística

01 Introducción

02 Función Link

03 Modelo. Formulación

04 Estimación de los parámetros

05 Interpretación de los coeficientes

06 Selección de variables

07 Predicción

08 Validación

Regresión Logística

Introducción

01

Regresión logística

Motivación

Muchas situaciones tienen solo dos resultados posibles:

- Compra de un producto: sí o no
- Pago de un crédito: sí o no
- Pieza defectuosa: sí o no

Predecimos probabilidades

Al incorporar predictores, el modelo lineal clásico presenta limitaciones:

- La respuesta es dicotómica (0 o 1) y su distribución no es normal.
- Las predicciones pueden quedar fuera de [0, 1], como 2,3 o −4,5, que carecen de sentido como probabilidades.

El enlace logit **(una función link)** transforma probabilidades del intervalo (0, 1) en valores de toda la recta real, que podemos modelar con un predictor lineal.

Regresión Logística

Función Link

02

laSalle ENG
Universitat Ramon Llull

Regresión logística

Función Link

- La función link transforma la probabilidad de éxito (π) para obtener valores que vayan de −∞ a +∞.
  - π se mueve entre 0 y 1.
  - $\frac{\pi}{1-\pi}$ se mueve entre 0 y +∞. El cociente entre la probabilidad de éxito y la probabilidad de fracaso se denomina ***odd***.
  - $log(\frac{\pi}{1-\pi})$ se mueve entre −∞ y +∞.
- Por tanto, la función ***link*** es $log(\frac{\pi}{1-\pi})$
  - La función $f(x) = log(\frac{x}{1-x})$ se denomina función ***logit***. No es la única función link, pero sí la más usual e interpretable.
  - Cuando la función ***logit*** se aplica a una probabilidad, el resultado se denomina ***logodd*** (abreviatura de logaritmo de un odd).

Probabilidad, odds y logit en Python

Crédito: probabilidad de pago supuesta del 80 %

Ejemplo: cliente con una probabilidad de pago supuesta del 80 %.

Implementación

```
from scipy.special import logit, expit
p = 0.80
odds = p / (1 - p)
eta = logit(p)
p_recuperada = expit(eta)
print(f"odds={odds:.3f}, logit={eta:.3f}")
print(f"probabilidad={p_recuperada:.3f}")

odds=4.000, logit=1.386
probabilidad=0.800
```

Resultado: odds de 4 y logit de 1,386.

logit transforma la probabilidad. expit aplica la transformación inversa.

Regresión Logística

Modelo y formulación

03

laSalle ENG
Universitat Ramon Llull

Regresión logística

Modelo

Por tanto el modelo a ajustar será:

$$ln(\frac{\pi}{1-\pi}) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$$

- Si se desea conocer la probabilidad para un conjunto concreto de variables predictoras y ya se han estimado los coeficientes del modelo, se debe deshacer la transformación:

$$PL = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$$

PL: predictor lineal

$$ln(\frac{\pi}{1-\pi}) = PL \;\Rightarrow\; \frac{\pi}{1-\pi} = odds = e^{PL} \;\Rightarrow\; \pi = e^{PL} - \pi\, e^{PL}$$

$$(1 + e^{PL})\pi = e^{PL} \;\Rightarrow\; \pi = \frac{e^{PL}}{1 + e^{PL}} = \frac{1}{1 + e^{-PL}}$$

La probabilidad queda entre 0 y 1 para cualquier predictor lineal finito.

Regresión logística

Forma de la curva de probabilidad

Con una única **covariable** X, distintos coeficientes producen distintas curvas de probabilidad.

$\beta > 0$: p aumenta.

$\beta < 0$: p disminuye.

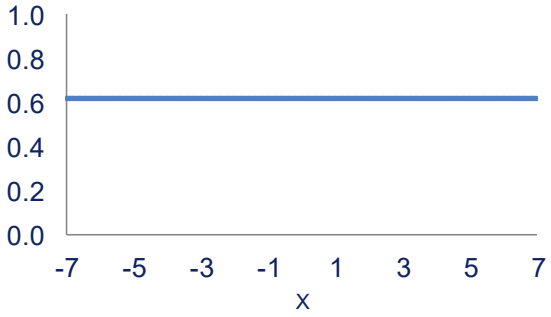
$\beta = 0$: p constante.

En el crédito, duración tiene $\beta < 0$.

La variación de p depende del punto de partida.

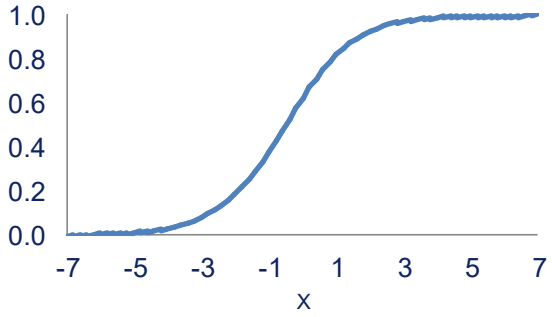
Sin efecto de X

$\beta_0 = 0,5 \quad \beta_1 = 0$



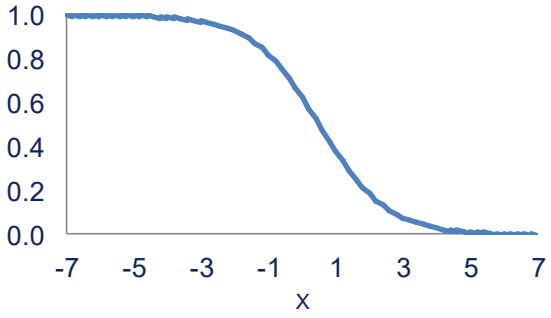
X favorece el éxito

$\beta_0 = 0,5 \quad \beta_1 = 1$



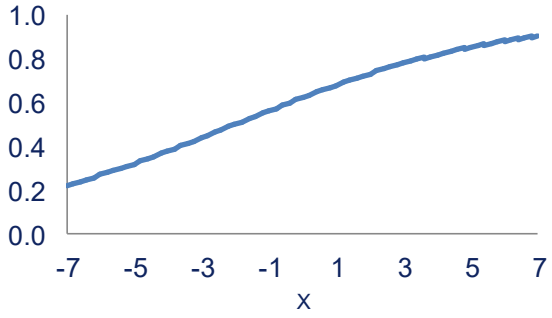
X favorece el fracaso

$\beta_0 = 0,5 \quad \beta_1 = -1$



X favorece levemente el éxito

$\beta_0 = 0,5 \quad \beta_1 = 0,25$



Eje vertical: probabilidad de éxito. La misma escala de 0 a 1 permite comparar las cuatro curvas.

Regresión Logística

Estimación de los parámetros

04

laSalle ENG
Universitat Ramon Llull

Regresión logística

Estimación de los parámetros del modelo

Los parámetros se estiman por máxima verosimilitud. Este método asume que la variable respuesta sigue una distribución **binomial**.

Lo que se hace es optimizar el valor de los parámetros del modelo que maximizan la "probabilidad" de haber observado estos datos.

$$ln(\frac{\hat{\pi}}{1-\hat{\pi}}) = b_0 + b_1 X_1 + \cdots + b_p X_p$$

$b_j = \hat{\beta}_j$ Cada b estima un coeficiente poblacional β. El acento circunflejo indica una estimación.

Atención: si una categoría solo presenta éxitos o solo fracasos, puede aparecer separación y no existir una estimación finita del coeficiente.

Regresión Logística

Interpretación de los coeficientes

05

laSalle ENG
Universitat Ramon Llull

Regresión logística

Cómo calcular e interpretar un OR

Las odds comparan la probabilidad de pago (éxito) con la de impago (fracaso): p / (1 − p).
El odds ratio (OR) divide las odds de un grupo entre las del grupo de referencia.

Saldo de la cuenta	Pagos	Impagos	Total
≥200 DM (alto)	40	20	60
Negativo	20	40	60
Total	60	60	120

Saldo de la cuenta, no del préstamo. Alto: ≥200 DM. Negativo: descubierto.
DM = marcos alemanes, moneda anterior al euro. Datos ilustrativos.

$$odds_{alto} = \frac{40}{20} = 2 \quad odds_{negativo} = \frac{20}{40} = 0{,}5$$

$$OR = \frac{odds_{alto}}{odds_{negativo}} = \frac{2}{0{,}5} = 4$$

Las odds de pago con saldo alto son 4 veces las de saldo negativo.

Probabilidad de pago: 40/60 = 66,7 % frente a 20/60 = 33,3 %.
En este ejemplo se duplica la probabilidad, mientras las odds se multiplican por 4.

Regresión logística

Por qué el OR es la exponencial del coeficiente

En el modelo logístico, las odds de cada perfil son la exponencial de su predictor lineal.

1. Calculamos las odds de cada cliente con el modelo estimado

$$odds_1 = exp(b_0 + b_1X_{11} + b_2X_{21} + \cdots + b_pX_{p1})$$
$$odds_2 = exp(b_0 + b_1X_{12} + b_2X_{22} + \cdots + b_pX_{p2})$$

2. Dividimos las odds y restamos los exponentes

$$OR = \frac{exp(b_0 + b_1X_{11} + b_2X_{21} + \cdots + b_pX_{p1})}{exp(b_0 + b_1X_{12} + b_2X_{22} + \cdots + b_pX_{p2})}$$
$$= exp[(b_0 + b_1X_{11} + b_2X_{21} + \cdots + b_pX_{p1}) - (b_0 + b_1X_{12} + b_2X_{22} + \cdots + b_pX_{p2})]$$
$$OR = exp[b_1(X_{11} - X_{12}) + b_2(X_{21} - X_{22}) + \cdots + b_p(X_{p1} - X_{p2})]$$

El intercepto se cancela. En X, el primer subíndice identifica la variable y el segundo, al cliente. Las covariables iguales también se cancelan.

Si X_1 aumenta $_1$ unidad y las demás variables no cambian:

$$OR = exp(b_1) = exp(1{,}3863) \approx 4$$

El modelo recupera el mismo OR que la tabla de saldo: aproximadamente 4.

Regresión logística en Python

Interpretación del resumen del ajuste

Implementación

```
modelo = smf.glm(formula, data=datos,
    family=sm.families.Binomial()).fit(); print(modelo.summary())
```

Cifras originales (extracto)

	coef	std err	z	P>|z|
Intercepto	1.006	1.176	0.855	0.392390
Saldo >=200 DM	**1.382**	**0.4272**	3.236	**0.001213**
Saldo 0 a <200 DM	0.6522	0.2533	2.575	0.010035
Sin cuenta	2.086	0.2769	7.535	4.90e-14
Duracion (meses)	-0.02832	0.01093	-2.591	0.009556
Hist. critico	1.756	0.4895	3.587	0.000335
Hist. retrasos	0.8378	0.5257	1.594	0.111038
Hist. al dia	1.060	0.4559	2.324	0.020102
Hist. sin creditos	0.6783	0.6391	1.061	0.288562
Coche nuevo	-1.067	0.3943	-2.707	0.006798

Devianza nula: 852.29 (686 gl)
Devianza residual: 620.05 (657 gl)
AIC: 680.05 Dispersion binomial: 1

Saldo: coeficiente 1,382
La exponencial de 1,382 da odds de pago 3,98 veces las de saldo negativo.

Error estándar: 0,4272
Mide la incertidumbre del coeficiente, no el error de predicción ni un porcentaje.

p-valor: 0,001213
Evidencia contra un coeficiente nulo al 5 %.

Duración: −0,02832
Un mes más reduce las odds un 2,8 %. No son 2,8 puntos de probabilidad.

```
Probabilidades: p_modelo = modelo.predict(nuevos)
```

Efectos e incertidumbre en el crédito

$\mathrm{OR} = \exp(\beta \times \Delta)$, con las demás variables constantes

- El OR mide la magnitud de la asociación. El intervalo de confianza indica su precisión. Saldo se compara con la referencia y duración se mide por mes.

Comparación	β	OR	IC95 % del OR
Saldo ≥200 DM	1,382	3,98	[1,72; 9,20]
Saldo entre 0 y <200 DM	0,6522	1,92	[1,17; 3,15]
Sin cuenta corriente	2,086	8,05	[4,68; 13,86]
Duración: un mes más	−0,02832	0,972	[0,951; 0,993]

$$\mathrm{IC}_{95\%}(\mathrm{OR}) = \exp(\hat{\beta} \pm 1,96 \times \mathrm{SE})$$

$H_0: \beta = 0$ equivale a $\mathrm{OR} = 1$. El contraste de Wald utiliza $z = \frac{\hat{\beta}}{\mathrm{SE}}$.

Saldo ≥200 DM: OR de 3,98, pero el IC de 1,72 a 9,20 admite efectos muy distintos.
Duración: odds un 2,8 % menores por mes y OR de 0,712 por doce meses.

IC de Wald aproximados. Un p-valor pequeño no demuestra utilidad predictiva ni causalidad.

Un mismo OR, distintas probabilidades

El cambio depende de la probabilidad inicial

Saldo ≥200 DM frente a negativo: $\mathrm{OR} \approx 3,983$.

$$\mathrm{odds}_1 = \mathrm{OR} \times \mathrm{odds}_0$$

$$p_1 = \frac{\mathrm{OR} \times p_0}{1 - p_0 + \mathrm{OR} \times p_0}$$

p_0: saldo negativo	p_1: saldo ≥200 DM
20 % (supuesto)	49,9 %
50 % (supuesto)	79,9 %
80 % (supuesto)	94,1 %

Probabilidades iniciales supuestas. El OR por sí solo no determina la probabilidad de un cliente.

Regresión Logística

Selección de variables

06

laSalle ENG
Universitat Ramon Llull

Selección de variables

Métodos manuales y automáticos

Los métodos del modelo lineal también se aplican a la regresión logística.

Selección manual: la pregunta del estudio y el conocimiento del problema orientan qué variables conservar.

Selección automática: forward añade términos, backward los elimina y stepwise combina ambos. Agiliza la búsqueda, pero puede sobreajustar.

Criterio AIC: equilibra ajuste y complejidad. Entre modelos comparables y con las mismas observaciones, preferimos un AIC menor.

Validación: seleccionamos solo en train y reservamos test para evaluar. La selección automática requiere comprobar su estabilidad.

Regresión Logística

Predicción

07

laSalle ENG
Universitat Ramon Llull

El umbral convierte probabilidades en clases

Predecimos pago si $\hat{p} \geq t$

El umbral t es la probabilidad mínima para predecir éxito (en este caso pago).
Con t = 0,5: ≥ 50 % predice pago y < 50 % predice no pago.

Matriz de confusión: realidad en filas y predicción en columnas. Orden: 0, 1.

Resultado real	Predice impago (0)	Predice pago (1)
Impago (0)	Verdadero negativo (tn)	Falso positivo (fp)
Pago (1)	Falso negativo (fn)	Verdadero positivo (tp)

De quienes pagan, proporción con probabilidad predicha ≥ t.

$$\text{Sensibilidad} = \frac{\text{pagos detectados}}{\text{pagos reales}}$$

De quienes no pagan, proporción con probabilidad predicha < t.

$$\text{Especificidad} = \frac{\text{no pagos detectados}}{\text{no pagos reales}}$$

Verdadero = acierto. Falso = error. Su coste orienta la elección del umbral.

Crédito: diez clientes ilustrativos

Diez observaciones para comparar los umbrales

Probabilidad de pago	Resultado
0.08	Impago
0.27	Impago
0.34	Pago
0.36	Impago
0.44	Impago
0.52	Impago
0.53	Pago
0.54	Impago
0.80	Pago
0.96	Pago

Ejemplo: cuatro pagos y seis impagos.

Implementación

```
import numpy as np
from sklearn.metrics import confusion_matrix
p = np.array([.08,.27,.34,.36,.44,
              .52,.53,.54,.80,.96])
y = np.array([0,0,1,0,0,0,1,0,1,1])
for t in [.4, .5]:
    tn, fp, fn, tp = confusion_matrix(
        y, p >= t).ravel()
    print(f"t={t:.1f}: S={tp/(tp+fn):.3f}, "
          f"E={tn/(tn+fp):.3f}")
```

```
t=0.4: S=0.750, E=0.500
t=0.5: S=0.750, E=0.667
```

Regresión Logística

Validación

08

laSalle ENG
Universitat Ramon Llull

Regresión logística

Curva ROC: todos los puntos de corte

La curva ROC representa, para cada punto de corte de la probabilidad predicha, la sensibilidad en función del complementario de la especificidad.

Cada umbral genera una pareja de valores. El eje horizontal recoge los falsos positivos entre los negativos reales, y el vertical recoge la proporción de los positivos detectados.

$$(x, y) = (1 - especificidad, sensibilidad)$$

Cuanto más se aproxima la curva a la esquina superior izquierda, mejor discrimina. Es decir, cuanto más *"abombada" (menos plana)* sea la curva, major capacidad de predicción.

Bajar el umbral puede aumentar aciertos positivos y falsos positivos. La ROC compara compromisos, pero no fija por sí sola el umbral.

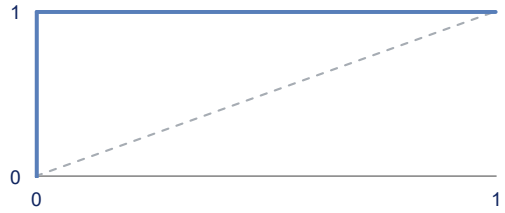
Regresión logística

AUC: área bajo la ROC e interpretación

AUC es el área bajo la ROC. Resume la discriminación: cuanto mayor, mejor ordena los casos positivos frente a los negativos (major capacidad predictiva).

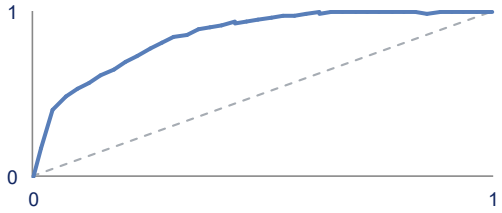
AUC	Interpretación del material
[0,5; 0,6)	Discriminación mala/ Discriminación al azar.
[0,6; 0,75)	Discriminación regular
[0,75; 0,9)	Discriminación buena
[0,9; 1)	Discriminación muy buena

$\mathrm{AUC} = 1$



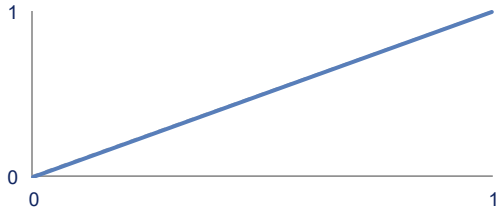
Perfecta

$\mathrm{AUC} \approx 0,8$



Buena

$\mathrm{AUC} = 0,5$



Sin discriminación

Predicción y ROC en Python

ROC y AUC con los diez clientes de la slide 23

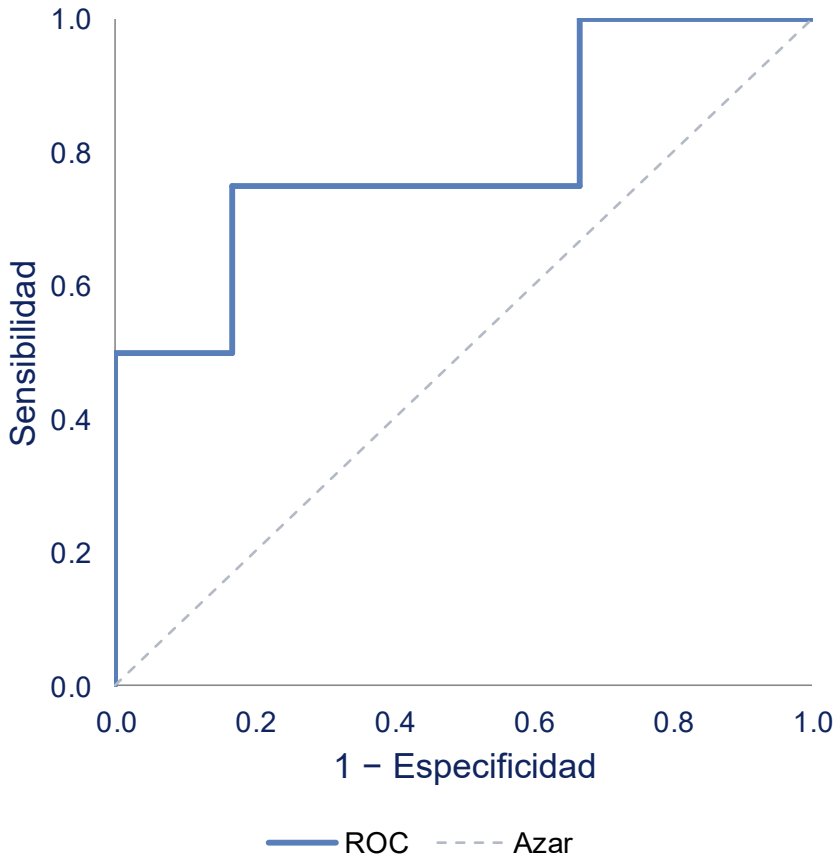
y: clase real (0=impago, 1=pago).
p: probabilidad ilustrativa de pago.
Reutilizamos los diez casos de la 25.

Implementación

```
from sklearn.metrics import (
    roc_curve, roc_auc_score)
# Mismos y, p de la slide 25
# fpr = 1 - especificidad
# tpr = sensibilidad
fpr, tpr, cortes = roc_curve(y, p)
auc = roc_auc_score(y, p)
print(f"AUC = {auc:.4f}")
AUC = 0.7917
```

AUC 0,7917

19 de 24 parejas pago–impago quedan bien ordenadas (79,17 %).



Validación

Hosmer–Lemeshow: cálculo y contraste (bondad de ajuste)

1. Preparación de los grupos

Ordena por probabilidad y forma G intervalos similares (habitualmente 10).
En cada intervalo: n = clientes, O = pagos reales, E = suma de probabilidades.

2. Cálculo del estadístico H

$$H = \sum_{g=1}^{G} \frac{(O_g - E_g)^2}{E_g(1 - E_g/n_g)}$$

Ejemplo hipotético de un grupo
n = 20, O = 10, E = 12
(10 − 12)² / [12(1 − 12/20)] = 0,83

H suma las aportaciones de todos los grupos. Impagos: n − O y n − E.

3. Contraste de hipótesis

H_0: buen ajuste por grupos. H_1: existen discrepancias.
Bajo H_0: referencia χ^2 aproximada con G − 2 gl (G = 10, gl = 8).

p-valor: probabilidad bajo H_0 de un H igual o mayor al observado.

p < 0,05: rechazamos H_0 **p ≥ 0,05: no rechazamos H_0**

No rechazar H_0 no demuestra validez. Revisar recuentos y calibración.

MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull

Anexo: máxima verosimilitud

Máxima verosimilitud: modelo y función objetivo

Cada respuesta y_i es Bernoulli (0 o 1). Conocemos x_i e y_i y buscamos β.

$$\eta_i = \beta_0 + \beta_1 x_i \quad p_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

Un éxito aporta p_i y un fracaso, $1 - p_i$. Los exponentes seleccionan el caso:

$$P(Y_i = y_i \mid x_i, \beta) = p_i^{y_i}(1 - p_i)^{1 - y_i}$$

Para observaciones independientes, multiplicamos las contribuciones:

$$L(\beta) = \prod_{i=1}^{n} p_i^{y_i}(1 - p_i)^{1 - y_i}$$

El logaritmo conserva el máximo y transforma el producto en una suma:

$$\ell(\beta) = ln\, L(\beta) = \sum_{i=1}^{n} [y_i\, ln\, p_i + (1 - y_i)\, ln(1 - p_i)]$$

Anexo: máxima verosimilitud

Derivación y ajuste de los coeficientes

Al sustituir la función logística y agrupar términos:

$$\ell(\beta) = \sum_{i=1}^{n} [y_i \eta_i - ln(1 + e^{\eta_i})]$$

$$ln\, p_i = \eta_i - ln(1 + e^{\eta_i}) \qquad ln(1 - p_i) = -ln(1 + e^{\eta_i})$$

La derivada clave recupera la probabilidad p_i:

$$\frac{d}{d\eta_i} ln(1 + e^{\eta_i}) = \frac{e^{\eta_i}}{1 + e^{\eta_i}} = p_i$$

La regla de la cadena da las condiciones para un máximo finito:

$$\frac{\partial \ell}{\partial \beta_0} = \sum_{i=1}^{n} (y_i - p_i) = 0 \qquad \frac{\partial \ell}{\partial \beta_1} = \sum_{i=1}^{n} x_i (y_i - p_i) = 0$$

Como p_i depende de β, en general no hay un despeje explícito.
El software actualiza β hasta converger. El ejemplo usa L-BFGS sin penalización.