MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull

Índice

Regresión logística

01 Función Link

02 Modelo. Formulación

03 Estimación de los parámetros

04 Interpretación de los coeficientes

05 Selección de variables

06 Predicción

07 Validación

Regresión logística

El caso del crédito y las preguntas de la sesión

¿Cómo se relacionan saldo y duración con el pago? ¿Basta el ajuste para decidir?

- Pago del crédito: respuesta positiva (1)
- Impago o default: respuesta negativa (0)
- Saldo y duración son el foco. El ajuste también incluye otras covariables.

Buscamos una probabilidad de pago coherente con una respuesta binaria:

- La respuesta toma dos valores. Su distribución condicional es Bernoulli.
- Un modelo lineal puede predecir valores fuera de 0–1, como 2,3 o −4,5. La falta de normalidad, por sí sola, no impide calcularlo.

El enlace logit permite formular un predictor lineal y recuperar probabilidades entre 0 y 1. Separaremos interpretación del ajuste y validación para decidir.

Regresión logística

Función Link

- La función link transforma la probabilidad de pago (π) para obtener valores que vayan de −∞ a +∞.
  - π se mueve entre 0 y 1.
  - $\frac{\pi}{1-\pi}$ se mueve entre 0 y +∞. El cociente entre la probabilidad de pago y la probabilidad de impago se denomina ***odd***.
  - $log(\frac{\pi}{1-\pi})$ se mueve entre −∞ y +∞.
- Por tanto, la función ***link*** es $log(\frac{\pi}{1-\pi})$
  - La función $f(x) = log(\frac{x}{1-x})$ se denomina función ***logit***. No es la única función link, pero sí la más usual e interpretable.
  - Cuando la función ***logit*** se aplica a una probabilidad, el resultado se denomina ***logodd*** (abreviatura de logaritmo de un odd).

Probabilidad, odds y logit en Python

Crédito: probabilidad de pago supuesta del 80 %

Ejemplo: cliente con una probabilidad de pago supuesta del 80 %.

```
> from scipy.special import logit, expit
> p = 0.80
> odds = p / (1 - p)
> eta = logit(p)
> p_recuperada = expit(eta)
> print(f"odds={odds:.3f}, logit={eta:.3f}")
> print(f"probabilidad={p_recuperada:.3f}")

[1] odds=4.000, logit=1.386
[1] probabilidad=0.800
```

Resultado: odds de 4 y logit de 1,386.

logit transforma la probabilidad. expit aplica la transformación inversa.

Regresión logística

Modelo

Por tanto el modelo a ajustar será:

$$ln(\frac{\pi}{1-\pi}) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$$

- Si se desea conocer la probabilidad para un conjunto concreto de variables predictoras y ya se han estimado los coeficientes del modelo, se debe deshacer la transformación:

$$PL = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p$$

PL: predictor lineal

$$ln(\frac{\pi}{1-\pi}) = PL \;\Rightarrow\; \frac{\pi}{1-\pi} = odds = e^{PL} \;\Rightarrow\; \pi = e^{PL} - \pi\, e^{PL}$$

$$(1 + e^{PL})\pi = e^{PL} \;\Rightarrow\; \pi = \frac{e^{PL}}{1 + e^{PL}} = \frac{1}{1 + e^{-PL}}$$

La probabilidad queda entre 0 y 1 para cualquier predictor lineal finito.

Regresión logística

Forma de la curva de probabilidad

Con una única covariable X, distintos coeficientes producen distintas curvas de probabilidad.

$\beta > 0$: p aumenta.

$\beta < 0$: p disminuye.

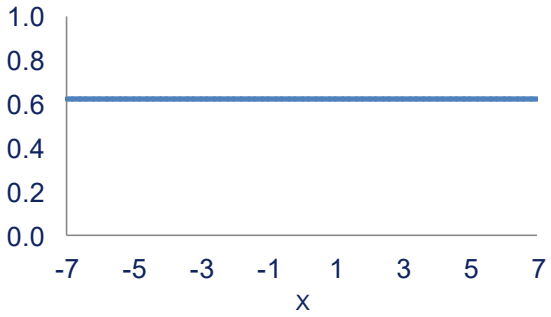
$\beta = 0$: p constante.

En el crédito, duración tiene $\beta < 0$.

La variación de p depende del punto de partida.

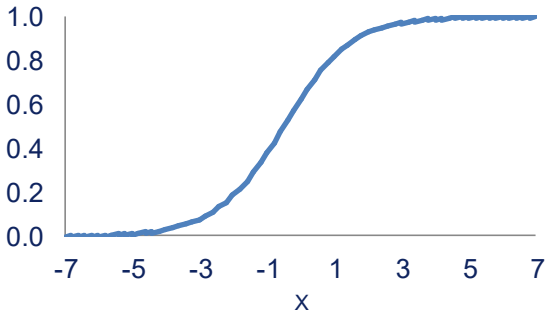
Sin efecto de X

$\beta_0 = 0,5 \quad \beta_1 = 0$



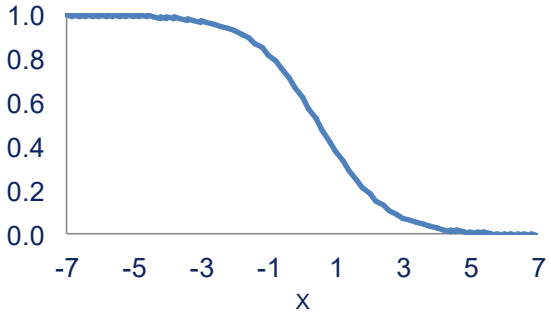
X favorece el éxito

$\beta_0 = 0,5 \quad \beta_1 = 1$



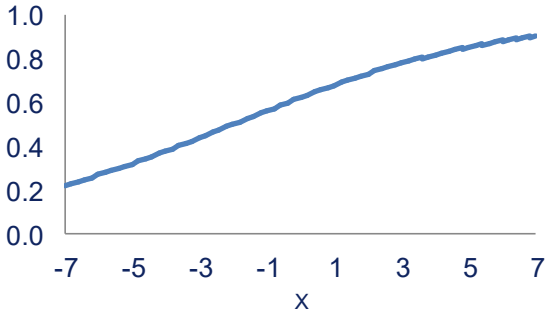
X favorece el fracaso

$\beta_0 = 0,5 \quad \beta_1 = -1$



X favorece levemente el éxito

$\beta_0 = 0,5 \quad \beta_1 = 0,25$



Eje vertical: probabilidad de éxito. La misma escala de 0 a 1 permite comparar las cuatro curvas.

Regresión logística

Estimación de los parámetros del modelo

Los parámetros se estiman por máxima verosimilitud. La respuesta sigue una distribución binomial, o Bernoulli si cada observación contiene un solo ensayo.

El ajuste busca los coeficientes que maximizan la verosimilitud de los datos observados. Cada éxito aporta su probabilidad y cada fracaso, su complementaria.

$$ln(\frac{\hat{\pi}}{1-\hat{\pi}}) = b_0 + b_1 X_1 + \cdots + b_p X_p$$

$b_j = \hat{\beta}_j$

Cada b estima un coeficiente poblacional β. El acento circunflejo indica una cantidad estimada.

Atención: una categoría sin éxitos o sin fracasos puede producir separación o celdas vacías. En ese caso, algún coeficiente puede no tener una estimación finita por máxima verosimilitud.

Regresión logística en Python

Ajuste y output: pago según el saldo

Datos ilustrativos: 20 pagos de 60 con saldo negativo y 40 de 60 con saldo alto (≥200 DM).

```
> # X: 0 = saldo negativo, 1 = saldo alto; y: 1 = paga, 0 = impago
> X = np.repeat([0, 1], 60).reshape(-1, 1)
> y = np.repeat([1, 0, 1, 0], [20, 40, 40, 20])
> modelo = LogisticRegression(C=np.inf, solver="lbfgs",
>                             max_iter=1000, tol=1e-10)
> modelo.fit(X, y)
> b0, b1 = modelo.intercept_[0], modelo.coef_[0, 0]
> p_pago = modelo.predict_proba([[0], [1]])[:, 1]
> print(f"Intercepto: {b0:.4f}; coef. saldo alto: {b1:.4f}")
> print("P(pago) [negativo, alto]:", p_pago.round(4))
> print(f"OR alto/negativo: {np.exp(b1):.4f}")

[1] Intercepto: -0.6931; coef. saldo alto: 1.3863
[1] P(pago) [negativo, alto]: [0.3333 0.6667]
[1] OR alto/negativo: 4.0000
```

Regresión logística

Odds ratio de pago según el saldo

DM significa marcos alemanes, la moneda anterior al euro. «Saldo alto» indica 200 marcos o más en la cuenta corriente, no el importe del préstamo. Lo comparamos con un saldo negativo (cuenta en descubierto).

Saldo de la cuenta	Pagos	Impagos	Total
≥200 DM (alto)	40	20	60
Negativo	20	40	60
Total	60	60	120

$$odds_{alto} = \frac{40}{20} = 2 \quad odds_{negativo} = \frac{20}{40} = 0{,}5$$

$$OR = \frac{odds_{alto}}{odds_{negativo}} = \frac{2}{0{,}5} = 4$$

En este ejercicio, las odds de pago con saldo alto son cuatro veces las de saldo negativo. El OR compara odds, no probabilidades.

Regresión logística

Odds ratio entre dos individuos: desarrollo completo

El OR divide las odds de pago del cliente 1 entre las del cliente 2. Cada odd divide la probabilidad de pago por la de impago.

1. Con el modelo estimado, calculamos las odds de cada cliente

$$odds_1 = exp(b_0 + b_1X_{11} + b_2X_{21} + \cdots + b_pX_{p1})$$

$$odds_2 = exp(b_0 + b_1X_{12} + b_2X_{22} + \cdots + b_pX_{p2})$$

2. Dividimos las odds y restamos los exponentes

$$OR = \frac{exp(b_0 + b_1X_{11} + b_2X_{21} + \cdots + b_pX_{p1})}{exp(b_0 + b_1X_{12} + b_2X_{22} + \cdots + b_pX_{p2})}$$

$$= exp[(b_0 + b_1X_{11} + b_2X_{21} + \cdots + b_pX_{p1}) - (b_0 + b_1X_{12} + b_2X_{22} + \cdots + b_pX_{p2})]$$

$$OR = exp[b_1(X_{11} - X_{12}) + b_2(X_{21} - X_{22}) + \cdots + b_p(X_{p1} - X_{p2})]$$

El intercepto se cancela. Cada coeficiente multiplica la diferencia entre los valores de su variable. En X, el primer subíndice indica la variable y el segundo, el cliente.

Regresión logística

Cambio unitario y codificación de categorías

Comparamos dos clientes que difieren en una unidad de una variable y tienen los mismos valores en las demás. En la fórmula anterior, las otras diferencias se anulan.

$$X_{11} - X_{12} = 1, \qquad X_{k1} - X_{k2} = 0 \quad (k \neq 1)$$

$$OR = exp(b_1)$$

La exponencial del coeficiente multiplica las odds de pago. Por ejemplo, un OR de 2 duplica las odds, no necesariamente la probabilidad.

Para una categoría, el indicador vale 0 en la referencia y 1 en la categoría comparada. Con varias categorías, usamos un indicador por cada categoría no de referencia.

$$OR = exp(1{,}3863) \approx 4$$

En el ejercicio ilustrativo, pasar de saldo negativo a saldo alto multiplica las odds de pago por cuatro. La probabilidad pasa del 33,3 % al 66,7 %, no se cuadruplica.

Ajuste del crédito en Python

Del ejercicio ilustrativo al ajuste multivariable original

Caso original: pago = 1, saldo negativo como referencia y duración en meses.

```
> import statsmodels.api as sm
> import statsmodels.formula.api as smf
> terminos = ["C(status)", "duration", "C(credit_hist)",
>     "C(purpose)", "credit_amo", "C(savings)", "installment",
>     "C(debtors)", "age", "C(installment2)", "C(foreign)"]
> formula = "y ~ " + " + ".join(terminos)
> modelo = smf.glm(formula, data=datos, missing="raise",
>                  family=sm.families.Binomial()).fit()
> print(modelo.summary())
> print(f"Devianza nula: {modelo.null_deviance:.2f}")
> print(f"Devianza residual: {modelo.deviance:.2f}")
> print(f"AIC: {modelo.aic:.2f}")
> print("Convergencia:", modelo.converged)

Resultados de referencia del material:
[1] Devianza nula: 852.29
[1] Devianza residual: 620.05
[1] AIC: 680.05
```

summary() muestra coeficientes e IC del 95 %. Cifras de referencia transcritas del material.

Regresión logística en Python

Interpretación del resumen del ajuste

```
> modelo = smf.glm(formula, data=datos,
    family=sm.families.Binomial()).fit(); print(modelo.summary())
```

```
[1] Cifras originales (extracto)
                        coef   std err       z     P>|z|
Intercepto             1.006     1.176   0.855   0.392390

Saldo >=200 DM         1.382    0.4272   3.236  0.001213
Saldo 0 a <200 DM     0.6522    0.2533   2.575  0.010035
Sin cuenta             2.086    0.2769   7.535  4.90e-14

Duracion (meses)     -0.02832   0.01093 -2.591  0.009556
Hist. critico          1.756    0.4895   3.587  0.000335
Hist. retrasos        0.8378    0.5257   1.594  0.111038
Hist. al dia           1.060    0.4559   2.324  0.020102
Hist. sin creditos    0.6783    0.6391   1.061  0.288562
Coche nuevo           -1.067    0.3943  -2.707  0.006798

Devianza nula: 852.29 (686 gl)
Devianza residual: 620.05 (657 gl)
AIC: 680.05    Dispersion binomial: 1
```

Saldo: coeficiente 1,382

La exponencial de 1,382 da odds de pago 3,98 veces las de saldo negativo.

Error estándar: 0,4272

Mide la incertidumbre del coeficiente. No es un error de predicción ni un porcentaje.

p-valor: 0,001213

Evidencia contra un coeficiente nulo al 5 %..

Duración: coef. −0,02832

Un mes más reduce las odds un 2,8 %. No son 2,8 puntos de probabilidad.

Fuente: resultados originales del crédito. Efectos sobre odds, con las demás variables constantes.

Efectos e incertidumbre en el crédito

$\mathrm{OR} = \exp(\beta \times \Delta)$, con las demás variables constantes

- El OR mide la magnitud de la asociación. El intervalo de confianza indica su precisión. Saldo se compara con la referencia y duración se mide por mes.

Comparación	β	OR	IC95 % del OR
Saldo ≥200 DM	1,382	3,98	[1,72; 9,20]
Saldo entre 0 y <200 DM	0,6522	1,92	[1,17; 3,15]
Sin cuenta corriente	2,086	8,05	[4,68; 13,86]
Duración: un mes más	−0,02832	0,972	[0,951; 0,993]

$$\mathrm{IC}_{95\%}(\mathrm{OR}) = \exp(\hat{\beta} \pm 1,96 \times \mathrm{SE})$$

$H_0: \beta = 0$ equivale a $\mathrm{OR} = 1$. El contraste de Wald utiliza $z = \frac{\hat{\beta}}{\mathrm{SE}}$.

Saldo ≥200 DM: OR de 3,98, pero el IC de 1,72 a 9,20 admite efectos muy distintos.
Duración: odds un 2,8 % menores por mes y OR de 0,712 por doce meses.

IC de Wald aproximados. Un p-valor pequeño no demuestra utilidad predictiva ni causalidad.

Un mismo OR, distintas probabilidades

El cambio depende de la probabilidad inicial

Saldo ≥200 DM frente a negativo: $\mathrm{OR} \approx 3,983$.

$$\mathrm{odds}_1 = \mathrm{OR} \times \mathrm{odds}_0$$

$$p_1 = \frac{\mathrm{OR} \times p_0}{1 - p_0 + \mathrm{OR} \times p_0}$$

p_0: saldo negativo	p_1: saldo ≥200 DM
20 % (supuesto)	49,9 %
50 % (supuesto)	79,9 %
80 % (supuesto)	94,1 %

Probabilidades iniciales supuestas. El OR por sí solo no determina la probabilidad de un cliente.

Regresión logística

Selección de variables y criterio AIC

AIC equilibra ajuste y complejidad: penaliza añadir parámetros. Entre modelos comparables, ajustados a las mismas filas, preferimos un AIC menor.

Forward añade términos, backward los elimina y stepwise combina ambos movimientos. La pregunta del estudio y la estabilidad también orientan la elección.

En backward partimos del modelo completo y probamos eliminar un término cada vez. Aceptamos el menor AIC si mejora el actual. Si no mejora, paramos.

Los factores salen completos. Revisamos separación y convergencia en cada candidato. Seleccionamos solo en train y reservamos test para evaluar.

La selección puede sobreajustar: hay que validar el procedimiento completo. El AIC 680,05 pertenece al ajuste original. La nueva selección sigue pendiente.

El umbral convierte probabilidades en clases

Predecimos pago si $\hat{p} \geq t$

Con pago como evento positivo, cada decisión puede acertar o cometer uno de estos errores.

Resultado real	Predice pago	Predice no pago
Paga	Verdadero positivo	Falso negativo
No paga	Falso positivo	Verdadero negativo

$$\text{Sensibilidad} = \frac{\text{pagos detectados}}{\text{pagos reales}}$$

$$\text{Especificidad} = \frac{\text{no pagos detectados}}{\text{no pagos reales}}$$



El criterio de decisión debe considerar qué errores resultan más costosos.

Crédito: diez clientes ilustrativos

Diez observaciones para comparar los umbrales

Probabilidad de pago	Resultado
0.08	Impago
0.27	Impago
0.34	Pago
0.36	Impago
0.44	Impago
0.52	Impago
0.53	Pago
0.54	Impago
0.80	Pago
0.96	Pago

Ejemplo: cuatro pagos y seis impagos.

```
> import numpy as np
> from sklearn.metrics import confusion_matrix
> p = np.array([.08,.27,.34,.36,.44,
>               .52,.53,.54,.80,.96])
> y = np.array([0,0,1,0,0,0,1,0,1,1])
> for t in [.4, .5]:
>     tn, fp, fn, tp = confusion_matrix(
>         y, p >= t).ravel()
>     print(f"t={t:.1f}: S={tp/(tp+fn):.3f}, "
>           f"E={tn/(tn+fp):.3f}")

[1] t=0.4: S=0.750, E=0.500
[1] t=0.5: S=0.750, E=0.667
```

S: sensibilidad. E: especificidad. Salida calculada con las diez observaciones.

Regresión logística

Curva ROC: todos los puntos de corte

La curva ROC representa, para cada punto de corte de la probabilidad predicha, la sensibilidad en función del complementario de la especificidad.

Cada umbral genera una pareja de valores. El eje horizontal recoge los falsos positivos entre los negativos reales, y el vertical recoge los positivos detectados.

Cuanto más se aproxima la curva a la esquina superior izquierda, mejor discrimina. Es lo que el PDF describe como una curva más «abombada», en lugar de plana.

$$(x, y) = (1 - especificidad, sensibilidad)$$

Bajar el umbral puede aumentar aciertos positivos y falsos positivos. La ROC compara compromisos, pero no fija por sí sola el umbral.

Regresión logística

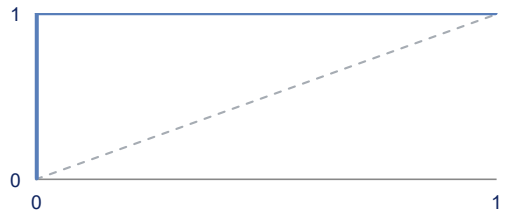
AUC: área bajo la ROC e interpretación

AUC es el área bajo la ROC. Resume la discriminación: cuanto mayor, mejor ordena los casos positivos frente a los negativos.

Equivale a la proporción de parejas pago–impago bien ordenadas. Los empates cuentan como media pareja.

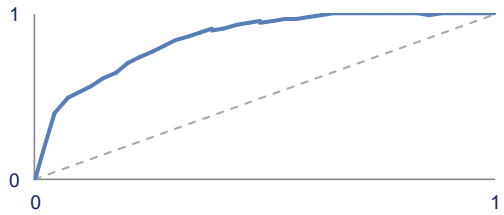
AUC	Interpretación del material
[0,5; 0,6)	Discriminación mala
[0,6; 0,75)	Discriminación regular
[0,75; 0,9)	Discriminación buena
[0,9; 1)	Discriminación muy buena

$\mathrm{AUC} = 1$



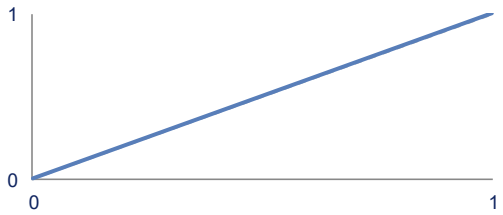
Perfecta

$\mathrm{AUC} \approx 0,8$



Buena (ejemplo)

$\mathrm{AUC} = 0,5$



Sin discriminación

Bandas orientativas. Las ROC son conceptuales. AUC no demuestra calibración ni utilidad de una decisión.

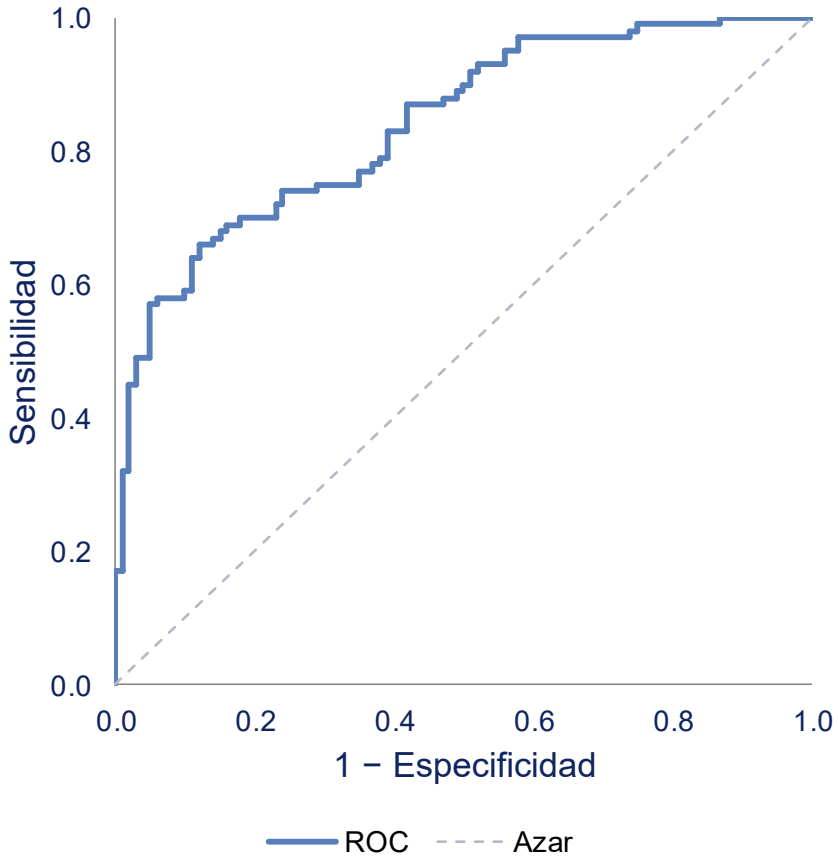
Predicción y ROC en Python

ROC y AUC en una muestra de 200 observaciones

```
> from sklearn.metrics import (
>     roc_curve, roc_auc_score)

> fpr, tpr, _ = roc_curve(
>     y_roc, p_roc)
> auc = roc_auc_score(y_roc, p_roc)
> print(f"AUC = {auc:.4f}")

[1] AUC = 0.8393
```



AUC 0,8393

El 83,93 % de las parejas pago–impago quedan bien ordenadas.

Datos simulados: 200 observaciones, 100 pagos y 100 impagos.

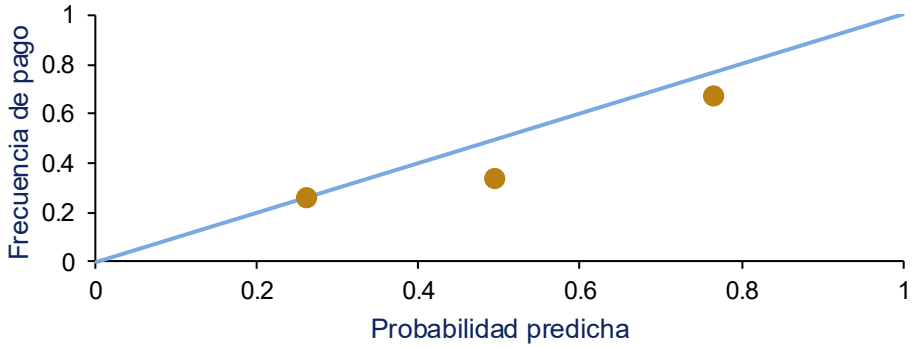
Calibración de las probabilidades

Frecuencia observada frente a probabilidad predicha

Retomamos los diez clientes de la diapositiva 19 y agrupamos sus probabilidades en tres cuantiles.

Diagonal ideal: observado y predicho coinciden.

```
> from sklearn.calibration import calibration_curve
> obs, pred = calibration_curve(y, p,
>     n_bins=3, strategy="quantile")
> print("obs:", obs.round(4))
[1] obs:  [0.25   0.3333 0.6667]
> print("pred:", pred.round(4))
[1] pred: [0.2625 0.4967 0.7667]
```



Primer grupo: 26,25 % predicho y 25 % observado.

Cada punto resume un grupo. Con solo diez casos, este ejercicio no permite validar el modelo.

Datos ilustrativos: diez casos agrupados en tres cuantiles.

Regresión logística

Bondad del ajuste: observados y esperados

Hosmer–Lemeshow compara los efectivos observados y esperados en grupos de probabilidades predichas.

Agrupamos por cuantiles de probabilidad, habitualmente en diez grupos de tamaño parecido. Los empates pueden reducir el número de grupos.

Observados (obs): número de respuestas positivas en cada grupo. Esperados (esp): suma de las probabilidades predichas de los individuos del grupo.

Con un p-valor inferior a 0,05, el contraste aporta evidencia de discrepancias entre observados y esperados. No rechazar no demuestra que el modelo sea válido.

Revisamos tamaños y recuentos esperados. El contraste complementa la gráfica de calibración.

Calibración y Hosmer–Lemeshow

La misma comparación, ahora agrupada

Cada cliente aporta su pago observado (0 o 1) menos su probabilidad estimada. Sumamos esas diferencias por grupo: la misma idea de observado menos predicho.

$$\sum_{i \in g}(y_i - \hat{p}_i) = O_g - E_g$$

$$O_g = \sum_{i \in g} y_i \quad E_g = \sum_{i \in g} \hat{p}_i$$

$$H = \sum_{g=1}^{G} \frac{(O_g - E_g)^2}{E_g(1 - E_g/n_g)}$$

O y E abrevian los pagos observados y esperados del grupo. n es su número de clientes. Agrupamos por cuantiles y revisamos tamaños, empates y recuentos esperados.

Con suficientes efectivos esperados, la referencia habitual es chi-cuadrado con G − 2 grados de libertad. Las muestras grandes pueden detectar discrepancias pequeñas, pero no rechazan siempre.

Un p-valor alto no prueba validez. Complementar con calibración gráfica.

Qué responde el caso

Asociaciones interpretables, uso pendiente de validación

- **Saldo:** odds de pago 3,98 veces las del saldo negativo para ≥200 DM, con el resto constante.
- **Duración:** cada mes adicional se asocia con odds de pago un 2,8 % menores.
- **Probabilidad:** el cambio depende del punto de partida. Un OR no determina por sí solo el riesgo individual.
- **Decisión:** estas asociaciones aún no justifican una regla de concesión.
- **Siguiente paso:** confirmar datos y categorías, reproducir el ajuste y evaluar AUC, calibración y errores en observaciones reservadas.

MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull